

学校代码: 10286
分 类 号: TP393
密 级: 公开
U D C: 004.9
学 号: *****



东南大学

硕士学位论文

面向加密流量分类的博弈对抗防御与高效训练方法研究

(学位论文形式: 应用研究)

研究生姓名: ***

导师姓名: *****

申请学位类别 电子信息硕士 学位授予单位 东南大学

领域名称 网络与信息安全 论文答辩日期 2026 年 月 日

研究方向 加密流量分析 学位授予日期 2026 年 月 日

答辩委员会主席 评 阅 人

2026 年 5 月

東南大學

电子信息硕士学位论文

面向加密流量分类的博弈对抗防御与高效训练
方法研究

专业名称: 网络与信息安全

研究生姓名: ***

导师姓名: *****

RESEARCH ON GAME-THEORETIC ADVERSARIAL DEFENSE AND EFFICIENT TRAINING METHODS FOR ENCRYPTED TRAFFIC CLASSIFICATION

A Thesis Submitted to

Southeast University

For the Professional Degree of Master of
Electronic and Information Engineering

BY

Supervised by

School of Cyber Science and Engineering

Southeast University

May 2026

东南大学学位论文独创性声明

本人声明所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得东南大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

研究生签名：_____日期：_____

东南大学学位论文使用授权声明

东南大学、中国科学技术信息研究所、国家图书馆、《中国学术期刊（光盘版）》电子杂志社有限公司、万方数据电子出版社、北京万方数据股份有限公司有权保留本人所送交学位论文的复印件和电子文档，可以采用影印、缩印或其他复制手段保存论文。本人电子文档的内容和纸质论文的内容相一致。除在保密期内的保密论文外，允许论文被查阅和借阅，可以公布（包括以电子信息形式刊登）论文的全部内容或中、英文摘要等部分内容。论文的公布（包括以电子信息形式刊登）授权东南大学研究生院办理。

研究生签名：_____导师签名：_____日期：_____

摘要

随着网络加密技术的全面普及，网络通信全面步入全加密时代，加密流量分类已成为网络空间安全综合治理的核心环节。尽管深度学习模型在封闭测试中表现优异，但在真实开放的对抗环境中却面临两大严峻的工程挑战：一是面对精心构造的逃逸攻击时表现出显著的脆弱性；二是引入多步对抗训练时，大规模预训练模型面临计算开销激增与显存溢出的算力瓶颈。针对高鲁棒性与高训练开销之间难以兼顾的固有矛盾，本文围绕加密流量抗逃逸防御机理、高效训练架构及工程化部署展开深入研究。全文的主要研究工作与创新成果总结如下：

(1) 提出了基于动态难度调度与二阶反应梯度优化的抗逃逸训练方法（DS-RGO）。针对传统对抗训练模型在面对抗逃逸攻击时鲁棒性差、训练过程易陷入局部最优和梯度震荡的问题，本方法将攻防过程建模为动态 Stackelberg 主从博弈。通过展开双层优化计算包含攻防二阶交互信息的反应梯度，赋予防御策略前瞻性；同时引入课程学习机制，自适应调度对抗样本的生成强度以平滑优化轨迹。在全量公开数据集上的实验表明，该方法不仅成功消除了训练初期的损失震荡，引导模型学习到更具语义不变性的深层协议特征，还将异构骨干网络的对抗鲁棒性较前沿基线方法提升了 4.2%~8.6%，实现了防御能力与收敛稳定性的双重跨越。

(2) 提出了基于动态流过滤与自适应缓存复用的高效训练方法（DF-ACR）。针对大参数序列模型执行多步对抗训练导致的高昂时间成本与显存溢出问题，本方法在时空联合维度进行了算法级轻量化设计。在空间维度，通过实时评估流样本的预测不确定性与梯度敏感度，动态剔除对鲁棒性贡献极低的冗余样本；在时间维度，基于对抗扰动的慢变性假设构建外部记忆库，并通过静态存储--动态对齐策略大幅减少高维张量的反向传播次数。在全量数据集上的实验结果表明，在维持防御精度边际损失极小的前提下，该方法实现了 4.6 倍的端到端训练加速比，显著降低了峰值显存占用，成功突破了大规模模型鲁棒训练中的算力瓶颈。

(3) 设计并实现了面向加密流量的抗逃逸分析与效能评估原型系统。针对真实物理受限环境的部署需求，本文基于 B/S 架构开发了集策略路由、高强度攻击模拟、高效模型训练与特征降维可视化于一体的四层验证平台。系统测试验证表明，在融合上述两大核心算法后，平台不仅在面对高强度逃逸攻击时展现出卓越的防御鲁棒性，更在训练吞吐量与显存优化方面实现了跨越式的性能提升，能平滑部署于 16GB 显存的主流工业边缘计算设备，具备极高的工程实用价值与落地潜力。

关键词：加密流量分析；对抗防御；课程学习；高效训练；Stackelberg 博弈

Abstract

With the widespread adoption of network encryption technologies, network communications have fully entered an era of universal encryption, making encrypted traffic classification a core component of cybersecurity governance. Although deep learning models perform excellently in closed testing environments, they face two severe engineering challenges in real-world open adversarial settings: first, they exhibit significant vulnerability to carefully crafted adversarial evasion attacks; second, when multi-step adversarial training is applied, large-scale pre-trained models suffer from surging computational overhead and memory overflow bottlenecks. To address the inherent trade-off between high robustness and prohibitive training costs, this dissertation conducts in-depth research on the anti-evasion defense mechanism of encrypted traffic, efficient training architectures, and engineering deployment. The main research contributions and innovations are summarized as follows:

(1) An anti-evasion training method (DS-RGO) based on dynamic difficulty scheduling and second-order reactive gradient optimization is proposed. Aiming at the problems of poor robustness, easy convergence to local optima, and gradient oscillation during training in traditional adversarial training models against evasion attacks, this method models the attack–defense process as a dynamic Stackelberg leader–follower game. By performing bi-level optimization to compute reactive gradients that capture second-order attack–defense interaction information, the defense strategy is endowed with foresight. Meanwhile, a curriculum learning mechanism is introduced to adaptively schedule the generation strength of adversarial samples for a smoother optimization trajectory. Experiments on full public datasets demonstrate that this method not only successfully eliminates loss oscillation in the early training stage and guides the model to learn deep protocol features with stronger semantic invariance, but also improves the adversarial robustness of heterogeneous backbone networks by 4.2%–8.6% compared with state-of-the-art baseline methods, achieving a dual breakthrough in defense capability and convergence stability.

(2) An efficient training method (DF-ACR) based on dynamic flow filtering and adaptive cache reuse is proposed. Aiming at the high time cost and video memory overflow caused by multi-step adversarial training performed by large-parameter sequential models, this method carries out algorithm-level lightweight design in the spatiotemporal joint dimension. In the spatial dimension, redundant samples with extremely low contribution to robustness are dynamically eliminated by real-time evaluation of the prediction uncertainty and gradient sensitivity of flow samples; in the temporal dimension, an external memory bank is constructed based on the slow-variation assumption of adversarial perturbations, and the number of backpropagations of high-dimensional tensors is significantly reduced through the static storage-dynamic alignment strategy. Experimental results on full datasets show that with negligible marginal loss of defense accuracy, this method achieves an end-to-end training speedup of 4.6 $\times$, significantly reduces peak video memory usage, and successfully breaks the computational power barrier for robust training of large-scale models.

(3) A prototype system for anti-evasion analysis and performance evaluation oriented to encrypted traffic is designed and implemented. In response to deployment requirements in real

physical constrained environments, this paper develops a four-layer verification platform integrating policy routing, high-intensity attack simulation, efficient model training, and feature dimensionality reduction visualization based on the B/S architecture. System tests and verification show that after integrating the above two core algorithms, the platform not only exhibits excellent defense robustness against high-intensity evasion attacks, but also achieves leapfrog performance improvements in training throughput and video memory optimization. It can be smoothly deployed on mainstream industrial edge computing devices with 16 GB video memory, demonstrating high engineering practical value and application potential.

Keywords: Encrypted traffic analysis; adversarial defense; course learning; efficient training; Stackelberg game

目 录

摘 要	I
Abstract	III
目 录	V
表格目录	IX
插图目录	XI
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	3
1.2.1 加密流量分类技术研究现状	3
1.2.2 加密流量对抗攻击与鲁棒防御研究现状	5
1.2.3 大规模流量模型高效训练与加速研究现状	7
1.3 本文主要研究内容	8
1.4 论文组织结构	9
第二章 相关技术研究	11
2.1 加密流量表征与分类模型基础	11
2.1.1 流量数据的多模态表征机制	11
2.1.2 基于序列模态的预训练语言模型	12
2.1.3 基于视觉模态的卷积神经网络	13
2.2 对抗攻击与防御理论基础	14
2.2.1 对抗样本的定义与生成算法	14
2.2.2 流量场景下的逃逸攻击特殊性	15
2.2.3 传统对抗训练框架及其局限性	16
2.3 博弈论与课程学习基础	16
2.3.1 Nash 均衡与 Stackelberg 均衡	16
2.3.2 双层优化与梯度估计	17
2.3.3 课程对抗训练	18
2.4 高效深度学习训练技术	19
2.4.2 基于数据重要性的核心集选择	19
2.4.3 对抗训练加速与梯度复用	21
2.5 本章小结	21
第三章 基于动态难度调度与二阶反应梯度优化的抗逃逸训练方法	23
3.1 引言	23
3.2 问题定义与威胁模型	23
3.2.1 加密流量分类任务的数学描述	23
3.2.2 流量逃逸攻击的威胁建模	23
3.2.3 Stackelberg 博弈在流量攻防中的映射关系	24
3.3 DS-RGO 方法框架设计	24
3.3.1 总体结构	24
3.3.2 基于课程学习的动态难度调度	25
3.3.3 基于 Stackelberg 博弈的二阶反应梯度优化	27
3.4 算法实现与模型适配	30
3.4.1 DS-RGO 训练算法流程描述	30
3.4.2 针对 ET-BERT 的具体实现细节	31

3.4.3 针对 BUPT-CNN 的具体实现细节	32
3.5 理论分析	32
3.5.1 课程学习策略对非凸损失曲面的平滑作用分析	33
3.5.2 Stackelberg 均衡点的收敛稳定性探讨	33
3.5.3 基于平坦极小值理论的泛化能力解析	34
3.5.4 连续空间博弈的物理映射与理论上限分析	35
3.6 实验评估与分析	36
3.6.1 实验设置	36
3.6.2 综合防御性能对比	39
3.6.3 训练稳定性与泛化性分析	40
3.6.4 消融实验	42
3.6.5 鲁棒性机理与可视化分析	43
3.6.6 攻击强度敏感性分析	45
3.6.7 细粒度类别防御效果分析	46
3.6.8 面向真实物理受限环境的逃逸鲁棒性验证	47
3.7 本章小结	48
第四章 基于动态流过滤与自适应缓存复用的高效训练方法	49
4.1 引言	49
4.2 问题定义与优化目标	49
4.2.1 对抗训练计算复杂度的数学建模	49
4.2.2 效率与鲁棒性的权衡关系	50
4.2.3 基于流样本的时空联合优化问题定义	50
4.3 DF-ACR 方法框架设计	51
4.3.1 总体结构	51
4.3.2 基于动态重要性的数据过滤机制	52
4.3.3 基于流量缓存的复用机制	54
4.4 算法实现与模型适配	56
4.4.1 DF-ACR 训练算法流程	56
4.4.2 针对 ET-BERT 的具体实现细节	57
4.5 理论分析	58
4.5.1 时空复杂度与算法级轻量化证明	58
4.5.2 时空近似计算下的模型收敛性分析	60
4.6 实验评估与分析	60
4.6.1 实验设置	61
4.6.2 综合效率与性能对比	63
4.6.3 资源消耗与显存优化分析	65
4.6.4 消融实验	66
4.6.5 参数敏感性分析	67
4.6.6 动态流过滤过程与自适应类别平衡分析	68
4.6.7 资源利用率与大批次扩展性分析	70
4.6.8 工程综合收益评估	71
4.7 本章小结	71
第五章 加密流量分析集成平台与评估系统的设计与实现	73
5.1 系统需求分析	73
5.1.1 功能性需求	73
5.1.2 非功能性需求	74

5.2 系统架构设计	74
5.3 系统功能模块设计	75
5.3.1 用户管理模块	75
5.3.2 模型训练模块	76
5.3.3 模型验证模块	78
5.3.4 可视化分析模块	79
5.4 系统部署与运行环境	80
5.4.1 软硬件环境配置	80
5.4.2 运行优化策略	80
5.5 系统功能测试	81
5.5.1 功能测试	81
5.5.2 性能测试	83
5.5.3 安全性测试	85
5.6 本章小结	87
第六章 总结与展望	89
6.1 论文总结	89
6.2 工作展望	89
参考文献	91
作者简介	95

表格目录

表 3-1 DS-RGO 算法	30
表 3-2 实验软硬件环境配置	38
表 3-3 骨干网络训练超参数设置	38
表 3-4 对抗攻击与防御机制参数设定	39
表 3-5 不同防御方法在 ET-BERT 上的分类准确率对比	39
表 3-6 不同防御方法在 BUPT-CNN 上的分类准确率对比	40
表 3-7 核心组件有效性的消融实验详细数据对比	42
表 4-1 DF-ACR 算法	56
表 4-2 实验软硬环境配置	62
表 4-3 不同训练方法的训练参数设定	62
表 4-4 不同训练方法的时间开销对比	63
表 4-5 不同训练方法的分类准确率对比	63
表 4-6 典型多数类与少数类在不同训练阶段的动态保留率对比	69
表 4-7 异构训练策略下 ET-BERT 模型的资源开销与轻量化收益对比	71
表 5-1 系统开发与部署环境配置表	80
表 5-2 系统功能测试用例与结果一览表	82
表 5-3 训练加速与资源开销对比测试表	83
表 5-4 面向海量离线 PCAP 文件的端到端检测吞吐量评估	84
表 5-5 对抗攻击下的鲁棒性评估数据表	85

插图目录

图 1-1 加密网络环境下的流量监管困境	1
图 1-2 工业互联网 IT/OT 融合下的加密对抗与防御受限场景	2
图 1-3 网络流量检测技术演进图	3
图 1-4 基于对抗扰动的加密流量逃逸攻击示意图	5
图 1-5 大规模预训练模型面临的计算资源瓶颈与训练效率挑战	7
图 1-6 论文组织架构	10
图 2-1 加密流量的多模态数据表征与预处理流程	11
图 2-2 ET-BERT 模型的预训练掩码机制示意图	12
图 2-3 对抗攻击下的决策边界偏移示意图	14
图 2-4 纳什均衡与 Stackelberg 博弈的决策逻辑对比	17
图 2-5 传统对抗训练与课程对抗训练的收敛机制对比	18
图 2-6 大规模模型多步对抗训练显存溢出机制	19
图 2-7 基于核心集的数据筛选原理	20
图 3-1 DS-RGO 方法整体框架图	25
图 3-2 动态攻击难度调度策略曲线图	26
图 3-3 Stackelberg 博弈交互与梯度反向传播机制图	29
图 3-4 不同模型架构下各训练策略的损失收敛轨迹对比	41
图 3-5 鲁棒准确率随训练轮次的泛化趋势分析	41
图 3-6 核心组件在异构模型上的消融实验结果对比	43
图 3-7 强对抗攻击下特征空间分布的 t-SNE 可视化对比	44
图 3-8 对抗环境下关键流量字段的注意力机制热力图对比	45
图 3-9 不同扰动半径下的模型鲁棒性敏感度分析	46
图 3-10 DS-RGO 模型在强攻击下的细粒度分类混淆矩阵	47
图 3-11 面向真实物理受限环境的逃逸鲁棒性验证	48
图 4-1 DF-ACR 方法整体框架图	51
图 4-2 基于重要性的流样本动态过滤示意图	53
图 4-3 扰动缓存的更新与复用状态机制图	55
图 4-4 训练效率与鲁棒准确率的 Pareto 前沿权衡分析	64
图 4-5 不同训练策略下的 GPU 显存峰值占用对比	65
图 4-6 异构大模型单轮训练耗时的细粒度成分分解	65
图 4-7 核心加速模块有效性的消融实验结果	66
图 4-8 动态过滤保留比例 ρ 对加速比与精度的影响	67
图 4-9 检索缓存更新周期 T_c 对模型性能的敏感性分析	68
图 4-10 训练全周期内流样本动态过滤过程的可视化	69
图 4-11 不同批次大小下的计算吞吐量与扩展性分析	70
图 5-1 系统总体架构图	74
图 5-2 系统功能模块设计图	75
图 5-3 实验任务生命周期状态图	76
图 5-4 模型训练与策略适配流程图	77
图 5-5 对抗鲁棒性验证流程图	78
图 5-6 可视化评估交互时序图	79
图 5-7 实验配置与策略路由交互界面	82
图 5-8 实时训练监控与资源审计大屏	84

图 5-9 对抗防御效能评估结果界面	86
图 5-10 特征空间可视化分析界面	87

第一章 绪论

1.1 研究背景与意义

随着新一代信息技术的飞速发展与数字化转型的深入推进，网络通信已成为支撑现代社会运转的核心组成部分。为了应对日益严峻的数据泄露、网络监听以及满足公众对隐私保护的迫切需求，加密通信技术开始在各类网络应用场景中全面普及并应用。当前，互联网传输协议正经历着一场巨大变革，以 TLS 1.3、QUIC 为代表的新一代加密协议已成为流量传输的基础。这些协议通过引入 0-RTT，快速连接建立前向保密以及加密服务等机制，极大地提升了通信的安全性及效率^[1]。根据 Sandvine 发布的全球互联网现象报告及 Google 透明度报告显示，全球互联网中加密流量的占比已稳居 90% 以上，在移动通信、跨境电商及金融支付等关键领域甚至接近 100%，网络空间正式步入全加密时代^[2]。

然而，流量的全面加密化客观上造成了网络监管边界的暗箱化，导致传统的网络管理手段面临失效危机。长期以来，网络防火墙、入侵检测系统以及服务质量保障设备主要依赖深度包检测技术（Deep Packet Inspection, DPI）^[3]。该技术通过匹配数据包载荷中的明文特征来精准识别业务类型或检测恶意攻击。但在全加密环境下，数据载荷被加密算法混淆为高熵值的伪随机序列，特征字符串彻底不可见。同时，随着动态端口和端口随机化技术的广泛应用，传统的基于 IANA 知名端口号的分类方法也已不再可靠^[4]。这种载荷不可读、端口不可信的技术代沟，使得网络管理者逐渐失去了对流量内容的感知与管控能力，网络安全边界变得日益模糊。加密环境下的监管困境如图 1-1 所示，在传统明文环境下，DPI 能够通过内容匹配识别威胁。然而在右侧所示的加密环境中，数据载荷的不可见性导致传统防御形同虚设。



图 1-1 加密网络环境下的流量监管困境

此外，加密技术的广泛应用具有显著的双刃剑效应：它在为合法用户构建安全屏障的同时，也为恶意行为提供了可行路径。攻击者正利用加密协议的不可见性，将恶意流量伪装成正常的网络通信数据，从而构建起穿透传统防御体系的隐蔽通道。据 SonicWall 发布的网络威胁报告揭示，利用加密通道进行的恶意攻击呈持续上升趋势，超过 40% 的恶意软件已具备加

密通信能力^[5]。僵尸网络、勒索病毒以及高威胁组织广泛使用 HTTPS、Tor 等协议来隐藏其命令与控制信道和数据窃取行为，以逃避防火墙的审查与阻断^[6]。这种披攻击手段使得传统的基于黑名单或规则匹配的防御策略无效，网络防御被迫从简单的规则匹配向复杂的行为分析转型。

这一威胁在工业互联网领域尤为严峻。作为新一代信息技术与工业系统深度融合的产物，工业互联网已成为国家关键信息基础设施的重要组成部分。随着 IT 与 OT 网络的深度融合，原本封闭的工业控制系统逐渐开放，攻击面显著扩大^[7]。在这些对实时性、可靠性要求极高的工业场景中，网络环境呈现出高度异构化和协议私有化的特征。攻击者开始利用流量变形等智能化手段，通过动态调整包长分布和发送时序，将恶意流量伪装成正常的工业协议流量，极易引发生产中断甚至物理设施损坏的安全事故^[8]。更为矛盾的是，工业边缘设备通常计算资源与存储空间十分有限。然而，现有的高性能加密流量分析模型参数量巨大，难以满足工业场景下对低延迟、轻量化和快速更新的严苛要求^[9]。工业互联网 IT/OT 融合下的加密流量对抗与资源受限场景如图 1-2 所示，在 IT 与 OT 网络深度融合的架构中，攻击者利用加密协议的隐蔽性构建逃逸通道，能够轻易穿透基于特征匹配的传统 IT 边界防护。同时，当恶意流量到达 OT 边缘侧时，由于工业网关和边缘计算设备存在严格的算力瓶颈，难以直接部署大规模高鲁棒性的防御模型。




图 1-2 工业互联网 IT/OT 融合下的加密对抗与防御受限场景

为了突破 DPI 的局限，学术界逐渐将深度学习技术引入加密流量分析领域，试图利用流统计特征或时空特征实现端到端的自动化分类。虽然深度学习模型在特征提取能力上取得突破，但在实际部署中仍面临对抗鲁棒性缺失的难题。现有模型多基于封闭数据集训练，然而在现实对抗中，深度学习模型表现出极度的脆弱性。研究表明，攻击者只需利用自动化工具对数据包进行微小的扰动，即可诱导高精度模型产生高置信度的误判，导致安全防线崩溃^[10]。因此，如何在资源受限且对抗激烈的复杂环境下，构建鲁棒、高效的加密流量防御体系，已成为亟待攻克的关键难题。

尽管当前已有许多基于深度学习的加密流量分类研究成果，但为了提供更加可靠、可控的网络安全监测服务，并进一步提升模型在复杂对抗环境下数据识别的实时性与准确性，针对动态博弈防御与高效训练技术的研究仍具有重要的学术价值与工程应用意义。

1.2 国内外研究现状

通过结合本文的研究内容、研究方法以及应用场景，下面将从加密流量分类技术、对抗攻击与鲁棒防御和大规模流量模型高效训练与加速的研究现状三个方面，概述当前国内外研究现状及发展趋势。

1.2.1 加密流量分类技术研究现状

随着网络传输协议的快速演进，加密流量分类技术的研究大致经历了四个发展阶段，其演进脉络如图 1-3 所示。早期深度包检测技术高度依赖明文特征匹配，在加密流量大规模普及后适用性显著下降；随后基于流统计特征的传统机器学习方法得到广泛应用，但该类方法严重依赖人工设计特征，模型泛化能力存在明显瓶颈；当前，基于端到端自动特征提取的深度学习已成为主流方案，然而在面对针对性构造的对抗逃逸攻击时，模型仍表现出显著的脆弱性。这一技术发展趋势，也推动当前研究范式逐步向大规模预训练模型与博弈对抗防御相结合的方向发展。



图 1-3 网络流量检测技术演进图

早期的流量分类主要依赖基于端口的方法，以 IANA 定义的端口号曾是分类的主要依据。然而，随着动态端口分配、网络地址转换以及端口随机化技术的广泛应用，基于端口的分类效果大幅退化。Moore^[3]指出基于端口的分类准确率已大幅下降至 50%-70%，难以满足实际需求。随后，基于 DPI 的方法成为主流。该技术通过分析数据包载荷中的特征字符串进行识别。但在全加密环境下，载荷被混淆为高熵值的伪随机序列，特征彻底不可见。Fu^[1]在综述中指出，随着 TLS 1.3 协议对握手阶段的加密，DPI 技术正面临全面失效的困境。此外，Cui 等人^[11]指出，DPI 方法还面临着特征库维护成本高昂的问题，面对海量且频繁更新的恶意软件，人工提取规则的速度已远远落后于攻击技术的迭代速度。

为了克服加密带来的不透明性，研究者转向利用流级别的统计特征进行分类。这一阶段的研究主要聚焦特征工程的精细化。Draper-Gi^[4]公开了经典的 ISCX-VPN-NonVPN 数据集，并提取了流持续时间、包长序列、包到达间隔等统计特征，利用 C4.5 决策树和 k-NN 算法实现了对 VPN 流量的识别。Lashkari^[12]进一步提出了基于时间的流特征提取方法，通过随机森林算法有效区分了 Tor 匿名流量。除了侧信道特征，Fan 等人^[6]总结指出，流量载荷的熵值也是区分加密流量与压缩文件的关键特征，Wang 等人^[13]利用熵值特征成功区分 8 种不同的加密

流量。此外, Shen 等人^[14]针对 Web 指纹识别场景, 提出了结合累计和与 k-指纹特征的方法, 提升了细粒度分类的效果。然而, 这类方法高度依赖人工特征工程。Rezaei^[15]指出, 人工提取的特征往往依赖专家经验, 泛化能力较差, 且难以捕捉长序列数据中复杂的时序依赖关系。

随着深度学习技术的发展, 其强大的自动特征提取能力逐渐取代传统机器学习成为主流。纵观当前的学术前沿, 基于深度学习的加密流量分类研究主要围绕序列模态、视觉模态以及图模态这三个维度展开。对于视觉模态, 该类方法基于流量即图像的假设。Wang 等人^[16]提出的 M-CNN 模型将数据包的前 N 个字节映射为灰度图像, 利用 2D-CNN 提取流量的纹理特征。Rezaei 等人^[15]提出了利用迁移学习的思路, 将在 ImageNet 上预训练的 CNN 模型迁移至流量分类任务, 解决了训练数据不足的问题。Zhang 等人^[17]进一步优化了该方法, 针对 SSL/TLS 流量, 提出了基于会话级图像转换与深度森林结合的检测方法, 有效实现了细粒度的恶意流量分类。对于序列模态, 该类方法将流量视为时间序列。Lopez-Martin 等人^[18]率先利用长短时记忆网络和门控循环单元捕捉数据包头部的时序相关性, 不仅利用了包长、间隔等统计信息, 还融合首部字节的语义信息。Lotfollahi 等人^[19]提出的 Deep Packet 框架整合了堆叠自编码器与一维卷积神经网络, 实现了对加密应用类型和恶意软件流量的高精度分类。对于图模态, 为了捕捉流量通信模式中的拓扑结构, 基于图神经网络的方法成为新的研究趋势。Fan 等人^[6]在综述中提到, Wang 等^[16]人构建了基于流和图的混合分析模型, 通过图结构挖掘通信节点之间的交互关系, 在检测僵尸网络等加密流量时表现出色, 准确率达到了 99.94%。

然而, 图模态方法主要依赖于多条流之间交互关系的构建, 其计算图构建过程复杂, 难以满足工业互联网边缘端对单条流进行实时、端到端检测的效率需求; 同时, 本文旨在解决针对数据包载荷内容的逃逸攻击, 而非针对通信关系的分析。因此, 为了构建更具通用性且高效的抗逃逸防御体系, 本文的研究范围将聚焦于基于载荷分析的视觉模态与序列模态, 后续章节不再对图模态展开深入探讨。

近年来, 受自然语言处理领域 BERT 模型的启发, 将数据包字节流视为自然语言进行建模成为新的研究热点, 即预训练模型(Pre-trained Language Models, PLM)。Lin 等人^[20]在 WWW 会议上提出的 ET-BERT 模型是该方向的里程碑。该模型采用 Transformer 架构, 通过在大规模无标注流量数据上执行掩码突发预测和同源流预测任务进行预训练, 能够学习到加密协议握手阶段深层的上下文交互特征。在微调阶段, ET-BERT 仅需少量样本即可在多个基准数据集上达到超过 99% 的精度。随后, He 等人^[21]提出的 PERT 模型通过引入动态掩码机制, 进一步提升模型在少样本场景下的表现。

虽然上述基于深度学习的加密流量分类方法在封闭、静态的实验环境下已达到极高的识别精度, 但在面对真实、动态且对抗激烈的网络空间时, 其实际部署仍面临两大核心瓶颈: 对抗环境下的鲁棒性缺失与大规模数据下的训练效率低下。一方面, 现有模型普遍基于环境良性的理想假设, 缺乏内生的安全防御机制。正如 Yan 等人^[22]所指出的, 以 ET-BERT 为代表的高精度模型对输入数据的微小扰动极度敏感, 难以抵御旨在逃避检测的流量逃逸攻击。虽然目前已有 SMOTE 过采样或 GAN 生成式增强^[23]等数据级方法, 以及代价敏感学习^[24]等算法级方法, 但在高度动态的加密流量场景下, 如何保持少数类的召回率仍是挑战。另一方面, 随着深度学习模型向亿级参数规模演进, 其计算复杂度呈指数级上升。Wang 等人^[9]强调, 高

高昂的训练成本与推理延迟已严重制约了此类模型在工业互联网等资源受限场景下的实时更新与部署，且现有模型多基于闭集假设。此外，Zhang 等人^[25]的研究表明，面对网络中涌现的新型加密应用，传统分类器会将其错误分类为已知类别，缺乏有效的开集识别能力。

综上所述，如何在保证高分类精度的前提下，同时突破对抗鲁棒性与训练高效性的双重壁垒，已成为加密流量分析技术实战化落地的关键。针对这两大挑战，下文将分别对现有的相关研究现状与局限性展开深入剖析。

1.2.2 加密流量对抗攻击与鲁棒防御研究现状

随着机器学习与深度学习技术深度融入网络流量分析领域，网络攻防的焦点已从传统的系统漏洞利用，逐渐演变为针对检测模型的算法对抗与策略博弈。攻击者不再局限于仅仅通过加密协议隐藏载荷内容，而是利用数据驱动模型的高维决策边界脆弱性发起对抗攻击。其核心机制如图 1-4 所示：攻击者旨在生成对抗样本以实现流量逃逸，即在保持原始流量恶意功能不变的前提下，通过在特征空间施加微小扰动诱导模型误判，从而在复杂的异构网络环境中规避安全检测。这一严峻趋势迫使防御体系必须从基于特征匹配的静态检测，向基于对抗学习、主动防御及博弈决策的动态体系演进。




图 1-4 基于对抗扰动的加密流量逃逸攻击示意图

在深度学习赋能的加密流量分析领域，算法对抗的底层机制上，流量逃逸主要源于深度学习模型对输入空间微小扰动的极度敏感性。余正飞等^[26]在对抗机器学习综述中指出，攻击者通过在原始恶意流量中添加难以察觉的对抗扰动，能够诱导模型在保持高置信度的情况下做出错误分类。Goodfellow 等^[27]提出的快速梯度符号法揭示了线性模型在高维空间中的脆弱性，证明了仅需沿梯度方向施加微小步长的扰动即可导致模型误判。而在更为现实的黑盒攻击场景下，Papernot 等^[28]提出的基于雅可比显著图的方法表明，攻击者可以通过构建替代模型寻找对分类结果影响最大的特征点，利用对抗样本的迁移性实现跨模型的规避检测。随着生成式 AI 发展，Iliyasu 等^[29]的研究进一步证实，利用生成对抗网络可以自动化地学习良性流量的分布特征并将其注入恶意流量，使得生成的对抗流量在特征空间上与正常背景流量高度重叠，极大提升逃逸攻击的智能化水平。

除了算法层面的对抗，工业互联网、物联网及无线网络等特定场景的协议特殊性与设备异构性，为流量逃逸提供了天然的物理掩护。刘奇旭等^[7]通过对工业互联网流量的深入分析指出，IT 与 OT 网络的深度融合导致了安全边界的模糊，攻击者倾向于利用 Modbus、S7Comm 等私有工业协议的解析盲区进行逃逸，例如通过将恶意指令拆解并混入正常的周期性轮询流量中实施慢速攻击，从而有效规避基于阈值的异常检测。在物联网环境中，Shukla 等^[30]分析发现，海量异构设备产生的背景流量噪声极大，攻击者利用 IoT 设备流量的规律性，通过模拟智能家居设备的发送频率发起低速率拒绝服务攻击，这种攻击能够轻易绕过基于体积统计

的传统防火墙。针对无线通信网络的开放信道与动态拓扑特性，程定国等^[31]强调，在无线自组网中，攻击者通过频繁变换路由路径或模拟无线信道的多径衰落效应，人为制造丢包和重传特征，使得防御者难以区分正常的网络抖动与恶意的丢包攻击，在链路层掩盖其攻击行为。

面对日益复杂化和场景化的逃逸手段，传统的被动式防御已难以招架，研究重心正转向提升模型鲁棒性与构建多维主动防御体系。在增强模型内生安全方面，余正飞等^[26]总结了对抗训练与防御蒸馏等关键技术。Madry 等^[32]提出的基于投影梯度下降的对抗训练方法，通过在训练过程中混合最强的一阶对抗样本，显著提升模型在面对流量变形时的决策边界稳健性。针对工业及物联网设备的资源受限问题，Mohamed 等^[33]提出基于物理层特征的防御思路，指出利用 LoRaWAN 等设备的射频指纹可作为难以伪造的身份标识，有效识别那些在应用层伪装完美但在物理发射特征上存在异常的设备。Telikani 等^[24]则提出了一种代价敏感的学习机制，在提升鲁棒性的同时解决因恶意样本稀缺导致的类不平衡问题，确保了逃逸攻击的检出率。

更为根本的防御变革在于引入主动防御与博弈论思想，旨在打破攻防双方的信息不对称，将防御前置。杨宇等^[34]提出了包含预测-防御-检测-响应闭环的主动防御模型，其核心在于动态目标防御技术。Jajodia 等^[35]的研究表明，通过动态变换网络配置、随机化检测模型的特征提取窗口或定期重置模型参数，可以不断改变系统的攻击面，迫使攻击者花费大量时间进行探测，从而大幅降低其逃逸攻击的成功率。考虑到攻防本质上的策略对抗属性，刘小虎等^[36]指出，在信息不完备条件下防御决策应被建模为贝叶斯博弈。通过构建攻防收益矩阵并计算纳什均衡点，可以在有限资源下选择最优的检测阈值和防御部署策略。Liang 等^[37]进一步提出了演化博弈模型，模拟攻防策略的长期动态演化过程，为应对未知逃逸攻击提供了理论指导。此外，Wang 等^[38]结合图神经网络提出的防御方法，通过分析通信节点间的拓扑交互模式而非单一流量的特征，有效识别出异常的路由行为，为复杂网络环境下的反逃逸提供了新的方案。

尽管现有的研究在加密流量对抗攻击与鲁棒防御体系构建方面取得了显著进展，但面对日趋复杂的网络攻防态势与异构化的网络环境，当前技术在实际应用中仍面临诸多局限与挑战。首先，高质量对抗样本数据的匮乏与数据孤岛现象严重制约了防御模型的泛化能力。樊祖薇等^[6]指出，现有的研究大多依赖于陈旧或合成的公开数据集，缺乏针对真实工业控制系统或大规模物联网场景下的高隐蔽性逃逸攻击样本，导致实验室环境下训练出的高鲁棒性模型在面对现网中不断演变的各种变种攻击时，往往表现出严重的性能衰退。其次，防御模型的计算开销与边缘设备资源受限之间的矛盾尚未得到有效解决。刘奇旭等^[7]强调，虽然对抗训练和基于 GNN 的防御方法能显著提升检测性能，但其高昂的计算与存储成本难以适配对实时性要求极高且算力有限的工业控制器或 IoT 终端；同时，余正飞等^[26]也提到，对抗训练往往以牺牲模型在良性样本上的准确率为代价，这种鲁棒性-准确性的权衡在实际部署中极难把握。付钰等^[1]分析认为，当前的分类模型普遍缺乏对未知类别的开集识别能力，一旦攻击者采用全新的协议伪装或流量变形策略，模型极易将其错误归类为已知良性流量而非发出警报。最后，基于博弈论的主动防御策略在落地时面临理论简化的挑战。刘小虎等^[36]指出，现有的攻防博弈模型往往建立在参与者完全理性及收益矩阵静态可知的理想假设之上，而在真实的攻防对抗中，信息往往是高度不完备且动态变化的，寻找纳什均衡点的计算复杂度使得实时的最优防御决策难以在毫秒级的网络攻防中快速生成。因此，如何在复杂的非凸优化曲

面上构建符合攻防时序逻辑的防御模型，并解决强对抗环境下的梯度震荡与收敛困难问题，是当前提升加密流量分析鲁棒性亟需突破的关键瓶颈。

此外，必须指出的是，现有研究大多集中在计算机视觉与自然语言处理领域的连续特征空间对抗。将其直接迁移至网络空间安全领域，特别是加密流量分类场景中，存在着巨大的语义与协议鸿沟。网络流量具有强时序性、高度离散性以及严格的底层协议状态机约束，单纯的数值型噪声注入在物理网络中往往会破坏协议完整性。同时，安全防御者面临的是具有强目的性的高级持续性威胁或动态规避攻击，而非简单的自然分布偏移。如何在保证加密协议规范的前提下，将高维空间的理论对抗防御映射为对实际恶意流量伪装的有效拦截，是本文在引入博弈理论时着力解决的核心难点。

1.2.3 大规模流量模型高效训练与加速研究现状

随着高速网络带宽的普及以及加密协议的广泛应用，流量分析领域正面临前所未有的数据爆炸挑战。经典的加密流量数据集原始流量文件动辄达到数 GB 甚至 TB 级别，且由海量的小文件数据包组成。贺巩山等^[39]在面向深度学习的数据存储技术综述中深入剖析了这一现象，指出随着数据集规模的指数级增长，深度学习训练面临严峻的 I/O 墙挑战。当 GPU 等加速器的计算能力遵循摩尔定律飞速提升时，底层存储系统的 I/O 吞吐能力却相对滞后。Dean 等^[40]的研究进一步量化了这一差距，表明在处理海量小文件时，频繁的元数据操作与随机读取会导致存储系统的吞吐率下降至峰值的 10% 以下。具体到流量分析场景，训练任务通常需要随机读取海量数据包以打乱样本顺序，这导致严重的缓存抖动，致使昂贵的计算资源因等待数据加载而被迫闲置，这种数据饥饿现象已成为制约大规模流量模型训练的核心瓶颈。这种情况如图 1-5 所示，在处理大规模流量数据时，I/O 阻塞与显存限制往往导致训练进程频繁中断或效率极低，已成为制约高性能模型快速迭代的核心障碍。




图 1-5 大规模预训练模型面临的计算资源瓶颈与训练效率挑战

面对大规模数据带来的计算与存储压力，当前的主流研究主要侧重于模型侧的轻量化设计，试图通过降低模型复杂度来提升整体效率。唐湘云等^[41]在联邦学习算法效率的分析中总结了当前的模型压缩技术，包括网络剪枝、权重量化及知识蒸馏等。例如，Han 等^[42]提出的深度压缩技术通过剪除冗余连接并量化权重，显著减少了模型的存储需求。Hinton 等^[43]的知识蒸馏框架则通过教师-学生网络模式，将大模型的知识迁移至轻量级模型中。然而，这些重模型压缩、轻训练加速的思路存在本质局限：一方面，模型压缩虽然降低了推理阶段的延迟，但并未解决训练阶段海量数据的加载与前向、反向传播的巨大开销，McMahan 等^[44]在联邦平均算法的研究中指出，在训练初期进行过度压缩往往会导致模型难以收敛；另一方面，肖国庆等^[45]在大规模图神经网络研究中指出，面对复杂的非欧氏空间数据或高维流量特征，过度

的简化采样往往会导致关键结构信息的丢失。Chiang 等^[46]的实验也证实,在处理长尾分布数据时,粗粒度的压缩策略会显著牺牲模型对少数类样本的识别精度,这对于需要高精度的恶意流量检测任务而言是不可接受的。

为了解决训练过程本身的效率问题,数据库与系统领域的学者提出了一系列数据管理与采样优化方案,为流量分析提供了新的跨域视角。李国良等^[47]提出了面向 AI 的数据管理技术,主张利用数据库成熟的索引与物化视图技术,通过库内学习将计算下推至存储层。Hellerstein 等^[48]开发的 MADlib 系统展示了如何在数据库引擎内部直接执行线性代数运算,避免了数据在存储与计算引擎之间的高频传输,从而显著降低 I/O 开销。与此同时,针对与流量拓扑结构具有相似性的图数据训练难题,肖国庆等^[45]总结了基于采样的训练策略。Hamilton 等^[49]提出的 GraphSAGE 算法通过邻居采样技术,将全图训练转化为小批次,有效降低单次迭代的内存需求,解决了大规模图数据的显存溢出问题。

尽管上述通用技术提供了优化思路,但在加密流量分析的特定场景下,仍存在显著的研究空白。首先,现有的优化方案缺乏针对流量数据特性的数据筛选机制。王睿等^[50]在边缘智能协同训练的研究中强调,边缘设备存储与计算资源极度受限,无法容纳全量原始流量。然而,网络流量包含大量冗余的重传包、确认包及高度相关的时序载荷,直接应用通用的随机采样策略会导致关键握手特征丢失。Mao 等^[51]的研究表明,缺乏语义感知的筛选机制会使得大量算力浪费在无效数据的训练上。李国良等^[47]虽然提到了利用视图缓存中间结果,但在流量分析中,繁重的包头解析、流重组以及统计特征提取往往在超参数搜索或多轮迭代中被重复执行。Boehm 等^[52]在 SystemML 的研究中指出,对于迭代式机器学习任务,缺乏细粒度的计算复用是导致端到端训练时间过长的主要原因。因此,如何设计一种既能适应流量时空相关性进行高效筛选,又能实现特征提取阶段计算缓存复用的训练框架,是打破大规模流量分析效率瓶颈的关键步骤。

1.3 本文主要研究内容

针对上述两大挑战,本文分别从博弈对抗防御与高效训练正则化两个维度展开研究,旨在解决加密流量分析模型在面对对抗样本逃逸攻击时表现出的鲁棒性缺失问题,以及由对抗训练带来的巨大计算资源开销问题。最终设计并实现一个兼具高鲁棒性与高训练效率的加密流量抗逃逸分析系统。具体来说,论文的研究内容包括以下三点:

(1) 针对加密流量分析模型易受逃逸攻击且传统对抗训练难以收敛的问题,设计了一种基于动态难度调度与二阶反应梯度优化的抗逃逸训练方法(DS-RGO),以提升模型的收敛稳定性和抗逃逸能力。

传统的基于纳什均衡的对抗训练在非凸优化曲面上容易陷入梯度震荡,导致模型无法收敛至最优防御状态。为此本文将攻防过程建模为非零和的 Stackelberg 博弈,防御者在优化参数时显式计算并利用攻击者的二阶反应梯度,从而预判攻击策略的变化,平滑优化轨迹。此外,引入了课程学习机制,设计动态的攻击难度调度策略。在训练初期通过限制攻击者的扰动半径和迭代步数进行热身,引导模型优先学习流量的基础语义特征;随着训练深入,逐步提升攻击强度,迫使模型在复杂的决策边界附近寻找平坦极小值。

本文在 Cross-Platform 2022(App60)公开基准数据集上对该方法进行了验证,并理论分析

证明了二阶反应梯度在优化过程中起到了雅可比正则化器的作用。实验结果表明，相比于基线方法，该方法不仅显著提升了模型在强对抗攻击下的鲁棒准确率，还有效解决了对抗训练过程中的过拟合与灾难性遗忘问题。

(2) 针对大规模加密流量场景下对抗训练计算成本高昂、资源消耗大的问题，提出了一种基于动态流过滤与自适应缓存复用的高效训练方法（DF-ACR），以实现训练效率与防御性能的帕累托最优。

鉴于加密流量数据呈现显著的长尾分布特性，且对抗扰动在参数更新过程中具有慢变性，全量实时计算对抗样本存在极大的算力冗余。本文从时空两个维度进行联合优化：在空间维度构建了基于损失值和梯度范数的多维重要性评估指标，设计了动态流样本过滤机制，精准剔除对鲁棒性贡献低的简单样本；在时间维度提出了自适应缓存复用策略，利用外部记忆库存储历史最优扰动，并通过懒惰更新机制复用历史梯度信息。针对序列模型，还专门设计了基于掩码的动态对齐算法，解决了变长序列与静态缓存的适配问题。

本文对该方法的复杂度进行了理论推导，并在单卡 GPU 环境下进行了广泛的对比实验。结果表明，该方法在保持抗逃逸性能无显著损耗的前提下，将训练速度提升了 4.6 倍，并大幅降低了显存峰值占用。该方法成功打破了对抗训练中高鲁棒性必高消耗的固有矛盾，为大规模加密流量分析模型的敏捷更新提供了工程可行的解决方案。

(3) 基于上述研究内容，本文设计并实现了加密流量抗逃逸分析和评估原型系统。

首先，本文分析了系统的功能性需求和非功能性需求，设计了系统的总体架构。其次采用模块化设计思想，将系统划分为数据预处理模块、高效对抗训练模块、流量分类检测模块和可视化分析模块。其中，高效对抗训练模块集成本文提出的 DS-RGO 和 DF-ACR 算法，作为系统的核心防御引擎；可视化模块提供对流量特征分布和攻击防御效果的直观展示。最后基于深度学习框架和高性能计算服务器对系统进行了部署与实现。

系统测试结果表明，该系统能够有效识别并防御各类基于梯度的流量逃逸攻击，同时支持在大规模流量数据上的快速模型迭代。DS-RGO 方法为系统提供了底层的安全保障，而 DF-ACR 方法则确保了系统在资源受限环境下的运行效率，两者协同工作，满足了网络空间安全中对于加密流量分析系统鲁棒性和高效性的双重需求。

1.4 论文组织结构

本文围绕加密流量分析场景下面临的对抗样本逃逸威胁与对抗训练计算开销巨大这一对主要矛盾，提出了融合博弈论与课程学习的抗逃逸防御方案，以及基于时空联合优化的训练加速方案。DS-RGO 方法为模型提供底层安全保障，DF-ACR 方法确保资源受限下的训练效率，两者协同工作构建了高效鲁棒的加密流量分析体系，逻辑关系如图 1-6 所示。全文共分为六章，具体结构安排如下：

第一章绪论。阐述加密流量分析及其对抗安全的研究背景与意义，系统综述了流量逃逸攻击、防御算法及深度学习高效训练领域的研究现状，分析现有技术面临的收敛难、开销大等挑战，明确了本文的研究内容与创新点，最后说明全文的章节架构与逻辑关系。

第二章相关技术研究。详细介绍了加密流量分类的主流模型，对抗攻击与防御理论，博弈论与课程学习和高效深度学习技术，为后续章节算法设计与优化奠定理论基础。

第三章基于动态难度调度与二阶反应梯度优化的抗逃逸训练方法。针对传统对抗训练在非凸优化曲面上存在的梯度震荡与收敛困难问题，提出 DS-RGO 方法。该方法将课程学习引入主从博弈框架，设计了动态的攻击难度调度机制，并通过展开优化计算二阶反应梯度，引导模型在平滑的损失曲面上收敛至稳健的 Stackelberg 均衡点。通过实验，验证了该方法在提升模型鲁棒准确率与收敛稳定性方面的优势。

第四章基于动态流过滤与自适应缓存复用的高效训练方法。针对大规模流量数据上对抗训练计算成本高昂的问题，提出 DF-ACR 方法。该方法在空间维度利用多维重要性指标精准剔除冗余样本，在时间维度利用慢变性假设复用历史扰动，并解决了变长序列的对齐难题。实验证明该方法在保持模型抗逃逸性能的前提下，显著提升了训练速度并降低了显存开销，实现了效率与鲁棒性的 Pareto 最优。

第五章加密流量分析集成平台与评估系统的设计与实现。从系统的功能性需求与非功能性需求出发，设计了分层架构与核心功能模块，包括数据预处理、高效对抗训练、流量分类检测以及可视化评估模块。基于高性能服务器完成系统的开发部署与功能测试，验证了本文所提方案在实际网络安全环境中的工程可行性。

第六章总结与展望。总结本文在加密流量抗逃逸防御与高效训练方面的研究成果，客观分析现有方案存在的局限性，并结合生成式 AI 等前沿技术，提出未来研究方向。




图 1-6 论文组织架构

第二章 相关技术研究

2.1 加密流量表征与分类模型基础

根据第一章 1.2.1 节的分析，鉴于图模态在单流载荷分析上的局限性，本节重点阐述序列模态与视觉模态这两种主流的特征机制及其对应的骨干网络架构，为后续构建抗逃逸与高效训练方法奠定基础。

2.1.1 流量数据的多模态表征机制

网络流量本质上是由海量数据包组成的连续二进制流。在原始流量数据包（Packet Capture, PCAP）文件中，数据包包含链路层、网络层、传输层头部以及应用层载荷。构建多模态表征旨在从不同视角挖掘流量的深层特征。

为了利用深度学习技术对加密流量进行端到端的自动化特征提取，首要挑战在于构建合理的数据表征。由于加密协议将应用层载荷混淆为高熵的随机序列，传统的特征提取方法难以奏效。PCAP 经过预处理分化为两种核心模态的过程如图 2-1 所示。




图 2-1 加密流量的多模态数据表征与预处理流程

如图 2-1 所示，本文的预处理流程并未采用单一视角的特征提取，而是构建了序列模态与视觉模态两条并行的表征路径，旨在从不同维度捕捉加密流量的深层规律。这两类模态的具体构建方法与物理含义阐述如下：

（1）序列模态表征

序列模态表征基于流量即语言的假设。网络通信协议具有严格的语法和语义规则，数据包之间的交互过程类似于自然语言中的对话，而数据包内部的字节序列则类似于句子中的单词。构建流程主要包括两个关键步骤：

流切分与重组：依据五元组信息将离散数据包聚类为会话流。为了统一输入维度，通常截取每条流的前 N 个字节或前 M 个数据包。Wang 等人^[53]率先提出了端到端框架，证明了序列特征在提取协议头部模式上的有效性。

分词与令牌化：这是衔接预训练语言模型的关键步骤。传统的序列方法使用原始字节值，而现代方法引入了自然语言处理中的字节对编码（Byte Pair Encoding, BPE）技术^[20]。BPE 将频繁出现的字节组合合并为一个 Token，有效降低了序列长度并提升了语义捕捉能力。

（2）视觉模态表征

视觉模态表征基于流量即图像的假设。不同应用或恶意软件在协议头部结构和包长分布上保留了特定的标识。主流构建方法是将一维字节流重塑为二维灰度矩阵。设流量样本 x 为一维字节向量，按照固定宽度 W 折叠为 $H \times W$ 的矩阵，并归一化至 $[0,1]$ 区间。其数学映射为：

$$I_{i,j} = \frac{x_{i \cdot W + j}}{255}, \quad 0 \leq i < H, 0 \leq j < W \quad (2.1)$$

Wang 等人^[16]和 Lotfollahi 等人^[19]的研究表明，这种映射能够保留流量的局部空间相关性，IP 头部和 TCP 头部的固定字段在矩阵中呈现为条纹结构，便于提取边缘和纹理特征。

2.1.2 基于序列模态的预训练语言模型

基于 Transformer 的预训练语言模型凭借其卓越的上下文建模能力，已成为当前加密流量分类任务的最先进（State of the arts, SOTA）基座模型。

（1）Transformer 与自注意力机制

Vaswani 等人^[54]提出的 Transformer 架构摒弃了循环结构，完全依赖自注意力机制捕捉序列中任意位置的依赖关系。在流量分析中，这允许模型直接建立相隔甚远的协议特征之间的关联。其核心计算公式为：

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2.2)$$

其中 Q, K, V 分别为查询、键和值矩阵。这种全局感知使得 Transformer 比传统模型更能理解复杂的加密协议交互逻辑。

（2）代表性架构

Devlin 等人^[55]提出的 BERT 模型通过引入预训练-微调范式，彻底改变了自然语言处理领域的格局。Lin 等人^[20]提出的 ET-BERT 模型成功将此范式迁移至加密流量分析领域，成为目前提取加密流量深层语义特征的最强骨干网络。针对流量字节流与自然语言在分布上的差异，ET-BERT 创新性地设计了两项核心预训练任务：掩码突发预测（Masked Burst Prediction, MBP）和同源流预测（Same-origin Flow Prediction, SOFP），以实现无标注流量数据的自监督学习。

MBP 是 ET-BERT 捕捉流量微观字节特征的核心机制。区别于 NLP 中随机掩盖单个单词的做法，MBP 考虑到流量数据的连续性，采取掩盖连续字节片段的策略。其具体运作流程如图 2-2 所示。




图 2-2 ET-BERT 模型的预训练掩码机制示意图

如图 2-2 所示，在预训练阶段，系统将原始流量 Token 序列中的部分连续片段随机替换为特殊的[MASK]标记。输入序列经过 Transformer 编码器的多头自注意力机制处理后，模型能够充分捕捉上下文 Token 之间的长距离依赖关系。最终，在输出层对应掩码位置处，模型通过全连接层预测被遮蔽的原始 Token 数值。这种训练过程使模型在不解密载荷的前提下，掌握了诸如 TLS 握手特征、报文长度分布等关键协议逻辑。

除了微观的字节特征，ET-BERT 还通过 SOFP 任务学习宏观的会话结构。该任务训练模型判断两个输入的数据包序列是否属于同一个会话流，从而增强了模型对流级别上下文连贯性的理解。

鉴于 ET-BERT 在提取加密流量深层语义特征方面的卓越表现，它是当前序列模态分析任务中事实上的基准模型，也为后续章节研究对抗防御和高效训练提供了理想的实验对象。

2.1.3 基于视觉模态的卷积神经网络

尽管以 ET-BERT 为代表的 Transformer 架构在捕捉长距离语义依赖方面表现优异，但卷积神经网络（Convolutional Neural Networks, CNN）凭借其局部连接和权值共享特性，在处理具有空间结构特征的视觉模态流量数据时，依然具备不可替代的优势。

（1）基于空间局部性的特征提取机制

在加密流量中，尽管载荷高熵，但协议头部往往出现在相对固定的位置。CNN 通过卷积核在输入矩阵上滑动运算，能够有效提取这些底层特征模式。对于输入流量矩阵 X ，卷积层第 k 个特征图的计算过程可形式化描述为：

$$Y_{i,j}^k = \sigma \left(\sum_m \sum_n w_{m,n}^k \cdot X_{i+m,j+n} + b^k \right) \quad (2.3)$$

其中， (i,j) 表示像素坐标， w^k 为第 k 个卷积核的权重矩阵， b^k 为偏置项， $\sigma(\cdot)$ 为非线性激活函数。通过堆叠多层卷积与池化操作，网络能够将底层的字节分布特征逐层抽象为高层的协议语义表征，从而实现对加密应用类型的准确判别。

（2）代表性架构

DeepPacket 框架^[19]是该方向的经典基准，它利用 2D-CNN 提取类似于图像纹理的流量特征。本文选用的 BUPT-CNN 即属于此类架构。基于视觉模态的 CNN 架构通常包含数据预处理、层次化特征提取以及语义聚合等多个阶段。在数据预处理阶段，原始高熵流量数据首先被映射为二维视觉矩阵，使得协议头等结构性信息能够在空间上显式呈现。随后，在层次化特征提取阶段，卷积层通过局部连接与权值共享机制提取低层字节特征，并结合最大池化操作逐步压缩特征图尺寸、增强特征的平移不变性随着网络层数加深，模型能够将低层特征进一步抽象为中层结构特征，最终形成对协议行为具有判别能力的高层语义表示。这种由浅入深的特征学习过程，使得 CNN 能够有效建模加密流量中的隐含结构信息。

相比于 Transformer，CNN 的参数量较小，推理速度快，更适合资源受限的边缘部署；但在处理长序列依赖和深层语义理解方面，其能力略逊于预训练模型。这两种模型在结构与机理上的显著异构性，使其成为验证本文所提防御算法泛化能力的理想对象。

BUPT-CNN 凭借其轻量化与结构紧凑的特点，在工业边缘场景下应用广泛。作为视觉模态的典型代表，其与 Transformer 架构显著的异构性，使其成为验证防御算法泛化性能的重要

基准。

2.2 对抗攻击与防御理论基础

深度学习加密流量模型极易遭受逃逸攻击，而传统对抗训练面临着梯度震荡与计算开销巨大的双重瓶颈。本节将梳理攻防理论并剖析其局限，为后续提出高效的博弈防御机制奠定基础。

2.2.1 对抗样本的定义与生成算法

(1) 数学定义与优化目标

对抗样本是指在原始良性样本 x 的基础上叠加了精心设计的扰动 δ 后生成的样本 x_{adv} 。从数学角度看，对于给定的分类器 $f_\theta(\cdot)$ 和真实标签 y ，对抗攻击旨在寻找满足以下约束的最优扰动 δ ：

$$\text{maximize } J(f_\theta(x + \delta), y) \quad \text{s.t. } \|\delta\|_p \leq \epsilon \quad (2.4)$$

其中， $J(\cdot)$ 为损失函数， $\|\cdot\|_p$ 为 L_p 范数， ϵ 为扰动预算。约束条件 $\|\delta\|_p \leq \epsilon$ 确保了扰动足够微小，使得对抗样本在统计特征或感官上与原始样本保持一致，从而具备隐蔽性。

(2) 几何定义

从几何空间的角度来看，深度学习模型的分类过程可以视作在高维特征空间中划定决策边界的过程。攻击者的目标，即是寻找一个梯度方向，使得样本点跨越当前的决策边界进入错误类别的区域。对抗攻击在特征空间中的几何诱导过程如图 2-3 所示。




图 2-3 对抗攻击下的决策边界偏移示意图

如图 2-3 所示，原始样本 x 位于模型划分的良性区域内。攻击者在满足扰动约束 ϵ 的范围内，通过计算梯度方向寻找到最优扰动向量 δ 。该向量将样本从良性区域推向决策边界的另一侧，生成的对抗样本 x_{adv} 虽然在视觉或统计特征上与原始样本极为接近，但在模型的逻辑判断中已掉入恶性区域，导致模型误判。

这种现象在加密流量场景下表现为逃逸攻击。由于加密流量分类器的决策边界往往具有极高的非线性，微小的字节级扰动即可触发此类逃逸。这一脆弱性揭示了构建鲁棒防御体系的紧迫性。在本文第三章中，将通过博弈对抗的方式重新优化决策边界，使其对图 2-3 所示的这类扰动向量具有更强的鲁棒性。

(3) 主流生成算法

为了求解上述优化问题，学术界提出了一系列基于梯度的攻击算法：

1.快速梯度符号法（Fast Gradient Sign Method, FGSM）

Goodfellow 等人^[56]提出的 FGSM 是最早期的单步攻击算法。基于深度神经网络的线性假设，FGSM 仅需计算一次反向传播，沿着损失函数的梯度方向施加固定步长的扰动：

$$x_{adv} = x + \epsilon \cdot \text{sign}(\nabla_x J(\theta, x, y)) \quad (2.5)$$

FGSM 计算效率极高，常用于生成基准对抗样本，但由于其仅进行了单步线性近似，在面对具有复杂非凸曲面的模型时，攻击成功率较低。

2.投影梯度下降法（Projected Gradient Descent, PGD）

为了克服单步攻击的局限性，Madry 等^[32]人将攻击建模为约束优化问题，并提出了 PGD 算法。PGD 本质上是 FGSM 的多步迭代版本，被公认为是当前一阶攻击算法中的最强攻击。其迭代更新公式为：

$$x^{t+1} = \Pi_{x+S} \left(x^t + \alpha \cdot \text{sign}(\nabla_x J(\theta, x^t, y)) \right) \quad (2.6)$$

其中， t 为迭代轮次， α 为单步步长， Π_{x+S} 表示投影算子，用于将更新后的样本投影回以 x 为中心、 ϵ 为半径的允许邻域 S 内。PGD 能够更充分地探索损失曲面的局部极值点，生成的对抗样本具有极强的破坏力，因此常被用作评估模型鲁棒性的标准基准。

3.C&W 攻击

Carlini 和 Wagner^[57]提出了一种基于优化的攻击方法。不同于 FGSM/PGD 直接最大化损失，C&W 引入了特定的目标函数 $f(x')$ 并通过拉格朗日乘法处理约束，旨在最小化扰动距离的同时最大化误分类概率。尽管其计算开销巨大，但能生成更高质量的对抗样本，常用于打破防御机制的梯度掩蔽假象。

2.2.2 流量场景下的逃逸攻击特殊性

与计算机视觉领域中直接对像素点进行连续型数值修改不同，加密流量在面对对抗攻击时具有严格的物理与协议限制。为了保证网络连接的有效性与上下文的语义一致性，攻击者往往只能在特定的时间或空间维度施加离散的扰动。在流量逃逸攻击场景中，攻击者主要通过空间维度的载荷填充、包长伪装，以及时间维度的发包延迟注入、时序重排等方式来构建对抗样本。这种时空扰动不仅高度离散，且极易破坏原始协议的握手状态。因此，流量领域的对抗样本通常被称为逃逸攻击，其扰动 δ 映射为具体的流量混淆策略，主要为以下两种：

载荷填充：对应于特征空间中的数值增加。攻击者在数据包末尾或特定的 **Padding** 字段添加无意义的随机字节，改变数据包长度分布和字节频率特征，从而欺骗基于统计特征的模型。

时序干扰：对应于特征位置的偏移。攻击者通过在数据包之间插入延迟，改变包到达间隔序列，以规避基于时序特征的检测。

Rosenberg 等人^[58]的研究表明，即使在黑盒条件下，攻击者也可以通过查询模型的置信度反馈，利用遗传算法或强化学习生成功能正常的恶意流量变种，这对传统的入侵检测系统构成了严峻威胁。

2.2.3 传统对抗训练框架及其局限性

为了防御对抗攻击，对抗训练（Adversarial Training, AT）被认为是目前最有效的方法。其核心思想是将对抗样本纳入训练过程，通过不断修复模型在决策边界附近的盲区来增强防御能力。

（1）Min-Max 博弈框架

Madry 等^[32]人将对抗训练形式化为经典的 Min-Max 鞍点优化问题：

$$\min_{\theta} E_{(x,y) \sim D} \left[\max_{\|\delta\|_p \leq \epsilon} J(f_{\theta}(x + \delta), y) \right] \quad (2.7)$$

该公式包含两个相互对抗的过程：

内部最大化：模拟攻击者，寻找能够最大化模型损失的最强扰动。

外部最小化：模拟防御者，利用找到的对抗样本更新模型参数 θ ，以最小化最坏情况下的损失。

（2）现有方法的局限性

尽管基于 Min-Max 的 PGD-AT 及其变体在一定程度上提升了鲁棒性，但在应用于大规模加密流量模型时面临三大瓶颈：

收敛困难与梯度震荡：内部最大化问题是非凸的。在训练初期，模型参数尚未稳定，强行寻找最强攻击往往会导致生成的对抗样本质量波动剧烈，进而导致外部参数更新方向震荡，模型难以收敛至纳什均衡点。

鲁棒性与准确性的失衡：Zhang 等人^[59]从理论上证明了鲁棒性与自然准确率之间存在内生矛盾。过度关注极端对抗样本往往会破坏模型对正常样本的特征提取能力，导致正常流量分类精度显著下降。

巨大的计算开销：标准 PGD-AT 需要进行 K 次反向传播来生成一个对抗样本。这意味着训练耗时是普通训练的 $K+1$ 倍。对于参数量过亿的预训练模型，这种计算成本过大。

上述局限性表明，传统的 Min-Max 框架已难以满足大规模加密流量分析任务在收敛性与效率上的双重需求。这也迫切要求引入新的博弈机制与高效训练策略，来打破上述瓶颈。

2.3 博弈论与课程学习基础

机器学习的攻防对抗天然契合博弈论建模。本节将阐述从传统的 Nash 均衡向 Stackelberg 均衡演进的理论逻辑，并引入双层优化与课程学习理论，为后文的防御框架奠定数学基础。

2.3.1 Nash 均衡与 Stackelberg 均衡

在对抗性机器学习的研究中，模型所有者（防御者）与恶意扰动生成者（攻击者）之间的互动天然符合博弈论的建模范畴。根据决策时序的不同，现有的对抗博弈主要分为 Nash 均衡与 Stackelberg 均衡两类模型。

（1）Nash 均衡及其局限性

经典的对抗训练框架通常将问题建模为零和博弈，旨在寻找一个 Nash 均衡点 (θ^*, δ^*) ，其数学目标为同时最小化和最大化损失函数：

$$\min_{\theta} \max_{\delta} L(\theta, \delta) \quad (2.8)$$

在此状态下，假设防御者 θ 和攻击者 δ 同时行动，任何一方都无法通过单方面改变策略来

获得更多收益。然而，这种同时决策的假设往往忽略了参数更新过程中的动态耦合性。在实际安全对抗中，防御者更新参数 θ 会直接改变攻击者的最优策略空间。忽略这一交互项，容易导致优化陷入局部次优解，且在非凸优化面上极易引发梯度震荡。

（2）Stackelberg 均衡与主从博弈

为了更准确地描述网络防御场景中防御者先行部署模型，攻击者随后发起逃逸的非对称关系，Stackelberg 主从博弈模型提供了更严谨的视角。在该框架下，博弈双方被定义为：

领导者（Leader）：拥有先手优势。其目标是在预见到跟随者会做出最优反应的前提下，优化自身的防御策略。

跟随者（Follower）：处于后手地位。在观测到领导者的策略 θ 后，做出最大化自身攻击收益的最优响应 $\delta^*(\theta)$ 。

Stackelberg 均衡的优化目标是一个嵌套的双层问题：

$$\min_{\theta} L(\theta, \delta^*(\theta)) \quad \text{s.t.} \quad \delta^*(\theta) = \arg \max_{\delta' \in \mathcal{S}} L(\theta, \delta') \quad (2.9)$$

现有研究^[60]表明，Stackelberg 均衡在泛化性能和收敛稳定性上通常优于 Nash 均衡，因为它允许防御者利用反应函数 $\delta^*(\theta)$ 来主动引导优化轨迹，使模型参数收敛至对攻击扰动更不敏感的平坦极小值区域。

（3）决策逻辑对比

为了直观展示两种博弈模型在决策机制上的本质差异，本文绘制了如图 2-4 所示的逻辑对比图。




图 2-4 纳什均衡与 Stackelberg 博弈的决策逻辑对比

如图 2-4 左侧所示，纳什均衡模型下，攻防双方在信息隔离下同时决策，防御者难以预判攻击变化。相比之下，Stackelberg 模型构建了清晰的时序结构，防御者显式地计算并利用了攻击者的最优反应 $\delta^*(\theta)$ 。这种基于双层优化的前瞻性机制，正是本文第三章 DS-RGO 方法构建抗逃逸防御体系的核心理论依据。

2.3.2 双层优化与梯度估计

Stackelberg 博弈在数学形式上属于典型的双层优化问题。其特点在于约束条件本身是一个嵌套的优化问题，通用形式如下：

$$\begin{aligned} \min_{\theta} L_{upper}(\theta, \delta^*(\theta)) \\ \text{s.t. } \delta^*(\theta) = \arg \max_{\delta} L_{lower}(\theta, \delta) \end{aligned} \quad (2.10)$$

其中，上层问题优化模型参数 θ ，下层问题优化对抗扰动 δ 。求解该问题的核心难点在于计算上层目标对 θ 的全导数。根据链式法则，该梯度包含两部分：

$$\frac{dL}{d\theta} = \frac{\partial L}{\partial \theta} + \frac{\partial L}{\partial \delta} \cdot \frac{\partial \delta^*(\theta)}{\partial \theta} \quad (2.11)$$

第一项 $\frac{\partial L}{\partial \theta}$ 为直接梯度，仅反映参数对损失的静态影响。

第二项包含的 $\frac{\partial \delta^*(\theta)}{\partial \theta}$ 为隐函数梯度，它刻画了攻击策略对防御参数变化的敏感度。

由于深度神经网络中 $\delta^*(\theta)$ 通常没有显式解析解，直接计算该项涉及高昂的 Hessian 矩阵求逆运算。为此，Roth^[60]等人提出了展开优化技术，将下层攻击者的 K 步迭代优化过程视为计算图的一部分，通过自动微分框架进行反向传播。进一步的研究利用 Hessian 向量积（Hessian-Vector Product, HVP）近似计算，成功将计算复杂度从 $O(d^2)$ 降低至 $O(d)$ 。这种高效的梯度估计技术使得在大规模加密流量分析模型上求解 Stackelberg 博弈成为可能，也是本文第三章算法实现的关键支撑。

2.3.3 课程对抗训练

尽管 Stackelberg 博弈提供了更好的理论收敛点，但在高维非凸优化面上，直接引入强对抗约束容易导致优化发散或灾难性遗忘。传统的对抗训练框架通常在训练初期便向模型注入高强度的对抗样本，这种一步到位的强对抗扰动会破坏模型对基础协议特征的特征空间映射，导致损失函数曲面变得崎岖，引发严重的梯度震荡乃至无法收敛。Bengio 等人^[61]提出的课程学习（Curriculum Learning, CL）理论指出，通过构建由易到难的任务序列，可以有效平滑非凸优化曲面，加速模型收敛。传统对抗训练与基于课程学习的对抗训练范式对比如图 2-5 所示。




图 2-5 传统对抗训练与课程对抗训练的收敛机制对比

如图 2-5 所示，将课程学习机制引入对抗训练后，防御策略的演进呈现出清晰的阶梯式特征。模型先学习未受扰动的弱对抗样本以建立稳固的决策边界，随后系统自适应提升攻击难度。这种由易到难的动态博弈过程，有效平滑了非凸优化曲面。

在对抗防御领域, Cai 等人^[62]验证了课程机制的有效性, 提出了课程对抗训练 (Curriculum Adversarial Training, CAT)。其核心思想是动态调度攻击者的强度:

训练初期, 限制扰动预算 ϵ 或减少攻击迭代步数 K , 防止模型在尚未学习到数据分布特征时被强攻击打破, 从而避免梯度消失问题^[63]。

训练后期, 随着模型鲁棒性的提升, 逐步增加攻击强度以逼近最坏情况风险。

相关理论分析表明, 课程机制能够作为一种有效的动态正则化手段, 引导模型沿着更加平稳的路径逼近 Stackelberg 均衡点。这为本文解决 ET-BERT 等大模型在对抗训练初期的不收敛问题提供了重要的理论指导。

2.4 高效深度学习训练技术

随着加密流量表征模型参数规模的急剧膨胀, 计算资源的瓶颈在对抗训练阶段被进一步放大。标准的对抗训练本质上是一个极度耗时的双层优化过程, 尤其是执行多步迭代攻击时, 模型需要保留庞大的前向传播计算图以执行多次高维张量的反向梯度计算。大规模模型在执行多步对抗训练时的显存溢出机制如图 2-6 所示。




图 2-6 大规模模型多步对抗训练显存溢出机制

如图 2-6 所示, 对于动辄数亿参数的预训练模型而言, 多步梯度累加与高频的上下文缓存切换, 会导致显存占用呈指数级飙升, 极易在资源受限的边缘设备上引发崩溃。为打破鲁棒性与高开销的矛盾, 本节将重点探讨基于数据重要性的核心集选择与对抗梯度复用两类高效训练理论, 为后文提出高效的训练方法奠定基础。

2.4.2 基于数据重要性的核心集选择

在大规模数据集中, 样本包含的信息量存在显著冗余。Toneva 等人^[64]的研究发现, 深度学习模型在训练过程中存在明显的遗忘: 大量的容易样本在早期的训练阶段即可被模型正确分类且不再遗忘, 而真正决定决策边界位置的往往是少量的难样本或边缘样本。

基于此发现, 学术界发展出了核心集选择理论。其核心目标是寻找原始数据集 D 的一个加权子集 S , 使其在梯度空间或几何分布上能够最大程度地逼近全量数据, 从而在减少训练样本数量的同时保持模型性能。基于该理论的数据筛选原理如图 2-7 所示:




图 2-7 基于核心集的数据筛选原理

如图 2-7 所示，原始数据集 D 通常呈现高密度的冗余分布，大量特征模式重复的样本（灰色点）聚集在分布中心。如果使用全量数据训练，计算资源将大量浪费在这些对优化贡献极小的样本上。经过重要性指标 $S(x)$ 过滤后，算法筛选出位于分布边缘的关键样本（红色点）。这些样本在几何上构成了数据分布的支撑向量。尽管核心集 S 极为稀疏，但其依然完整保留了原始数据的拓扑结构与决策边界信息。

这一理论为解决大规模加密流量对抗训练的效率瓶颈提供了重要启示。根据筛选时机的不同，现有方法主要分为静态剪枝与动态筛选两类。

（1）静态剪枝

早期的核心集选择主要关注几何特征。Mirzasoleiman 等人^[65]提出了 CRAIG 方法，试图在梯度空间中寻找一个加权子集 S ，使其能够逼近全数据集 D 的梯度总和。其数学目标表述为最小化梯度误差的上界：

$$\min_{S \subset D, |S|=k} \sum_{i \in D} \min_{j \in S} \|\nabla_{\theta} L(x_i) - \nabla_{\theta} L(x_j)\| \quad (2.12)$$

这种方法通常在训练前进行一次性筛选，虽然计算量较小，但难以适应训练过程中模型决策边界的动态变化，且对于非凸优化问题往往只能提供模糊的误差边界。

（2）动态筛选

为了适应训练动态，动态筛选策略在每个 Epoch 实时评估样本的重要性。Katharopoulos 等人^[66]提出了基于梯度范数的重要性采样，指出梯度范数 $\|\nabla_{\theta} L_i\|$ 较大的样本对参数更新的贡献更显著，应当赋予更高的采样概率 $P(i)$ 。为了保证梯度的无偏估计，通常需要对损失函数进行反向加权：

$$L_{\text{weighted}} = \frac{1}{|B|} \sum_{x_i \in B} \frac{1}{|D| P(i)} L(x_i, y_i) \quad (2.13)$$

在对抗训练场景下，样本的重要性评估更为复杂。Paul 等人^[67]的数据瘦身理论证明，在训练后期仅保留位于决策边界附近的难样本，不仅能加速收敛，还能在一定程度上最大化模型的泛化边界。这种基于重要性动态筛选的思路，正是本文第四章构建 DF-ACR 训练方法的理论基础。

2.4.3 对抗训练加速与梯度复用

除了在数据层面做减法，另一条提升效率的技术路线是在算法层面优化反向传播的次数。由于对抗训练的计算瓶颈主要在于生成对抗样本时需要进行 K 次梯度回传，研究者提出了一系列利用历史信息复用或层级结构解耦的加速方法。

(1) Free 对抗训练

Shafahi 等人^[68]提出了 Free-AT (Free Adversarial Training) 策略，旨在打破 PGD-AT 的计算壁垒。该方法利用了对抗扰动的慢变性，即在连续的训练微步中，同一个样本的最优扰动 δ^* 是高度自相关的。Free-AT 通过在更新模型参数 θ 的同时复用上一次迭代生成的扰动梯度，实现了无计算消耗的对抗训练：

$$\begin{aligned}\theta_{t+1} &\leftarrow \theta_t - \eta \nabla_{\theta} L(x + \delta_t) \\ \delta_{t+1} &\leftarrow \delta_t + \epsilon \cdot \text{sign}(\nabla_x L(x + \delta_t))\end{aligned}\quad (2.14)$$

这种梯度重放机制本质上是將生成对抗样本的开销分摊到了参数更新的每一步中，实现了与普通训练相当的时间复杂度。这种利用历史扰动信息的思想，为本文第四章设计对抗扰动缓存策略提供了思路。

(2) YOPO (You Only Propagate Once)

针对深层神经网络，Zhang 等人^[69]提出了 YOPO 算法。该方法观察到，对抗扰动主要影响模型的第一层，而深层的权重变化相对平缓。YOPO 利用庞特里亚金最大值原理 (Pontryagin's Maximum Principle, PMP) 将对抗梯度的计算限制在网络的第一层，仅对第一层进行 K 次 PGD 攻击，而对后续深层网络仅进行一次反向传播。其核心思想是解耦扰动生成与参数更新的计算图：

$$\nabla_{\delta} L \approx \nabla_{\delta} L(\theta, x + \delta) \big|_{\text{frozen deep layers}} \quad (2.15)$$

YOPO 显著减少了对抗训练中的梯度计算量，特别是对于 ET-BERT 这类超深层模型，这种利用层级结构进行计算解耦的思想具有极高的参考价值。

3. 单步快速对抗训练 (Fast-AT)

Wong 等人^[70]重新研究了单步 FGSM 攻击，发现只要结合适当的随机初始化，单步攻击也能训练出具有竞争力的鲁棒模型，即 Fast-AT。这推翻了以往认为必须使用多步 PGD 才能获得鲁棒性的观点。这一结论证明了在对抗训练中只要能找到梯度的主要方向，并不一定需要进行完整的 PGD 迭代。这为本文第四章中基于缓存的近似梯度计算提供了理论上的收敛性保证。

2.5 本章小结

本章围绕加密流量分类、对抗攻防理论及高效训练技术展开研究。首先，深入探讨了加密流量的多模态表征机制，重点阐述了以 ET-BERT 为代表的序列预训练模型和以 BUPT-CNN 为代表的视觉卷积模型，确立了本文后续实验的骨干网络。其次，系统阐述了对抗攻击的生成机理与防御理论，分析了传统 Min-Max 对抗框架的局限性，并引入 Stackelberg 博弈与课程学习理论，为解决非凸优化环境下的收敛难题提供思路。最后，针对大规模数据训练效率低下的问题，研究了核心集选择与梯度复用技术，揭示了利用数据时空冗余特性实现训练加速

的可行性。本章通过理论分析与技术原理解构，为后续提出的 DS-RGO 博弈防御方法和 DF-ACR 高效训练框架奠定了坚实的理论基础。

第三章 基于动态难度调度与二阶反应梯度优化的抗逃逸训练方法

3.1 引言

随着 TLS 1.3 与 QUIC 协议的普及，深度学习已成为加密流量分析的核心手段。然而，模型决策边界的非线性使其极易遭受 Obfsproxy 等工具诱导的逃逸攻击。现有基于 Min-Max 博弈的对抗训练在应用于 ET-BERT 等大模型时，面临梯度震荡、难以收敛及自然准确率大幅下降等瓶颈。

为此，本章提出基于动态难度调度与二阶反应梯度优化的抗逃逸训练方法（Dynamic Difficulty Scheduling and Reaction Gradient Optimization, DS-RGO）。该方法通过 Stackelberg 主从博弈建模攻防演化，利用二阶反应梯度捕捉复杂的攻防交互，并引入由弱至强的动态难度调度机制平滑非凸优化曲面。实验表明，DS-RGO 在保证快速收敛的同时，显著提升了模型在抗逃逸攻击时的鲁棒性。

此外，为了验证 DS-RGO 算法的通用性，本章分别在基于 Transformer 架构的序列模态与基于 CNN 的视觉模态模型上进行了联合验证，确保了博弈优化机制在不同特征表征下的鲁棒性增益。

3.2 问题定义与威胁模型

在介绍 DS-RGO 的具体实现之前，本节首先对加密流量分类任务、流量逃逸攻击的威胁模型以及 Stackelberg 博弈的映射关系进行形式化定义。

3.2.1 加密流量分类任务的数学描述

设加密流量数据集为 $D=(x_i, y_i)_{i=1}^N$ ，其中 $x_i \in X$ 表示输入的流量样本， $y_i \in Y=1, 2, \dots, C$ 表示流量对应的真实类别标签， N 为样本总数。

针对本文研究的两种异构深度学习模型，输入空间 X 的数学定义如下：

（1）针对 ET-BERT 模型（序列模态）：

ET-BERT 将流量视为自然语言序列。首先利用 Datagram2 Token 工具将原始 PCAP 数据包载荷转换为 Token 索引序列。设序列最大长度为 L ，词表大小为 V ，则输入 $x \in 0, 1, \dots, V-1^L$ 。在模型内部，输入 x 首先经过嵌入层映射为连续的向量矩阵 $e \in \mathbb{R}^{L \times d}$ ，其中 d 为嵌入维度。分类器 f_θ 旨在学习映射关系 $f_\theta: \mathbb{R}^{L \times d} \rightarrow \mathbb{R}^C$ ，以最小化预测分布与真实标签之间的交叉熵损失。

（2）针对 CNN 模型（视觉模态）：

该模型将流量视为灰度图像。将连续的数据包字节流截断并重组为矩阵形式，并归一化至 $[0, 1]$ 区间。设图像的高度为 H ，宽度为 W ，则输入 $x \in [0, 1]^{H \times W}$ 。分类器 g_ϕ 旨在学习映射关系 $g_\phi: \mathbb{R}^{H \times W} \rightarrow \mathbb{R}^C$ 。

3.2.2 流量逃逸攻击的威胁建模

在网络安全对抗场景中，流量逃逸攻击是指攻击者通过对原始恶意流量 x 施加微小的扰动 δ ，生成对抗样本 $x_{adv}=x+\delta$ ，使得分类器产生误判，即 $f_\theta(x_{adv}) \neq y$ ，同时保持流量原有的恶意功能和协议合规性。

我们将攻击者的目标建模为有约束的优化问题。对于给定的样本 (x, y) 和固定的模型参数 θ ，攻击者寻找最优扰动 δ^* 以最大化分类损失函数 L ：

$$\delta^* = \arg \max_{\delta \in S} L(f_\theta(x + \delta), y) \quad (3.1)$$

其中， S 为允许的扰动空间，用于约束攻击者的能力边界。通常使用 l_p 范数来定义：

$$S = \{\delta \in R^{\dim} \mid \|\delta\|_p \leq \epsilon\} \quad (3.2)$$

对于 ET-BERT， δ 对应于 Embedding 空间中的向量噪声，模拟攻击者通过同义词替换或流量填充引起的语义偏移。

对于 CNN， δ 对应于图像像素值的微小变化，模拟攻击者对数据包载荷字节值的直接修改。

3.2.3 Stackelberg 博弈在流量攻防中的映射关系

传统的对抗训练通常基于纳什均衡假设，即攻防双方同时行动。然而，在实际的抗逃逸防御中，防御者通常具有先发优势——防御者先部署模型，攻击者再根据模型特性设计逃逸样本。

因此，本文将加密流量的攻防过程建模为 Stackelberg 博弈：

领导者（Leader）：流量分类器（防御者）。其策略是模型参数 θ ，目标是最小化在攻击者做出最优反应后的分类风险。

跟随者（Follower）：流量伪装器（攻击者）。其策略是扰动 δ ，目标是在观测到 θ 后，最大化分类器的预测误差。

这种博弈关系构成了一个典型的双层优化问题：

$$\begin{aligned} \text{Outer Level (Leader): } \min_{\theta} F(\theta) &= E_{(x, y) \sim D} [L(f_\theta(x + \delta^*(\theta)), y)] \\ \text{Inner Level (Follower): s.t. } \delta^*(\theta) &= \arg \max_{\delta \in S} L(f_\theta(x + \delta), y) \end{aligned} \quad (3.3)$$

在此框架下，最优扰动 $\delta^*(\theta)$ 不再被视为一个独立的常数，而是模型参数 θ 的隐函数。防御者在更新 θ 时，必须考虑其对攻击者策略 $\delta^*(\theta)$ 的诱导效应，这正是 Stackelberg 博弈优于传统 Min-Max 对抗训练的核心所在。

3.3 DS-RGO 方法框架设计

本节提出一种基于动态难度调度与二阶反应梯度优化的抗逃逸训练方法 DS-RGO。下文将依次从总体结构、动态难度调度 DS 模块，以及二阶反应梯度优化 RGO 模块三个维度展开详细论述。

3.3.1 总体结构

针对加密流量分类模型在强对抗环境下存在的收敛困难与鲁棒性缺失问题，本章提出了一种基于动态难度调度与二阶反应梯度优化的抗逃逸训练方法 DS-RGO。该方法将深度学习中的课程学习机制引入主从博弈模型，通过动态调度攻击者的扰动能力，引导模型从易到难逐步掌握深层抗逃逸特征。DS-RGO 方法的整体运作流程如图 3-1 所示。




图 3-1 DS-RGO 方法整体框架图

如图 3-1 所示，为了解决强对抗环境下的训练收敛难题，该框架构建了一个双模态协同的闭环优化系统，主要包含以下两个核心功能模块：

模块一：课程难度调度循环。该模块对应图中的外层循环，充当系统的控制中枢。它根据当前训练进程，动态计算扰动半径 $\epsilon(t)$ 与攻击步数 $K(t)$ ，为博弈过程设定由弱至强的平滑约束边界，防止训练初期的梯度震荡。

模块二：Stackelberg 博弈循环。该模块对应图中的内层循环，是系统的计算引擎。在课程调度器设定的约束下，防御者与攻击者执行双层博弈交互。防御者利用展开优化技术计算包含二阶信息的全导数，驱动模型参数 θ 逐步收敛至稳健的 Stackelberg 均衡点。

下文将分别阐述这两个模块的核心原理与实现策略。

3.3.2 基于课程学习的动态难度调度

本节阐述 DS-RGO 方法中的 DS 控制模块，即系统的动态控制策略。

在加密流量分析任务中，ET-BERT 和 CNN 等深度模型通常面临高度非凸的损失曲面。若在训练初期直接引入最大强度的攻击，跟随者往往能轻易找到导致模型损失极大的扰动，从而引发严重的梯度震荡甚至模型崩溃。

为了解决这一问题，本节设计了多维度的动态攻击调度器，从扰动半径、攻击迭代步数和攻击步长三个维度控制，实现从弱对抗到强对抗的平滑过渡。

(1) 扰动半径的线性增长策略

扰动半径 ϵ 决定了攻击者在特征空间中允许偏离原始样本的最大距离。我们将训练过程划

分为热身阶段和强化阶段。

定义随训练轮次 t 变化的动态半径 $\epsilon(t)$ 如下：

$$\epsilon(t) = \begin{cases} \epsilon_{\max} \cdot \frac{t}{T_{\text{warm}}} & \text{if } 1 \leq t < T_{\text{warm}} \\ \epsilon_{\max} & \text{if } T_{\text{warm}} \leq t \leq T_{\text{total}} \end{cases} \quad (3.4)$$

其中， T_{warm} 为设定的热身总轮数， $\epsilon_{\max}$ 为预设的最大允许扰动预算。

在 $t < T_{\text{warm}}$ 阶段： $\epsilon(t)$ 较小，此时对抗样本近似于良性样本。模型主要致力于学习流量的显性特征，快速建立基本的分类能力，确保干净数据准确率。

在 $t \geq T_{\text{warm}}$ 阶段： $\epsilon(t)$ 达到最大值。此时模型已具备基本判别力，攻击者转为模拟高强度的流量伪装，迫使模型放弃脆弱的浅层特征，转而学习深层抗干扰特征，从而获得抗逃逸能力。

(2) 攻击迭代步数的阶梯式调整

除了扰动大小，攻击者寻找最优解的计算能力也是影响训练稳定性的关键因素。在 Stackelberg 博弈中，过大的 K 值意味着跟随者能够更精准地找到防御者的漏洞，导致 Leader 的梯度估计方差增大。

我们设计了随 $\epsilon(t)$ 联动的步数调度函数 $K(t)$ ：

$$K(t) = \begin{cases} 1 & \text{if } t < \frac{1}{3}T_{\text{warm}} \\ \lfloor \frac{K_{\max}}{2} \rfloor & \text{if } \frac{1}{3}T_{\text{warm}} \leq t < T_{\text{warm}} \\ K_{\max} & \text{if } t \geq T_{\text{warm}} \end{cases} \quad (3.5)$$

在初期 $K=1$ ：此时攻击等价于 FGSM。这相当于一种粗糙的正则化，计算开销极低，允许防御者快速更新参数，避免因过度拟合强攻击而导致无法收敛。

在后期 $K=K_{\max}$ ：攻击者进行多步精细攻击。此时防御者利用展开优化计算出的 Stackelberg 梯度包含更准确的二阶信息，引导模型收敛至稳健的 Stackelberg 均衡点。

结合上述公式，本文构建了多维度的攻击调度器。为了直观展示攻击者能力随训练进程的演变规律，图 3-2 描绘了扰动半径 $\epsilon(t)$ 与攻击步数 $K(t)$ 在整个训练周期内的动态变化趋势。




图 3-2 动态攻击难度调度策略曲线图

由图 3-2 可见，训练过程被清晰地划分为两个阶段：在热身阶段，扰动半径线性增加，而攻击步数维持在低位。这种弱对抗策略有效地平滑了优化初期的损失曲面，引导模型优先学习加密流量的协议指纹等显性特征。随后进入强化阶段，攻击强度达到峰值，迫使模型在复杂的决策边界附近寻找平坦极小值，从而获得对抗大范围流量伪装的深层鲁棒性。

(3) 攻击步长的自适应缩放

为了适配动态变化的 $\epsilon(t)$ ，攻击的单步更新步长 α 也需要进行自适应缩放，以保证攻击者在 $K(t)$ 步内能够充分探索扰动空间 S_t ：

$$\alpha(t) = \eta \cdot \frac{\epsilon(t)}{K(t)} \quad (3.6)$$

其中 η 为超参数，确保攻击行为能够覆盖边界。

通过上述联合调度机制，DS-RGO 将原本非凸优化问题转化为一系列难度递增的子问题序列，有效平滑了损失曲面，解决了 ET-BERT 等大模型在对抗训练中易出现的梯度爆炸问题。

(4) 非凸优化曲面的平滑机制

在训练初期，通过限制 $\epsilon(t) \approx 0$ ，优化问题的可行域极小，DS-RGO 退化为标准训练。这使得模型能够在平滑的损失曲面上快速找到一个较好的初始解。随着 $\epsilon(t)$ 和 $K(t)$ 的逐步增大，优化曲面的复杂度逐渐提升，模型被迫在已有的知识基础上，逐步适应更严苛的约束条件。这种由易到难的过程，有效地规避了直接优化复杂双层目标时极易陷入的局部极小值或梯度爆炸陷阱，确保了 ET-BERT 等大模型在对抗训练中的收敛稳定性。

3.3.3 基于 Stackelberg 博弈的二阶反应梯度优化

本节阐述 DS-RGO 方法中的 RGO 模块，即系统的核心计算引擎。

为了防御流量逃逸攻击，我们将分类器与伪装器之间的对抗过程建模为一个非合作 Stackelberg 博弈。在此框架下，防御者利用双层优化理论预判攻击者的反应，并通过展开优化技术计算包含二阶交互信息的 Stackelberg 梯度。

(1) Stackelberg 双层优化建模

不同于寻找纳什均衡的传统 Min-Max 思路，本文强调防御者的先发优势。我们将这一过程形式化为如下的带有动态约束的双层优化问题：

1. 内层跟随者问题：在博弈的内层，攻击者作为跟随者，在观测到防御者的模型参数 θ 后，旨在寻找一个最优扰动 δ^* 以最大化分类器的损失函数。与传统对抗训练不同，本文引入课程约束，即攻击者的能力受到当前训练阶段 t 的限制。

对于给定的输入样本 (x, y) 和当前轮次 t ，跟随者的优化目标定义为

$$\delta^*(\theta; t) = \arg \max_{\delta \in S_t} L_{\text{attack}}(f_{\theta}(x + \delta), y) \quad (3.7)$$

其中， S_t 表示随时间 t 变化的允许扰动集合：

$$S_t = \{\delta \in \mathbb{R}^D \mid \|\delta\|_p \leq \epsilon(t)\} \quad (3.8)$$

在此， $\epsilon(t)$ 是由课程调度器控制的动态扰动半径。 $\delta^*(\theta)$ 显式地表达了攻击者的最佳反应不仅依赖于模型参数 θ ，还受控于当前的课程阶段 t 。

2. 外层领导者问题：在博弈的外层，防御者作为领导者，其目标是寻找最优参数 θ ，使得在攻击者做出最佳反应 $\delta^*(\theta)$ 后的分类风险最小化。

防御者的全局优化目标定义为：

$$\min_{\theta} F(\theta) = E_{(x,y) \sim D}[L_{train}(f_{\theta}(x + \delta^*(\theta; t)), y)] \quad (3.9)$$

在 Stackelberg 博弈中，外层目标函数 $F(\theta)$ 对 θ 的依赖包含两部分：

直接依赖： L 对 f_{θ} 的直接影响；

隐式依赖： L 通过攻击反应 $\delta^*(\theta)$ 对 θ 产生的间接影响。

3.DS-RGO 的统一形式：内层与外层结合，得到 DS-RGO 的最终双层优化形式：

$$\begin{aligned} \min_{\theta} \sum_{i=1}^N L_{train}(f_{\theta}(x_i + \delta_i^*), y_i) \\ s.t. \delta_i^* = \arg \max_{\|\delta\|_p \leq \epsilon(t)} L_{attack}(f_{\theta}(x_i + \delta), y_i) \end{aligned} \quad (3.10)$$

该目标函数的物理意义为：

通过双层结构，模型被迫学习不仅在当前参数下表现好，而且在参数发生微小变化导致攻击者策略改变后，依然表现优异的鲁棒特征。

约束条件 $\|\delta\|_p \leq \epsilon(t)$ 使得优化问题的可行域随训练进程动态扩展。在训练初期，可行域极小，问题退化为标准训练，保证了模型在复杂损失曲面上的快速收敛；随着 t 增大，可行域扩大，模型逐渐适应强对抗环境，最终收敛至稳健的 Stackelberg 均衡点。

（2）基于展开优化的全导数分解

在传统的对抗训练中，普遍采用 Danskin 定理的近似推论，即计算模型参数 θ 的梯度时，假设攻击者生成的扰动 δ^* 是固定的常数，忽略了 θ 的更新对攻击策略 δ^* 的反作用。这种近似虽然计算简单，但丢失了博弈过程中的二阶交互信息，容易导致训练不稳定。

为了捕捉 Stackelberg 博弈中 Leader 对 Follower 的策略预判能力，本文采用展开优化技术来精确计算防御者的梯度。

全导数的分解回顾防御者的全局优化目标：

$$\min_{\theta} F(\theta) = L(f_{\theta}(x + \delta^*(\theta)), y) \quad (3.11)$$

其中 $\delta^*(\theta)$ 是内层优化问题的最优解。在 Stackelberg 博弈视角下， δ^* 是 θ 的函数。根据链式法则，目标函数对 θ 的梯度可分解为两部分：

$$\nabla_{\theta} F = \underbrace{\frac{\partial L(x + \delta^*, y)}{\partial \theta}}_{\text{Direct Gradient}} + \underbrace{\frac{\partial L(x + \delta^*, y)}{\partial \delta^*} \cdot \frac{d\delta^*(\theta)}{d\theta}}_{\text{Indirect (Reaction) Gradient}} \quad (3.12)$$

直接梯度（Direct Gradient）：表示在当前攻击 δ^* 保持不变的情况下，如何调整 θ 以降低分类损失。这是传统 Min-Max 方法唯一优化的项。

间接梯度（Indirect Reaction Gradient）：表示 θ 的微小变化如何诱导攻击者改变最优策略 δ^* ，进而影响最终损失。这一项包含博弈的二阶曲率信息，是实现抗逃逸预判关键。

然而，传统的对抗训练仅计算直接梯度，忽略了模型参数变化对攻击策略的潜在诱导影响。为了捕捉这种动态博弈过程中的二阶交互信息，本文利用展开优化近似计算全导数。图 3-3 直观展示了 Stackelberg 博弈中的梯度反向传播路径与计算机制。




图 3-3 Stackelberg 博弈交互与梯度反向传播机制图

如图 3-3 所示，防御者的参数更新梯度由两条路径合成：

路径 A 计算了损失函数关于参数的直接偏导数，这是标准方法所采用的项；

而路径 B 则是 Stackelberg 博弈的核心创新点。该路径通过将内层攻击者的 PGD 迭代过程展开为计算图，显式地计算了反应梯度项。这种机制相当于在优化过程中引入了一个前瞻性正则化项，能够有效抑制导致攻击敏感度剧增的参数更新方向，从而提升训练的稳定性。

（3）梯度的近似计算与参数更新

由于 $\delta^*(\theta)$ 通常没有解析解，直接计算雅可比矩阵 $\frac{d\delta^*}{d\theta}$ 极其困难。我们利用前向展开策略，将攻击者的优化过程视为一个有限步的动态系统。

设攻击者的优化过程由 K 步梯度上升构成，第 k 步的更新公式为 ϕ ：

$$\delta_{k+1} = \Phi(\delta_k, \theta) = \Pi_{\epsilon(t)} [\delta_k + \alpha \cdot \text{sign}(\nabla_{\delta} L(f_{\theta}(x + \delta_k), y))] \quad (3.13)$$

我们将最优解 δ^* 近似为 K 步迭代后的结果 $\delta_K(\theta)$ 。此时， $\frac{d\delta^*}{d\theta}$ 可以通过沿优化路径的反向传播递归计算：

$$\frac{d\delta_K}{d\theta} = \frac{\partial \Phi}{\partial \theta} + \frac{\partial \Phi}{\partial \delta_{K-1}} \cdot \frac{d\delta_{K-1}}{d\theta} \quad (3.14)$$

将上述递归式代入全导数公式，我们得到 DS-RGO 的参数更新梯度。为了降低计算 Hessian 矩阵的显存开销，我们在实际实现中采用截断反向传播或一阶泰勒展开近似。

最终用于更新模型参数的梯度方向为：

$$\theta_{new} \leftarrow \theta - \eta (\nabla_{\theta} L - \xi \cdot \nabla_{\delta}^2 L \cdot \nabla_{\delta} L) \quad (3.15)$$

其中, $\nabla_{\theta\delta}^2 L$ 是损失函数关于参数和扰动的混合偏导数, ξ 是正则化系数。

公式中的第二项充当了博弈正则化器。如果模型参数 θ 向某个方向更新会导致攻击者更容易找到破坏力强的扰动, 该正则化项会产生反向抑制力, 迫使模型避开那些虽能降低当前 Loss 但极其脆弱的参数区域, 从而真正实现抗逃逸的鲁棒性。

3.4 算法实现与模型适配

本节将 DS-RGO 方法的理论框架转化为具体的算法执行流程, 并针对 ET-BERT 和 CNN 两种不同模态的模型特性给出适配方案。

3.4.1 DS-RGO 训练算法流程描述

DS-RGO 训练算法的核心逻辑是将动态难度调度机制嵌入到 Stackelberg 双层博弈的迭代优化过程中。算法旨在通过在训练初期限制攻击者的扰动能力和搜索深度, 引导模型快速收敛至凸性较好的参数区域; 随后逐步释放攻击能力, 利用展开优化捕捉二阶博弈信息, 最终收敛至稳健的 Stackelberg 均衡点。

我们将整个训练过程形式化为算法 1, 其具体执行步骤如下:

表 3-1 DS-RGO 算法

算法 3.1 DS-RGO 算法

输入:

加密流量训练数据集 $D=(x_i, y_i)_{i=1}^N$

分类器模型 $f(\cdot; \theta)$, 初始参数 θ_0

课程超参数: 最大扰动半径 ϵ_{max} , 最大攻击迭代步数 K_{max} , 热身阶段轮数 T_{warm}

优化超参数: 学习率 η , 总训练轮数 T , 攻击步长系数 α_0

输出:

鲁棒模型参数 θ^*

1. 初始化

2 随机初始化模型参数 $\theta \leftarrow \theta_0$

3 初始化当前训练轮次 $t \leftarrow 1$

4 迭代训练过程

5 **While** $t \leq T$ **do**:

6 步骤 1: 更新课程参数

7 计算当前扰动半径: $\epsilon_t \leftarrow \min(\epsilon_{max}, \epsilon_{max} \cdot \frac{t}{T_{warm}})$

8 计算当前攻击步数:

9 **If** $t < T_{warm}/3$ **then** $K_t \leftarrow 1$

10 **Else** $K_t \leftarrow K_{max}$

11 计算攻击步长: $\alpha_t \leftarrow 2.5 \cdot \frac{\epsilon_t}{K_t}$

12 步骤 2: 批次优化

13 **For** each batch (X,Y) sampled from D **do**:

14 2.1 跟随者优化

15 初始化扰动 $\delta \leftarrow U(-\epsilon_t, \epsilon_t)$

16 **For** $k=1$ to K_t **do**:

17 计算攻击梯度: $g_{adv} \leftarrow \nabla_{\delta} L(f(X+\delta; \theta), Y)$

18 更新扰动并投影: $\delta \leftarrow \Pi_{\epsilon_t}(\delta + \alpha_t \cdot \text{sign}(g_{adv}))$

19 **End For**

20 获取最优扰动: $\delta^* \leftarrow \delta$

21 2.2 领导者更新

```

22      计算直接梯度:
23       $G_{direct} \leftarrow -\nabla_{\theta} L(f(X+\delta^*; \theta), Y)$ 
24      计算反应梯度[基于展开近似]:
25       $G_{react} \leftarrow -\nabla_{\delta} L \cdot \nabla_{\theta}^2 L$ 
26      计算全导数:  $G_{total} \leftarrow G_{direct} + \lambda \cdot G_{react}$ 
27      更新参数:  $\theta \leftarrow \theta - \eta \cdot G_{total}$ 
28      End For
29       $t \leftarrow t+1$ 
30  End While
31  返回结果:
32  Return  $\theta^* \leftarrow \theta$ 

```

3.4.2 针对 ET-BERT 的具体实现细节

ET-BERT 模型利用 BERT 的双向 Transformer 编码器结构来学习加密流量的上下文表示。与 CNN 处理的连续图像数据不同，ET-BERT 的输入是离散的 Token 索引序列。由于离散数据无法直接进行梯度反向传播，我们采用嵌入层扰动策略来实现 CS-Stackelberg 算法。

(1) 输入映射与嵌入表示

设原始加密流量样本经过预处理后得到 Token 序列 $w=[w_1, w_2, \dots, w_L]$ ，其中 $w_i \in 1, \dots, |V|$ 为词表索引， L 为序列长度。

在 ET-BERT 的前向传播中，离散序列 w 首先通过嵌入层映射为连续的向量空间：

$$E = \text{Embed}(w; \theta_{emb}) + P + S \quad (3.16)$$

其中， $E \in R^{L \times D}$ 表示综合嵌入向量， D 为隐藏层维度。Embed($\cdot$) 为词嵌入， P 为位置嵌入， S 为段嵌入。

(2) 对抗扰动的注入机制

为了在 Stackelberg 博弈中模拟攻击者的伪装行为，我们将对抗扰 δ 直接叠加在综合嵌入向量 E 上，而非修改离散的 Token w 。

攻击后的嵌入表示 E_{adv} 定义为：

$$E_{adv} = E + \delta \quad (3.17)$$

其中，扰动矩阵 $\delta \in R^{L \times D}$ 具有与 E 相同的维度。

在内层优化阶段，攻击者的目标是在课程约束下寻找最优扰动：

$$\delta^* = \arg \max_{\|\delta\|_F \leq \epsilon(t)} L(f_{encoder}(E + \delta; \theta_{enc}), y) \quad (3.18)$$

这里 $\|\cdot\|_F$ 表示 Frobenius 范数， $\epsilon(t)$ 为当前课程阶段允许的最大语义偏移量。

虽然 δ 是添加在连续向量空间的噪声，但在加密流量语境下，它模拟了攻击者通过流量填充或同义负载替换导致的高维特征偏移。较小的 $\epsilon(t)$ 模拟微小的时序抖动，较大的 $\epsilon(t)$ 模拟大范围的混淆代理行为。

(3) 梯度计算与参数冻结策略

由于 ET-BERT 模型参数量巨大，为了提高双层优化的计算效率，我们在算法实现中采用了部分冻结策略：

内层循环：在计算 $\nabla_{\delta} L$ 以更新 δ 时，我们将模型的所有参数 θ 设为 `requires_grad=False`。此时只构建关于 δ 的计算图，显著减少显存占用。

外层循环：在计算 Stackelberg 梯度更新 θ 时，恢复参数的梯度计算，并将 δ^* 作为常数张量参与前向传播。

具体实现中，Embedding 层的扰动注入通过 PyTorch 的 register_hook 实现，确保扰动能够正确参与梯度流的计算。

3.4.3 针对 BUPT-CNN 的具体实现细节

BUPT-CNN 模型采用流量即图像的表征策略，将数据包载荷截断并重组为二维灰度矩阵。针对该模态，DS-RGO 算法主要通过像素级扰动来实现，同时引入严格的边界约束以保证生成的对抗样本在物理上的有效性。

(1) 流量图像化与输入表征

设原始流量数据包序列经预处理后，被重塑为矩阵 $x \in R^{H \times W}$ 。为了适配卷积神经网络的输入要求，通常将字节值 $b \in 0, \dots, 255$ 归一化至浮点数区间 $[0,1]$ 。

模型映射函数定义为：

$$g_\phi : [0,1]^{H \times W} \rightarrow R^C \quad (3.19)$$

其中 ϕ 为卷积核及全连接层参数。

(2) 像素级扰动与物理约束

在 Stackelberg 博弈的内层优化中，攻击者生成的扰动 $\delta \in R^{H \times W}$ 被叠加到原始图像上。与 ET-BERT 仅约束范数不同，CNN 模型的对抗样本必须满足盒约束，即扰动后的像素值不能溢出 $[0,1]$ 的有效区间。

因此，对抗样本的生成公式包含一个截断操作：

$$x_{adv} = \text{Clip}_{[0,1]}(x + \delta) = \min(\max(x + \delta, 0), 1) \quad (3.20)$$

结合课程学习机制，攻击者的优化目标为：

$$\delta^* = \arg \max_{\|\delta\|_\infty \leq \epsilon(t)} L(g_\phi(\text{Clip}(x + \delta)), y) \quad (3.21)$$

$\|\delta\|_\infty \leq \epsilon(t)$ ：限制了攻击者修改每个字节的最大幅度。例如 $\epsilon=8/255$ 表示每个字节的值最多改变 8 个单位。这模拟了攻击者为了规避基于统计特征的检测，只能对载荷进行微调。

Clip($\cdot$)：确保生成的对抗流量可以被还原为合法的二进制数据流，防止出现数学上存在但物理上无法构造的数据包。

(3) 梯度传播特性

由于 CNN 的卷积操作和激活函数几乎处处可导，相比于 ET-BERT，在 CNN 上计算 Stackelberg 梯度更加直接。在计算反应梯度时，我们需要计算二阶混合偏导数 $\nabla_{\delta\phi}^2 L$ 。对于 CNN，这相当于计算：

$$\frac{\partial}{\partial \phi} \left(\frac{\partial L}{\partial x} \right) \quad (3.22)$$

这一项迫使卷积滤波器学习那些梯度变化率低的特征。模型倾向于提取那些即使输入像素发生剧烈扰动、特征响应值依然保持稳定的鲁棒纹理，而非依赖易被篡改的载荷内容特征。

3.5 理论分析

本节从优化理论的角度探讨 DS-RGO 方法的有效性。重点分析课程学习策略的可优化性、

Stackelberg 均衡点的收敛稳定性、基于平坦极小值理论的泛化性和连续空间博弈的物理映射与理论上限。

3.5.1 课程学习策略对非凸损失曲面的平滑作用分析

在加密流量抗逃逸训练中，ET-BERT 和 CNN 等深度神经网络的参数空间极大，且包含复杂的非线性激活函数，导致防御者的全局优化目标函数 $F(\theta)$ 具有高度非凸性。

我们将对抗训练的目标函数记为 $\rho_\epsilon(\theta)$:

$$\min_{\theta} \rho(\theta) \quad \text{where} \quad \rho(\theta) = E_{(x,y)} \left[\max_{\|\delta\| \leq \epsilon} L(f_{\theta}(x+\delta), y) \right] \quad (3.23)$$

若直接在训练初期设定 $\epsilon = \epsilon_{max}$ ，由于 $\max$ 操作符会选取损失曲面在局部邻域内的极值点，这会极大地增加目标函数的曲率和不规则性，导致优化器陷入较差的局部极小值或发生梯度发散。

定理 1: 课程平滑效应

当扰动半径 $\epsilon(t)$ 较小时，目标函数 $\rho_{\epsilon(t)}(\theta)$ 近似于原始损失函数的平滑版本；随着 $\epsilon(t)$ 增大，目标函数逐步引入对抗约束。课程调度通过控制 $\epsilon(t)$ 的增长速率，构建了一条从易优化曲面到鲁棒曲面的连续路径。

证明分析:

利用泰勒级数展开，我们可以分析 ϵ 对目标函数的影响。对于足够小的 ϵ ，在输入样本 x 附近的损失函数可近似为线性:

$$L(f_{\theta}(x+\delta), y) \approx L(f_{\theta}(x), y) + \delta^T \nabla_x L(f_{\theta}(x), y) \quad (3.24)$$

此时，内层最大化问题 $\max_{\|\delta\| \leq \epsilon} (\delta^T \nabla_x L)$ 的解析解为 $\epsilon \|\nabla_x L\|_*$ (其中 $\|\cdot\|_*$ 为对偶范数)。代入外层目标函数，可得:

$$\rho_{\epsilon}(\theta) \approx \underbrace{L(f_{\theta}(x), y)}_{\text{Standard Loss}} + \underbrace{\epsilon \|\nabla_x L(f_{\theta}(x), y)\|_*}_{\text{Gradient Regularization}} \quad (3.25)$$

该近似公式揭示了 DS-RGO 课程机制的物理本质:

(1) 初期阶段 $\epsilon(t) \rightarrow 0$

此时 $\rho_{\epsilon}(\theta) \approx L^*_{\text{clean}}$ 。目标函数退化为标准的交叉熵损失。这使得模型能够在一个相对平滑的凸区域内快速收敛，优先学习加密流量的显性特征，为后续对抗训练提供一个良好的参数初始化点 $\theta \cdot \text{init}$ 。

(2) 过渡阶段 $\epsilon(t)$ 增大

第二项 $\epsilon(t) \|\nabla_x L\|_*$ 充当了一个动态权重的雅可比正则化项。随着 $\epsilon(t)$ 缓慢增加，模型寻找那些输入微小变化导致输出剧烈变化的参数区域。这种渐进式的正则化迫使优化轨迹始终保持在损失曲面的平坦区域，避免了直接进行强对抗训练时可能的梯度爆炸。

(3) 最终阶段 $\epsilon(t) = \epsilon_{max}$

模型最终在强约束下微调，学习到对大范围流量伪装具有不变性的深层鲁棒特征。

综上所述，DS-RGO 通过动态调整 $\epsilon(t)$ ，有效地对高度非凸的对抗损失曲面进行了平滑处理，解决了传统方法因起步难度过高而导致的训练不收敛问题。

3.5.2 Stackelberg 均衡点的收敛稳定性探讨

传统的对抗训练基于纳什均衡假设，即寻找一个鞍点 (θ^*, δ^*) 使得:

$$L(\theta^*, \delta) \leq L(\theta^*, \delta^*) \leq L(\theta, \delta^*) \quad (3.26)$$

然而，在深度神经网络的非凸优化中，纳什均衡点往往难以稳定收敛，训练轨迹常表现为围绕鞍点的持续震荡。这是因为防御者仅根据当前的攻击样本更新 θ ，而忽略了 θ 的改变会立即引发 δ 的剧烈变化。

相比之下，DS-RGO 方法将问题建模为寻找 Stackelberg 均衡点。

定理 2：Stackelberg 梯度的稳定性

Stackelberg 更新方向包含了损失函数关于参数与扰动的二阶混合偏导数信息，该项在优化过程中充当了雅可比正则化器，能够抑制导致攻击敏感度剧增的参数更新方向，从而提升收敛稳定性。

证明分析：

回顾防御者在 Stackelberg 博弈中的更新梯度：

$$\nabla_{SE} F(\theta) = \underbrace{\nabla_{\theta} L(\theta, \delta^*)}_{\text{Direct Term}} - \underbrace{\nabla_{\delta}^2 L(\theta, \delta^*)^{-1} \nabla_{\delta\theta}^2 L(\theta, \delta^*) \nabla_{\delta} L(\theta, \delta^*)}_{\text{Implicit/Reaction Term}} \quad (3.27)$$

我们将重点分析反应项中的交叉导数部分 $\nabla_{\delta\theta}^2 L$ 对稳定性的贡献：

（1）抑制高敏感度方向：

交叉导数 $\nabla_{\delta\theta}^2 L$ 描述了模型参数 θ 的微小变化如何影响攻击者梯度 $\nabla_{\delta} L$ 的大小。如某个更新方向使得 $\nabla_{\delta} L$ 显著增大，反应项会产生一个反向的梯度分量，抵消直接项 $\nabla_{\delta} L$ 的更新。

这种机制相当于一种前瞻性防御，模型不仅学习如何降低当前的 Loss，还学习如何不让攻击者变得更强。

（2）平滑优化轨迹：

在标准的 Min-Max 优化中，攻击者和防御者的策略往往是解耦的，导致双方策略互斥跳变。Stackelberg 梯度将 $\delta^*(\theta)$ 的依赖关系内化到 θ 的更新中，使得优化路径沿着最优反应曲线移动，而非在不同的局部极值之间跳跃。

（3）免虚假鲁棒性：

许多传统方法容易陷入梯度掩蔽陷阱，模型通过破坏梯度信息来让 PGD 攻击失效，而非真正提升鲁棒性。Stackelberg 博弈显式利用了二阶梯度信息，迫使模型在损失曲面的曲率较小的区域收敛，寻找平坦极小值。平坦极小值意味着即使输入或参数发生微小扰动，Loss 也不会剧烈上升，这正是抗逃逸能力在几何上的体现。

综上所述，DS-RGO 方法通过显式计算并优化反应梯度，从理论上保证了模型能够收敛至比纳什均衡更稳定、泛化能力更强的 Stackelberg 均衡点。

3.5.3 基于平坦极小值理论的泛化能力解析

在加密流量分类的实际现网应用中，模型往往面临训练集与真实测试环境数据分布不一致的问题。因此，模型能否对未知的异构或逃逸流量保持较强的泛化能力，是衡量防御体系有效性的核心指标。本节基于深度学习优化几何理论，从平坦极小值的角度对 DS-RGO 方法的高泛化性进行严格的数学解析。

在深度神经网络的非凸优化曲面上，模型参数收敛的局部极小值通常可划分为尖锐极小值与平坦极小值。假设模型收敛于最优参数 θ^* ，当测试数据的特征分布发生偏移时，等效于

在参数空间施加了微小的扰动 $\Delta\theta$ 。根据泰勒展开，扰动后的分类损失变化量可近似为：

$$L(\theta^* + \Delta\theta) \approx L(\theta^*) + \nabla L(\theta^*)^T \Delta\theta + \frac{1}{2} \Delta\theta^T H \Delta\theta \quad (3.28)$$

由于在极小值点处一阶梯度 $\nabla L(\theta^*) \approx 0$ ，损失的剧增幅度主要由 Hessian 矩阵 H 的曲率决定。

传统的 Min-Max 对抗训练为了强行拟合对抗样本，往往会驱使模型陷入尖锐极小值。在此区域， H 的最大特征值极大，损失曲面极其曲折。这意味着一旦测试集流量特征与训练集产生微小差异，分类损失 L 就会呈二次方剧增，泛化能力断崖式衰退。

相比之下，本文提出的 DS-RGO 方法通过 Stackelberg 博弈显式地优化了模型的泛化边界。回顾防御者在 DS-RGO 中的参数更新梯度：

$$\frac{dF}{d\theta} = \nabla_{\theta} L - \xi \cdot \nabla_{\delta\theta}^2 L \cdot \nabla_{\delta} L \quad (3.29)$$

上述公式中，二阶交叉导数项 $\nabla_{\delta\theta}^2 L$ 改变了模型的收敛几何特性。在优化过程中，它充当了一个动态的雅可比曲率修正项。如果模型试图向一个曲率极大、容易过拟合的尖锐极小值更新，该修正项会产生较大的反向梯度，迫使优化轨迹偏离危险区域。

同时，配合动态难度调度机制，模型在初期被限制在平滑的低曲率空间内寻优。这二者的协同作用，在数学本质上严格约束了 Hessian 矩阵的迹，引导模型最终收敛于一个平坦极小值。在这种平坦的几何空间内，即使未知的逃逸流量带来了特征分布的偏移，模型在 $\theta^* + \Delta\theta$ 处的损失依然能够保持在与 $L(\theta^*)$ 相近的低位，从而为模型跨域应对复杂变种流量提供了坚实的泛化理论支撑。

3.5.4 连续空间博弈的物理映射与理论上限分析

本章在构建针对 ET-BERT 与 BUPT-CNN 模型的防御机制时，核心均依赖于在连续的特征或参数空间内引入对抗扰动 δ 。然而，这种基于梯度的连续空间博弈在向网络空间安全的真实物理环境映射时，存在固有的理论跨度。真实的加密流量在数据链路层或传输层均由离散的字节流构成，且受到 TLS 或 QUIC 等底层协议状态机的严格约束。假设原始网络流量为 x ，真实的对抗载荷定义为离散扰动 Δx 。为保证修改后的流量仍符合底层协议规范， Δx 必须属于一个受限的协议合法动作空间 $P(x)$ 。此时，攻击者在物理空间的规避优化目标可形式化表示为：

$$\max_{\Delta x \in P(x)} L(f(x \oplus \Delta x), y) \quad (3.30)$$

其中， $f(\cdot)$ 为分类器模型， L 为损失函数， $\oplus$ 表示物理载荷的注入或篡改操作。由于 $P(x)$ 是高度离散且非凸的约束空间，加之离散数据在深度神经网络中的不可导性，直接在物理数据包层面通过梯度寻优求解最优对抗载荷，本质上属于计算复杂度极高的 NP-Hard 组合优化问题。

为解决上述物理空间不可导与寻优困难的瓶颈，本章引入特征映射函数 $E(\cdot)$ ，将离散的物理流量隐式映射至连续的高维向量空间 $Z \in R^d$ 。在此连续空间中，模型引入了不受严格物理协议约束的连续扰动变量 δ 。这一处理方式在数学上构成了一种防御视角的松弛策略。松弛后的连续对抗优化目标转化为：

$$\max_{\delta \in R^d, \|\delta\|_p \leq \epsilon} L(f(E(x) + \delta), y) \quad (3.31)$$

其中, $\|\delta\|_p \leq \epsilon$ 限制了连续扰动的上界, 以确保其在隐空间内具有语义的相对连贯性。基于此连续空间的松弛策略, 本章提出如下关于防御鲁棒性边界的理论假设与界定:

引理 1: 连续空间扰动对物理离散攻击的理论上限界定

假设存在一种映射关系, 使得任意物理协议合法空间 $P(x)$ 内的离散扰动 Δx 映射到连续特征空间后的偏移量, 均被包含在半径为 ϵ 的连续扰动球 $B_\epsilon = \{\delta \in R^d \mid \|\delta\|_p \leq \epsilon\}$ 内, 即满足如下子集关系:

$$\{E(x \oplus \Delta x) - E(x) \mid \Delta x \in P(x)\} \subseteq B_\epsilon \quad (3.32)$$

则连续特征空间内的对抗损失, 在数学上必然构成了物理空间对抗损失的理论上限, 即满足不等式:

$$\max_{\delta \in B_\epsilon} L(f(E(x) + \delta), y) \geq \max_{\Delta x \in P(x)} L(f(x \oplus \Delta x), y) \quad (3.33)$$

基于引理 1 的形式化界定, 本章所设计的 DS-RGO 等机制实际上是在模拟一种无物理约束的最强攻击。通过在连续空间内赋予攻击者远超物理实际的扰动自由度, 若模型能够在极度严苛的连续高维特征逃逸中寻找 Stackelberg 均衡并保持鲁棒性, 则在面对现实物理网络中受协议规范、时序逻辑及离散载荷强约束的降维伪装攻击时, 必然具备极高的安全广度与防御覆盖面。这种将物理离散约束转化为连续空间上限评估的闭环论证, 在保证双层优化问题数学可解性与计算实时性的同时, 为系统的整体防御架构确立了严密的底层安全假设边界。

3.6 实验评估与分析

本节针对 ET-BERT 和 BUPT-CNN 模型开展实验评估。下文首先明确实验的基础环境与评估指标, 随后围绕方法的综合防御性、训练稳定性与泛化性等核心维度展开剖析。

3.6.1 实验设置

(1) 数据集与数据预处理

为了全面评估防御模型在现代复杂网络环境下的鲁棒性、泛化能力及多分类决策边界, 本文选取了当前加密流量分析领域最具时效性与挑战性的公开基准数据集 Cross-Platform2022(App60)。选择该数据集的依据在于其高度还原了真实网络空间中的极高难度混淆特征:

全加密协议覆盖: 该数据集包含了大量现代全加密协议流量。相较于早期协议, TLS1.3 与 QUIC 实现了握手阶段的彻底加密与特征随机化, 传统显式指纹完全失效。

跨平台与细粒度应用混淆: 数据集涵盖了同一应用在 iOS、Android、Windows 及 macOS 四大主流系统下的异构流量。这种跨平台带来的域偏移以及高达 60 类的细粒度 APP 划分, 使其天然具备类间距离极小的对抗属性, 代表了当前最高难度的分类场景。

为了从泛化性、机制完备性及工业级可扩展性三个维度全方位评估本文提出的防御与加速算法, 本文在预处理后的 Cross-Platform 2022(App60)数据集基础上, 构建了三个具有明确测试导向的评测基准:

域泛化评测子集 CP-Mobile 与 CP-Desktop: 分别提取纯移动端与纯桌面端流量, 严格检验模型在跨操作系统环境下的特征提取与域泛化能力。

极端复杂全集 CP-Full: 将移动端与桌面端流量进行全量融合。该全集包含了最剧烈的跨

域特征冲突与最大的样本规模。

实验中,为确保多分类任务评估的客观性与稳定性,所有数据集均按照 8:1:1 的比例执行分层随机采样,划分为训练集、验证集和测试集。

(2) 骨干网络选型策略

为了验证 DS-RGO 防御框架的通用性与有效性,本文选取了两种在架构机理与参数规模上截然不同的模型作为骨干网络:

序列模态代表: ET-BERT 大规模预训练模型。该模型基于 12 层 Transformer 架构,是目前加密流量分类领域的 SOTA 模型。ET-BERT 参数量巨大且损失曲面高度非凸,直接进行对抗训练极易发散。选用该模型旨在重点验证本文提出的课程学习机制在解决非凸优化收敛难题上的有效性。

视觉模态代表: BUPT-CNN 轻量级卷积模型。该模型基于 LeNet-5 改进,结构简单推理速度快,常用边缘侧部署。选用该轻量级模型旨在验证 Stackelberg 博弈策略不依赖于特定的大模型架构,能够广泛适用于不同计算量级的神经网络,具有良好的泛化能力。

针对本文选用的序列与视觉两类异构骨干网络,数据预处理流程遵循模态适配原则:

序列模态适配: 遵循流量即语言范式,首先利用 SplitCap 工具按五元组严格切分双向流,并去除链路层与网络层明文头部,仅保留应用层载荷。随后,将纯载荷转换为十六进制 Token 序列,并使用 BERTTokenizer 进行分词。考虑到大规模预训练模型的计算效率与特征信息量的平衡,序列长度统一截断或填充至 $L=512$ 。

视觉模态适配: 遵循流量即图像范式,将预处理后截取的前 784 字节纯载荷字节流转换为十进制,并归一化至 $[0,1]$ 区间。随后,按照空间映射规则重塑为 28×28 的二维灰度特征矩阵,以最大程度保留现代加密流量在空间维度上的纹理分布特征。

(3) 对比基准方法

为了客观衡量本文方法的性能,选取了 7 种具有代表性的防御方法进行对比,涵盖了从经典对抗训练到 NLP 领域前沿防御的多个维度:

Standard: 标准训练模型,无任何对抗防御机制,作为性能的下界对照。

PGD-AT^[32]: 基于投影梯度下降的对抗训练方法,是该领域的经典基准。

FreeLB^[71]: 专门针对 Transformer/BERT 结构设计的对抗训练方法,通过在 Embedding 层添加累积扰动来提升泛化性,是 NLP 领域的强基准。

CAT^[72]: 对比对抗训练 (Contrastive Adversarial Training)。该方法结合了对比学习与对抗防御,通过在特征空间中强制对齐对抗样本与真实同类样本的表征,是近年来解决高维特征空间下对抗逃逸的主流前沿方法。

Adv-LoRA^[73]: 对抗低秩适配 (Adversarial Low-Rank Adaptation)。当前针对大规模预训练模型鲁棒微调的代表性工作,通过在模型的低秩矩阵上执行对抗训练,在极大优化参数更新效率的同时保持了高度的对抗鲁棒性。

DiffPurify^[74]: 基于扩散模型的特征净化防御。作为新兴的主动防御范式,该方法利用扩散模型的前向去噪机制,在输入分类器前对受扰动的流量特征序列进行重构与净化。

DS-RGO: 本文提出的基于动态难度调度与二阶反应梯度优化的抗逃逸训练方法。

(4) 评价指标与参数设定

本文采用正常准确率（Clean Accuracy, CA）和鲁棒准确率（Robust Accuracy, RA）作为核心评价指标。其中，RA 统一基于 PGD-20 生成的强对抗样本进行评估，以模拟攻击者具备较强逃逸能力的场景。

鉴于加密流量固有的长尾分布特性，本章还引入了精确率（Precision）、召回率（Recall）以及宏平均 F1 分数（Macro-F1）。其中，通过对少数类的精确率与召回率进行细粒度剖析，可以有效评估模型抗灾难性遗忘的能力；而 Macro-F1 则作为综合评价指标，用于衡量模型在极端不平衡条件下的全局鲁棒鉴别力。

为了确保实验的可复现性，实验涉及的软硬件环境配置、核心超参数设定和对抗攻击与防御机制参数设定分别列于表 3-2、表 3-3 与表 3-4 中。实验统一在 NVIDIA GeForce RTX4090 单卡环境下进行。

表 3-2 实验软硬件环境配置

类别	项目	配置参数
硬件环境	CPU 处理器	Intel Xeon Gold 6248R @ 3.00GHz
	GPU 加速卡	NVIDIA GeForce RTX 4090
	RAM 内存	64GB DDR4 2933MHz
软件环境	操作系统	Ubuntu 20.04 LTS
	开发语言	Python 3.8.10
	深度学习框架	PyTorch 1.13.1 (CUDA 11.7, CuDNN 8.5)
	核心依赖库	Transformers 4.26.0, Scikit-learn 1.2.0

表 3-3 骨干网络训练超参数设置

参数名称	ET-BERT	BUPT-CNN
输入维度	Sequence Length L=512	Image Size 28*28
优化器	AdamW	Adam
学习率	$2*10^{-5}$	$1*10^{-3}$
批次大小	32	128
总训练轮次	20	50
权重衰减	$1*10^{-2}$	$1*10^{-4}$
学习率调度	Linear Warmup	Step Decay

表 3-4 对抗攻击与防御机制参数设定

类别	参数项	设定值
攻击空间约束	ET-BERT 扰动域	词嵌入层
	ET-BERT ϵ	0.05
	ET-BERT α	0.01
	CNN 扰动域	像素层 L_∞ 约束
	CNN ϵ	8/255
	CNN α	2/255
迭代步数设置	训练阶段 K_{train}	3
	测试阶段 K_{test}	20
DS-RGO	Warm-up Epochs	5
课程策略	扰动增长方式	线性增长 $0 \rightarrow \epsilon_{max}$

承接第三章 3.5.4 节的理论分析与安全假设,本章的基准评估统一在模型的连续特征空间中执行对抗载荷生成。这种评估方式的本质,旨在测试防御模型在面临引理 1 所述的理论上限攻击时的鲁棒性能退化情况。通过在极度严苛的连续高维空间中进行基准对比,并补充真实网络环境下的物理填充推理验证实验。

3.6.2 综合防御性能对比

为了验证所提 DS-RGO 方法在应对全加密流量对抗攻击时的有效性及跨平台泛化能力,本节在 CP2022 数据集的两个异构子集 CP-Mobile 移动端与 CP-Desktop 桌面端上,分别基于 ET-BERT 和 BUPT-CNN 两种骨干网络进行横向对比实验。

实验选取 Standard、PGD-AT、FreeLB、DiffPurify、CAT 以及 Adv-LoRA 共 6 种基准方法与 DS-RGO 进行对比。评价指标包括干净样本准确率 CA、基于 PGD-20 攻击的鲁棒准确率 RA,以及衡量类别不平衡鉴别力的宏平均 F1 分数 Macro-F1。实验详细结果如表 3-5 和表 3-6 所示,数据格式为: Acc%/Macro-F1%。

表 3-5 不同防御方法在 ET-BERT 上的分类准确率对比

防御方法	CP-MobileClean	CP-MobilePGD-20	CP-DesktopClean	CP-DesktopPGD-20
Standard	96.50/95.10	0.05/0.01	97.20/96.30	0.10/0.05
PGD-AT	88.40/86.50	62.20/58.80	89.10/87.20	64.50/61.10
FreeLB	90.20/88.60	65.50/61.10	91.00/89.50	67.20/64.50
DiffPurify	89.80/88.10	66.40/62.50	90.50/89.00	68.10/65.20
CAT	91.50/90.20	68.90/65.20	92.40/91.50	70.50/68.10
Adv-LoRA	92.80/91.40	70.10/67.40	93.50/92.20	72.40/70.20
DS-RGO	94.50/93.80	74.90/72.50	95.10/94.40	76.90/75.10

表 3-6 不同防御方法在 BUPT-CNN 上的分类准确率对比

防御方法	CP-MobileClean	CP-MobilePGD-20	CP-DesktopClean	CP-DesktopPGD-20
Standard	92.10/90.50	1.20/0.80	93.40/91.80	1.50/1.00
PGD-AT	84.50/82.10	54.50/49.20	85.80/83.50	56.80/51.50
FreeLB	86.20/84.10	57.10/53.50	87.50/85.20	58.90/55.40
DiffPurify	85.80/83.60	58.40/54.20	86.60/84.80	60.10/56.50
CAT	87.50/85.60	60.50/57.10	88.30/86.70	61.80/58.20
Adv-LoRA	88.20/86.50	60.20/56.80	89.10/87.40	62.50/59.40
DS-RGO	90.40/89.10	63.80/61.20	91.50/90.20	66.10/63.50

表 3-5、表 3-6 显示各模型在正常流量与对抗攻击下的分类表现。未加防御的 **Standard** 模型在 **PGD-20** 攻击下鲁棒准确率近乎归零，显示出深度分类器在加密流量特征空间的内生脆弱性。

DS-RGO 在 **CP-Mobile**、**CP-Desktop** 子集鲁棒准确率分别为 **74.90%**、**76.90%**，均达最优；相较于 **PGD-AT**、**Adv-LoRA**、**CAT** 等基线，证实 **RGO** 在高维流序列非凸优化中寻优更优，**DS** 机制将干净样本准确率损失控制在 **2.1%** 内，缓解鲁棒性与精度之间矛盾。

App60 数据集长尾分布下，强攻击中 **Adv-LoRA** 移动端 **Macro-F1** 仅 **67.40%**，存在少数类决策边界牺牲问题；**DS-RGO** 鲁棒 **Macro-F1** 稳定在 **72.50%~75.10%**，与整体准确率差值小，验证 **DS** 机制可保护长尾应用特征完整性。

DS-RGO 在 **CP-Desktop** 子集防御稳定，证明其学习到跨域一致的加密应用博弈特征；该方法在 **ET-BERT**、**BUPT-CNN** 架构上均实现性能提升，验证其架构普适性。

3.6.3 训练稳定性与泛化性分析

针对大模型在对抗训练过程中普遍存在的梯度震荡、收敛困难及鲁棒过拟合现象，本节重点考察了不同训练策略下的动态优化过程，并记录了 **ET-BERT** 与 **BUPT-CNN** 在训练全周期的收敛轨迹与验证集鲁棒准确率的变化趋势。

（1）异构模型的训练损失收敛轨迹对比

图 3-4 展示了采用不同训练机制时，**ET-BERT** 与 **BUPT-CNN** 在 **CP-Full** 数据集上的损失值收敛轨迹对比。




图 3-4 不同模型架构下各训练策略的损失收敛轨迹对比

图 3-4 的实验对比揭示模型特异性优化规律。图 3-4(a)中，ET-BERT 参数量庞大，传统对抗训练因初期固定强度扰动，在高维非凸曲面上易陷入局部极小值，引发梯度震荡，最终拟合 Loss 偏高；Adv-LoRA、CAT 等前沿方法通过低秩截断或对比约束平滑优化路径，但中后期仍存在收敛困难。

本文 DS-RGO 方法通过前 5 个 Epoch 动态难度调度平稳拟合数据分布，结合二阶反应梯度优化，在 ET-BERT 上实现最平缓且极小值更低的收敛轨迹。

横向对比图 3-4(a)与(b)可见，上述收敛差异在简单结构 BUPT-CNN 上较小，在亿级参数 ET-BERT 上显著放大，证实单纯对抗微调易导致大模型优化失效，而博弈机制与动态课程学习的深度融合，是大规模预训练模型稳定对抗优化的关键。

(2) 鲁棒性泛化趋势与过拟合分析

除了训练收敛性，模型泛化表现是评估训练稳定性的关键指标。图 3-5 展示 ET-BERT 与 BUPT-CNN 在 CP-Full 数据集上的 PGD-20 鲁棒准确率随训练轮次的变化轨迹。




图 3-5 鲁棒准确率随训练轮次的泛化趋势分析

图 3-5 揭示长周期训练泛化稳定性差异。ET-BERT 上，PGD-AT 与 FreeLB 在第 10-12 轮性能峰值后，鲁棒准确率回落 5%~8%，证实鲁棒过拟合；单纯 Min-Max 训练易使参数过度拟合特定对抗噪声，削弱泛化能力；CAT 仅缓解掉点，未消除回落。

DS-RGO 前 8 个 Epoch 因扰动受限性能滞后，后续无回落持续收敛，RA 稳定在 74.9% 左右；其泛化优势源于 RGO 隐式正则化，通过约束 Hessian 矩阵特征值，驱动参数落入平坦极小值区域，提升鲁棒稳定性。

图 3-5(b)中，BUPT-CNN 因模型容量受限，PGD-AT 无显著过拟合；DS-RGO 借助博弈寻优，将准确率上限提升约 6%，证实其可抑制大模型鲁棒过拟合，且异构架构下增益稳定。

3.6.4 消融实验

为了深入解析 DS-RGO 框架中动态课程学习 DS 与二阶反应梯度优化 RGO 两个核心组件的独立贡献及其相互作用关系，本节在 CP-Full 数据集上，针对 ET-BERT 与 BUPT-CNN 骨干网络设计严格的消融实验。我们构建了以下四种变体模型进行对比分析：

Baseline：基准模型。采用传统的 Min-Max 对抗训练框架，不包含博弈反应梯度，且训练全程采用固定强度的对抗扰动。

DS-AT：仅引入课程学习机制。采用动态的攻击难度调度策略，但在梯度计算上仍沿用传统的一阶 PGD 梯度，以规避初期优化失效。

RGO-AT：仅引入二阶反应梯度优化。将攻防建模为 Stackelberg 博弈，利用展开优化计算主从依赖梯度，但移除课程调度模块，训练初期即引入高强度对抗约束。

DS-RGO：完整模型。同时深度融合 Stackelberg 博弈二阶梯度与动态难度调度机制。

表 3-7 详细列出了上述四种变体在全量数据集应对 PGD-20 攻击下的鲁棒准确率 RA 及相对于基准方法的性能增益。图 3-6 则直观展示了各组件在不同骨干网络上的性能贡献分布。

表 3-7 核心组件有效性的消融实验详细数据对比

模型架构	变体模型	核心组件	PGD-20 RA(%)	相对提升
BUPT-CNN	Baseline	PGD-AT	55.60%	-
	DS-AT	PGD + DS	56.50%	+0.90%
	RGO-AT	PGD + RGO	60.20%	+4.60%
	DS-RGO	DS + RGO	64.90%	+9.30%
ET-BERT	Baseline	PGD-AT	63.50%	-
	DS-AT	PGD + DS	66.20%	+2.70%
	RGO-AT	PGD + RGO	69.80%	+6.30%
	DS-RGO	DS + RGO	75.80%	+12.30%




图 3-6 核心组件在异构模型上的消融实验结果对比

表 3-7 与图 3-6 的综合分析在全量异构数据的测试下验证了双重防御机制的核心效能。Baseline 与 RGO-AT 对比显示, CNN 与 ET-BERT 上引入博弈二阶梯度分别提升 4.60%、6.30%, 证实传统纳什均衡易陷次优解, RGO 通过优化主从依赖, 驱动参数向更平坦极小值区域收敛。DS 机制具显著模型特异性, Baseline 与 DS-AT 对比, 其在 BUPT-CNN 上仅增益 0.90%, 在 ET-BERT 上提升达 2.70%, 证实渐进式难度引导可保护大模型底层特征分布。

完整版 DS-RGO 在 ET-BERT 上总提升 12.30%, 超越单一模块增益总和 9.00%, 揭示 DS 构建平滑初始优化曲面、RGO 提供后期精准寻优方向, 二者融合是模型兼具高鲁棒性与稳定性的充要条件。

3.6.5 鲁棒性机理与可视化分析

为了深入探究 DS-RGO 方法提升抗逃逸能力的微观机理, 本节利用可视化技术对模型内部的特征提取行为, 从特征流形分布与语义注意力分布两个维度进行定性分析。

鉴于 ET-BERT 模型基于 Transformer 架构, 其独特的多头自注意力机制能够直观地映射出模型对流量序列中关键字节的语义关注度, 而这是传统卷积神经网络 CNN 所不具备的特性。因此, 为了更清晰地揭示防御机制如何修正模型对恶意载荷的关注焦点, 本节的特征流形与注意力热力图分析将聚焦于 ET-BERT 模型展开。

(1) 特征空间分布可视化

深度神经网络的抗干扰能力与其提取的高维特征分布形态密切相关。为了直观展示模型在强对抗攻击下的特征提取质量, 本文使用 t-SNE(t-Distributed Stochastic Neighbor Embedding) 算法, 将 ET-BERT 倒数第二层输出的 768 维特征向量映射至二维平面。考虑到 CP-Full 数据集包含 60 个细粒度类别, 为保证特征拓扑分布的可视化清晰度, 本实验随机抽取了 6 个极具代表性的高混淆加密应用进行展示。

图 3-7 展示了四种不同防御策略在受到 PGD-20 攻击后的特征流形分布对比, 图中不同颜色的散点代表不同的流量类别。




图 3-7 强对抗攻击下特征空间分布的 t-SNE 可视化对比

图 3-7 流形拓扑结构揭示防御机制对底层表征的重塑作用。图 3-7(a)中，Standard 模型受扰动后特征空间严重混叠，决策边界模糊；图 3-7(b)PGD-AT 初步形成聚类趋势，但类内分布松散；图 3-7(c)前沿方法 CAT 通过对比约束压缩类内距离，高维混淆区域仍存在边缘粘连。

图 3-7(d)中，DS-RGO 在同等攻击强度下维持清晰紧凑的聚类结构，具类内高聚合、类间强排斥优势，证实 Stackelberg 博弈梯度通过二阶反应项驱动参数落入平坦极小值区域，使模型学习到高同变性表征，从特征层面封锁对抗样本逃逸路径。

(2) 注意力机制热力图

为了进一步从语义层面解析模型的抗逃逸机理，本节提取了 ET-BERT 最后一层 Transformer 块对输入序列的注意力权重。图 3-8 展示了在处理一段受 PGD-20 攻击的 TLS 1.3 Client Hello 流量样本时，四种防御策略的注意力热力图对比。




图 3-8 对抗环境下关键流量字段的注意力机制热力图对比

图 3-8 权重分布揭示防御机制对模型关注焦点的修正作用。图 3-8(a)中，Standard 模型受攻击后注意力弥散，错误聚焦于末尾填充区域，证实对抗扰动诱导模型捕捉噪声；图 3-8(b)PGD-AT 缓解弥散，但高权重区域在协议头与噪声区间剧烈波动；图 3-8(c)前沿方法 CAT 加强协议字段捕获，但处理高随机性加密握手字段时存在局部注意力偏移。

图 3-8(d)中，DS-RGO 高权重区域精准稳定聚焦于序列头部 16、03、03 等 TLS 握手协议核心 Token，其语义聚焦能力证实博弈对抗训练驱动模型忽略易扰动 Padding 噪声，依赖语义不变性协议底层逻辑决策，从注意力机制层面保障模型鲁棒性。

3.6.6 攻击强度敏感性分析

在实际网络对抗中，攻击者可能会采用超出训练预期的强扰动进行破坏。由于 ET-BERT 模型参数空间巨大且决策边界高度非线性，其在面对极端扰动时通常表现出比轻量级模型更明显的脆弱性。因此，为了探究本文方法在极限条件下的防御边界与安全裕度，本节选取最具挑战性的 ET-BERT 模型作为压力测试对象，评估其在不同扰动半径下的性能衰减趋势。

本节突破了标准测试中固定 $\epsilon=0.05$ 的限制，评估了 ET-BERT 模型在面对超出训练预期的

更强扰动时的鲁棒准确率变化。我们将扰动半径 ϵ 的取值范围设定为四个梯度：0.05 标准扰动、0.10 强扰动、0.15 破坏性扰动及 0.20 极强扰动，对比了 PGD-AT、Adv-LoRA、DiffPurify、CAT 以及本文 DS-RGO 的鲁棒准确率衰减轨迹。




图 3-9 不同扰动半径下的模型鲁棒性敏感度分析

图 3-9 显示，随扰动半径 ϵ 增大，各防御模型性能均衰退，但溃散阈值差异显著。PGD-AT 在 $\epsilon=0.10$ 时鲁棒准确率大幅下跌；Adv-LoRA 在 $\epsilon=0.05$ 时表现优异， $\epsilon=0.15$ 时性能降至 28.5%；DiffPurify 在 $\epsilon=0.20$ 时效果失效；CAT 抗衰减性较好但极端扰动下类间边界仍被突破。DS-RGO 衰减最平缓防御下线最高： $\epsilon=0.15$ 时精度 56.2%， $\epsilon=0.20$ 时仍有 45.8%识别率，证实其二阶优化机制构建宽阔决策间隔，赋予模型抵御大幅流量变形的泛化裕度。

3.6.7 细粒度类别防御效果分析

在加密流量分类任务中，不同业务类别往往表现出高度相似的流量统计特征，这对模型在对抗环境下的细粒度判别能力提出了严峻挑战。为了探究本文方法在解决细粒度高混淆类别及长尾分布问题上的潜力，本节基于 CP-Full 数据集，重点剖析 DS-RGO 在 PGD-20 强对抗攻击下的具体业务场景防御效能。

鉴于 CP-Full 数据集包含多达 60 个细粒度类别，全量混淆矩阵存在严重的视觉信息过载。为清晰揭示模型在极端长尾分布下的判别效能，本节依据基准模型的前期测试结果，提取了 Top-10 最易混淆的难分样本对进行局部混淆矩阵的可视化呈现。




图 3-10 DS-RGO 模型在强攻击下的细粒度分类混淆矩阵

图 3-10 混淆矩阵表明，DS-RGO 对极度相似的细粒度流量具备稳健防御性。社交图文应用 Facebook 与 Instagram 强攻击下召回率超 93%，误报极低，证实博弈训练识别其强语义指纹。应对底层特征重叠的同类应用如 WhatsApp 等即时通讯类、YouTube 等流媒体类，传统对抗训练易交叉误判，而 DS-RGO 虽存在局部混淆，仍保持各应用 88%~94% 的极高召回率，鲁棒韧性突出。

这证实 Stackelberg 博弈梯度与 DS 机制结合，可保护高混淆类别决策边界，避免细微特征被噪声抹除，驱动模型挖掘底层时序语义差异，实现细粒度分类高鲁棒性。

3.6.8 面向真实物理受限环境的逃逸鲁棒性验证

前述基准实验已充分验证了模型在连续特征空间中的理论防御上限。为进一步印证防御机制向真实物理网络的映射有效性，本节设计了面向真实网络环境的物理离散规避验证实验。考虑到攻击者或流量混淆工具在物理链路中的实际操作受限于底层网络协议栈的状态机，其无法对流量字节进行任意梯度的连续修改。因此，本实验选取了现网中最常见、最具挑战性的数据包随机填充作为物理逃逸模拟。

实验在 CP-Full 数据集上全量展开。采用控制变量法，分别在应用层载荷尾部离散注入低强度 16-64 字节、中强度 128-256 字节与高强度 512 字节及以上的无意义 Hex 噪声。该操作精准模拟真实对抗中，攻击者企图通过篡改数据包长度序列与统计分布来规避深度包检测的典型行为。各模型在不同物理攻击强度下的鲁棒性演化如图 3-11 所示。




图 3-11 面向真实物理受限环境的逃逸鲁棒性验证

图 3-11 显示，四种模型在干净流量下基准分类性能优异，但面对物理特征偏移时差异明显。Standard 模型高强度混淆下准确率降至 31.0%，防御失效；PGD-AT 准确率降至 58.4%，难以适应高对抗现网环境；CAT 模型在中强度填充下准确率 81.2%，极端物理覆盖下跌至 69.8%。

DS-RGO 表现出稳健的跨域降维防御能力，512 字节高强度物理逃逸混淆下，其准确率仍达 88.5%，全场景性能波动低于 6.5%。这实证了 DS-RGO 通过 Stackelberg 博弈进行平坦化寻优，具备应对低维离散填充攻击的安全冗余与泛化能力，闭环理论假设，验证其工业落地可行性。

3.7 本章小结

本章针对加密流量分析模型在对抗样本攻击下的鲁棒性缺失问题，以及传统对抗训练在大规模参数优化中存在的收敛困难，提出了一种基于动态难度调度与二阶反应梯度优化的抗逃逸训练方法（DS-RGO）。首先，通过构建 Stackelberg 主从博弈模型，利用双层优化理论显式计算攻击者对防御策略的最佳反应梯度，引导模型参数收敛至全局更优的均衡点。其次，针对非凸优化曲面导致的梯度震荡问题，设计了动态课程难度调度机制，通过由弱至强的渐进式攻击策略平滑了损失曲面，有效解决了强对抗环境下的模型崩塌难题。

最后，在 Cross-Platform2022(App60)基准数据集上的实验结果表明，DS-RGO 方法在不同骨干网络上均展现出显著的防御性能，相比 FreeLB、CAT、Adv-LoRA、DiffPurify 等基线方法，其对抗鲁棒性提升了 4.2%~8.6%，且成功消除了训练过程中的 Loss 震荡现象。可视化分析进一步验证了该方法能促使模型聚焦于具有语义不变性的核心协议特征，从根本上提升了抗干扰能力。尽管该方法显著增强了安全性，但其计算开销依然巨大，针对这一效率瓶颈，第四章将提出流样本过滤与缓存复用的高效训练框架，以实现防御性能与训练效率的 Pareto 最优。

第四章 基于动态流过滤与自适应缓存复用的高效训练方法

4.1 引言

上一章提出的 DS-RGO 方法虽显著提升了模型的抗逃逸能力，但高强度的对抗迭代引发了计算开销的指数级增长。深入剖析发现，该算力瓶颈根源于对抗训练中的时空双重冗余：空间上，长尾分布导致大量简单样本被无效计算；时间上，扰动在相邻轮次间的慢变性被忽略。

为此，本章提出基于动态流过滤与自适应缓存复用的高效训练方法（Dynamic Flow Filtering and Adaptive Cache Reuse, DF-ACR）。该方法在空间维度基于动态重要性剔除冗余样本，在时间维度通过扰动缓存与变长序列对齐机制实现历史信息复用。实验表明，DF-ACR 在保证同等防御精度的前提下，能够将训练速度提升 4.6 倍，显著降低了显存峰值占用。

需要指出的是，该效率瓶颈具有显著的模型特异性。鉴于轻量级模型 CNN 单次前向传播耗时极短，效率瓶颈并不突出，强行引入复杂加速机制反增调度开销。而 ET-BERT 等大规模预训练模型才是算力消耗的重灾区，也是急需效率优化的对象。从架构特性来看，流量数据变长序列带来的无效 Padding 问题，主要制约的是基于 Transformer 架构的模型效率，而对基于局部卷积的 CNN 影响较小。

基于上述考量，本章的研究对象将不再包含轻量级 CNN 模型，而是聚焦于计算密集型的 ET-BERT 模型。旨在解决此类大模型在对抗训练中面临的时间维度计算冗余与空间维度显存浪费双重难题。

4.2 问题定义与优化目标

在介绍 DF-ACR 的具体实现之前，本节首先对加密流量对抗训练的计算复杂度进行数学建模，并形式化定义基于流样本的时空联合优化问题。

4.2.1 对抗训练计算复杂度的数学建模

设加密流量数据集 D 包含 N 个流样本。对于基于梯度下降的深度学习训练，一个 Epoch 的总计算成本 C_{total} 主要由前向传播、反向传播以及梯度攻击生成三部分组成。

（1）标准训练的成本

对于基座模型，单次前向传播耗时记为 C_{fwd} ，反向传播耗时记为 C_{bwd} 。标准训练仅在干净数据上进行，其单轮成本为：

$$C_{ST} = N \cdot (C_{fwd} + C_{bwd}) \quad (4.1)$$

（2）标准对抗训练的成本

在 PGD 对抗训练中，对于每个样本，在参数更新前需要进行 K 步 PGD 迭代以生成对抗扰动。每一步 PGD 包含一次前向传播和一次关于输入的梯度计算。因此单轮成本激增为：

$$C_{PGD} \approx N \cdot \left[\underbrace{(C_{fwd} + C_{bwd})}_{\text{Parameter Update}} + \underbrace{K \cdot (C_{fwd} + C_{bwd})}_{\text{Perturbation Generation}} \right] = (K+1) \cdot C_{ST} \quad (4.2)$$

对于 ET-BERT 模型，由 Transformer 的自注意力机制计算复杂度较高，当 K 通常取 3 到

10 时，训练时间将增加数倍，导致在大规模数据集上训练变得极其冗长。

(3) DF-ACR 的预期成本

本文提出的 DF-ACR 方法旨在通过两个维度降低 C ：

空间维（流过滤）：引入过滤比例 $\rho \in (0, 1]$ ，仅对 $N \cdot \rho$ 个高价值样本进行对抗训练。

时间维（缓存复用）：引入缓存更新周期 T_c ，使得攻击生成的平均次数从 K 降至 $\frac{K}{T_c}$ 。

优化后的理论成本模型为：

$$C_{DF-ARTC} \approx N \cdot \left[(C_{fwd} + C_{bwd}) + \rho \cdot \frac{K}{T_c} \cdot (C_{fwd} + C_{bwd}) \right] \quad (4.3)$$

显然，通过调节超参数 ρ 和 T_c ，可以显著降低计算开销。

4.2.2 效率与鲁棒性的权衡关系

高效训练的核心挑战在于减少计算量通常会导致鲁棒性下降。需要寻找 Pareto 最优解。

定义 $R(\theta)$ 为模型在测试集上的抗逃逸准确率。目标不是单纯最小化成本，而是满足鲁棒性约束的前提下最小化成本，或者在固定计算预算下最大化鲁棒性。这是一个约束优化问题：

$$\max_{\theta, \rho, T_c} R(\theta) \quad \text{s.t.} \quad C(\rho, T_c) \leq C_{budget} \quad (4.4)$$

其中 C_{budget} 是实际工程环境所允许的最大计算预算。

此外，面对大规模预训练模型高昂的计算开销，当前工业界与学术界提升效率的常规手段多依赖于网络剪枝或权重量化等物理层面的模型压缩技术。然而，结合加密流量对抗攻防的特殊场景，本文并未采纳这种结构瘦身策略。其根本原因在于，模型对逃逸攻击的鲁棒性高度依赖于其在非凸优化曲面上寻找到的平坦极小值。直接对大参数模型进行剪枝，极易破坏这些脆弱的深层拓扑结构，导致防御边界失效与鲁棒准确率的衰退；同时，粗粒度的压缩往往会导致模型丢失对长尾分布特征的捕获能力。因此，本文旨在提出一种算法级轻量化理念，即在不改变 ET-BERT 原始网络结构与理论容量的前提下，通过剔除训练与动态更新过程中的时空计算冗余，实现一种保证抗逃逸能力的轻量化加速方案。

4.2.3 基于流样本的时空联合优化问题定义

为了求解上述权衡问题，我们将 DF-ACR 建模为一个时空联合优化过程。

(1) 空间选择变量

引入二值指示变量 $m_i^{(t)} \in \{0, 1\}$ ，表示在第 t 轮训练中是否选中流样本 x_i 进行对抗正则化。该变量由重要性评估函数 $S(x_i)$ 决定：

$$m_i^{(t)} = \mathbb{I}(S(x_i) \geq \tau_t) \quad (4.5)$$

其中 $\mathbb{I}(\cdot)$ 为示性函数， τ_t 为动态过滤阈值。

(2) 时间复用变量

引入缓存变量 $\delta_{i, \text{cache}}$ 。在第 t 轮，若满足条件则直接使用 $\delta_{i, \text{cache}}$ ；否则重新计算更新缓存。

(3) 联合优化目标函数

DF-ACR 的最终训练目标是 minimize 以下混合损失函数：

$$\min_{\theta} \sum_{t=1}^T \sum_{i=1}^N \left[\underbrace{L(f_{\theta}(x_i), y_i)}_{\text{Clean Loss (All Samples)}} + \lambda \cdot m_i^{(t)} \cdot \underbrace{L(f_{\theta}(x_i + \delta_i^{(t)}), y_i)}_{\text{Robust Loss (Selected Samples)}} \right] \quad (4.6)$$

其中，对抗扰动 $\delta_i^{(t)}$ 的来源由缓存策略决定：

$$\delta_i^{(t)} = \begin{cases} \text{PGD}(x_i, y_i, \theta) & \text{if } t \pmod{T_c} = 0 \text{ (Update)} \\ \delta_{i, \text{cache}}^{(t-1)} & \text{otherwise (Reuse)} \end{cases} \quad (4.7)$$

该目标函数表明，我们始终保证模型学习所有流样本的基本分类特征，以维持基准识别率；同时，仅针对被筛选出的关键流样本注入对抗噪声，并利用缓存减少噪声生成的频率。这种策略在数学上等价于一种非均匀、稀疏采样的对抗正则化。

4.3 DF-ACR 方法框架设计

本节提出了一种基于动态流过滤与自适应缓存复用的高效训练方法 DF-ACR。下文将依次从总体结构、空间维度的动态流过滤（DF 模块），以及时间维度的自适应缓存复用（ACR 模块）三个方面展开详细论述。

4.3.1 总体结构

针对大规模加密流量对抗训练中存在的时空双重冗余问题，本章提出基于动态流过滤与自适应缓存复用的高效训练方法 DF-ACR，构建了一个紧密耦合的双层级联架构，分别在空间维度剔除低价值样本，在时间维度复用历史扰动，DF-ACR 的整体工作流程如图 4-1 所示。




图 4-1 DF-ACR 方法整体框架图

如图 4-1 所示，该架构包含两个级联的决策模块，共同决定每个流样本的计算路径：

第一级：空间过滤门控。这是系统的粗筛阶段。依据流样本的动态重要性评分 $S(x)$ ，将当前 Batch 的数据划分为关键样本集(Critical Set, D_{crit})与冗余样本集(Redundant Set, D_{redund})。

第二级：时间缓存复用机制。这是系统的精简阶段。针对通过初筛的关键样本，系统维护一个外部扰动记忆库。依据慢变性假设，以懒惰更新的方式决定是重新计算昂贵的 PGD 攻击，还是直接复用历史扰动。

下文将分别阐述这两个级联模块的核心原理与实现策略。

4.3.2 基于动态重要性的数据过滤机制

本节阐述 DF-ACR 方法中的 DF 模块，对应级联架构的第一级空间优化阶段。

在加密流量分类任务中，样本分布呈现显著的长尾特性与不均匀性。例如，部分大颗粒度的流媒体流量（如 YouTube 与 Netflix）其周期性突发传输模式较为固定，模型极易以高置信度识别；而采用端到端强混淆加密的即时通讯流量（如 WhatsApp 与 Telegram）其底层时序特征高度相似，极易产生语义重叠，往往紧密聚集在分类决策边界附近，属于典型的难样本。为了精准区分这两类样本，本节提出了一种融合预测不确定性与对抗敏感性的多维动态重要性评分机制 $S(x)$ ，并依据该评分对流样本进行分级处理。

（1）多维重要性度量指标

为了全面评估样本对抗训练的贡献度，本文定义了以下两个维度的评价分量：

1. 基于损失值的难易度度量 S_{loss} ：分类损失函数 L 直接反映了模型当前对样本 x 的拟合程度。损失值越大，表明模型无法通过现有的特征提取器正确分类该流量，该样本属于难样本，定义如下：

$$S_{loss}(x_i) = L_{CE}(f_{\theta}(x_i), y_i) = -\log p(y_i | x_i; \theta) \quad (4.8)$$

其中， $p(y_i | x_i)$ 是模型输出在真实标签 y_i 上的置信度。

对于特征明显的简单流量模型通常会给出接近 1.0 的置信度，导致 $S_{loss} \approx 0$ ；而特征模糊的混淆流量，置信度较低， S_{loss} 较大，意味着需要通过对抗训练来强化其特征边界。

2. 基于梯度范数的鲁棒敏感度度量 S_{grad} ：仅凭损失值无法完全衡量样本价值。有些样本虽然当前分类正确，但其位于决策边界极近位置，微小的扰动就能导致误判。这种特性由输入梯度的范数来刻画，定义如下：

$$S_{grad}(x_i) = \|\nabla_h L(f_{\theta}(x_i), y_i)\|_h \quad (4.9)$$

这里 h 表示模型的第一层连续输入表示：

对于 ET-BERT， h 对应 Embedding 层的输出张量 $E \in R^{L \times d}$ 。

对于 CNN， h 对应输入的归一化像素矩阵 $x \in R^{H \times W}$ 。

梯度范数 $\|\nabla_h L\|_2$ 衡量了损失函数相对于输入的敏感程度。 S_{grad} 越大，意味着该流量样本对扰动越敏感，攻击者只需极小的代价 δ 就能大幅增加 Loss。这类样本是提升模型抗逃逸能力的关键支撑向量，必须赋予高优先级。

（2）基于历史复用的评分模型

在实际训练中，为了计算 S_{grad} 而进行一次实时的反向传播会带来额外的计算开销，这违背高效训练的初衷。为此，本文采用历史信息复用策略：利用样本在上一轮缓存的梯度范数

来近似当前的重要性。最终的流样本重要性评分 $S(x_i)$ 定义为归一化后的加权和：

$$S(x_i)^{(t)} = \gamma \cdot \frac{S_{loss}(x_i)^{(t)}}{\mu_{loss}^{(t)}} + (1 - \gamma) \cdot \frac{S_{grad}(x_i)^{(t-1)}}{\mu_{grad}^{(t-1)}} \quad (4.10)$$

其中， t 表示当前训练轮次， μ_{loss} 和 μ_{grad} 分别是当前 Batch 或整个数据集的指标均值，用于消除量纲差异， $\gamma \in [0, 1]$ 是平衡系数，实验中通常设为 0.5。

通过该指标，DF-ACR 能够动态地将数据集划分为关键样本集 D_{crit} 与冗余样本集 D_{redund} ，其划分原理如图 4-2 所示。




图 4-2 基于重要性的流样本动态过滤示意图

如图 4-2 所示，算法设定动态阈值 $\text{Top-}\rho$ ，对左侧的高价值难样本进行强化，从而在大幅削减计算量的同时保持抗逃逸性能。

(3) 差异化过滤策略

如图 4-2 的底部决策分支所示，针对被判定为冗余样本集 D_{redund} 的数据，为了适应不同的资源限制场景，本节设计了两种差异化的处理模式：

1. 软过滤模式：对冗余样本仅跳过开销巨大的对抗攻击步骤，但保留其参与标准分类训练，其目标函数为：

$$L_{total} = \sum_{x \in D_{crit}} (L_{clean} + \lambda L_{adv}) + \sum_{x \in D_{redund}} L_{clean} \quad (4.11)$$

利用 Toneva 的遗忘事件理论，防止模型因长期不接触简单样本而导致自然准确率下降。适合对精度要求极高的场景。

2.硬过滤模式：直接将冗余样本从计算图中物理剔除，不参与任何前向或反向传播。其目标函数为：

$$L_{total} = \sum_{x \in D_{crit}} (L_{clean} + \lambda L_{adv}) \quad (4.12)$$

实现了 I/O 读取与 GPU 浮点运算的双重物理加速，极大提升吞吐量。适合资源极度受限或追求极致训练速度的场景。

(4) 机制分析：计算负载的动态均衡

上述基于动态重要性的过滤机制还隐式地实现了计算负载的自适应调节。

训练初期，由于模型尚未收敛，大部分样本的 Loss 较高，导致 $S(x)$ 普遍高于阈值 $\text{Top-}\rho$ 。此时系统倾向于进行全量训练，有助于快速巩固模型基础。

训练后期，随着训练深入，大部分简单样本的 Loss 趋近于零，被划入 D_{redund} 的比例大幅增加。系统自动进入稀疏训练模式，显著降低计算量。

这种前紧后松的动态特性与深度学习先学习简单模式，后攻克困难模式的训练规律完美契合，在保证收敛质量的同时最大化了整体训练速度。

4.3.3 基于流量缓存的复用机制

本节阐述 DF-ACR 方法中的 ACR 模块，对应级联架构的第二级时间优化阶段。

经过第一级空间门控筛选后，只有位于决策边界附近的高价值关键样本集 D_{crit} 会进入本阶段。对于这些样本，如果依然在每一轮训练中都执行完整的 PGD-K 迭代攻击，计算开销仍庞大。

为此，本节引入时间维度的优化策略。基于深度神经网络参数更新的慢变性假设，构建外部扰动记忆库，通过一次生成、多次复用的机制，大幅降低反向传播的频率。

(1) 外部记忆库与慢变性假设

相关研究表明，在模型训练的中后期，参数 θ 的更新步长通常较小，导致最优对抗扰动 δ^* 在特征空间中的演变轨迹呈现出显著的时间连续性。这意味着，上一轮生成的扰动对于当前轮次的模型而言，依然是一个极佳的近似攻击点。

基于此，系统维护一个与训练集大小一致的外部记忆库 M ，用于持久化存储每个流样本的历史最佳扰动：

设训练集 D 包 N 个样本，记忆库定义为键值对集合：

$$M = \{(\text{id}_i, \delta_i^{cache})\}_{i=1}^N \quad (4.13)$$

其中， id_i 是流样本的唯一索引， δ_i^{cache} 是该样本上一次生成的对抗扰动张量。

对于 ET-BERT 模型： $\delta_i^{cache} \in R^{L_{max} \times D}$ ，存储 Embedding 层的扰动向量，其中 L_{max} 是预处理时设定的最大序列长度， D 是隐藏层维度。

(2) 针对 ET-BERT 的变长序列对齐机制

在 ET-BERT 训练中，为了提高并行效率，通常在一个 Batch 内将所有流序列填充到该 Batch 的最大长度 L_{batch} ，而非全局最大长度 L_{max} 。这导致同一个流样本在不同 Batch 中的张量

形状可能不同,无法直接与缓存交互。为此,我们设计了静态存储-动态对齐策略,其原理如图 4-3 中间部分所示:




图 4-3 扰动缓存的更新与复用状态机制图

静态存储: 缓存 M 始终以全局最大长度 L_{max} 存储扰动。对于实际长度 $l_i < L_{max}$ 的流, 其缓存中索引 $[l_i, L_{max})$ 的区域被置为零或忽略。

动态读取: 当样本 x_i 被加载到当前 Batch 时, 系统根据其当前的 Padding Mask $M_i \in 0, 1^{L_{batch}}$ 从缓存中切片并读取对应部分的扰动:

$$\delta_i^{batch} = \text{Slice}(M[id_i], 0, L_{batch}) \odot M_i \quad (4.14)$$

动态写入: 当重新生成新扰动 δ_i^{new} 后, 将其写回缓存的对应位置, 并保持缓存中超出实际长度的部分不变。

(3) 状态流转与加速逻辑

为了最大化加速比, 我们引入缓存更新周期 T_c 。对于第 t 个训练 Epoch 中的样本 x_i , 其扰动 $\delta_i^{(t)}$ 的获取逻辑如下:

$$\delta_i^{(t)} = \begin{cases} \text{Generate}(x_i, y_i; \theta_t) & \text{if } t \pmod{T_c} = 0 \text{ or } id_i \notin M \\ M[id_i] & \text{otherwise} \end{cases} \quad (4.15)$$

更新阶段 (Update Phase, $t \% T_c == 0$): 攻击者执行完整的 PGD-K 攻击, 计算当前最优扰动, 并刷新缓存。此时计算开销较大。

复用阶段 (Reuse Phase, $t \% T_c != 0$): 直接从 M 读取扰动, 跳过 PGD 过程, 仅执行一次

对抗前向传播和反向传播。此时计算开销近似于标准训练。

通过这种一次生成，多次复用的策略，在 T_c 个周期内，原本需要 $T_c \times K$ 次梯度攻击计算，被缩减为 $1 \times K$ 次，理论加速比接近 T_c 倍。

4.4 算法实现与模型适配

本节将 DF-ACR 方法的理论框架转化为具体的算法执行流程，并针对 ET-BERT 的模型特性给出适配方案。

4.4.1 DF-ACR 训练算法流程

DF-ACR 算法的核心逻辑是在训练循环中动态维护一个活跃样本集和一个对抗扰动缓存库。算法在每一轮迭代中，首先根据流特征的重要性评分筛选出高价值样本，然后利用缓存机制复用历史对抗信息，从而最大限度地减少昂贵的梯度反向传播次数。

我们将该过程形式化为算法 4.1：

表 4-1 DF-ACR 算法

算法 4.1 DF-ACR 算法

输入：

加密流量训练数据集 $D=(x_i, y_i, id_i)_{i=1}^N$
 分类器模型 $f(\cdot; \theta)$ ，初始参数 θ_0
 效率超参数：过滤保留比例 $\rho \in (0, 1]$ ，缓存更新周期 T_c
 对抗超参数：扰动半径 ϵ ，攻击步数 K ，步长 α ，正则化系数 λ

输出：

高效鲁棒模型参数 θ^*

1 初始化

2 初始化扰动缓存库 $M \leftarrow \emptyset$

3 初始化模型参数 $\theta \leftarrow \theta_0$

4 初始化训练轮次 $t \leftarrow 1$

5 迭代训练过程：

6 While $t \leq T_{total}$ do:

7 For each batch $B=(X, Y, IDs)$ sampled from D do:

8 步骤 1：重要性评估

9 计算批次内每个样本的重要性评分 S :

10 $S(x) \leftarrow \gamma \cdot L \cdot CE(f(x; \theta), y) + (1 - \gamma) \cdot |\nabla \cdot xL|$

11 步骤 2：空间过滤

12 计算动态阈值: $\tau \leftarrow \text{Quantile}(S, 1 - \rho)$

13 划分关键样本集: $I_{crit} \leftarrow \{i \in B \mid S(x_i) \geq \tau\}$

14 划分冗余样本集: $I_{redund} \leftarrow \{j \in B \mid S(x_j) < \tau\}$

15 步骤 3：缓存交互与损失计算

16 初始化总损失 $L_{total} \leftarrow 0$

17 3.1 处理关键样本

18 For $i \in I_{crit}$ do:

19 If $t \pmod{T_c} = 0$ or $id_i \notin M$ then

20 [更新模式]: 执行 PGD 攻击生成新扰动

21 $\delta_{new} \leftarrow \text{PGD}(x_i, y_i, \theta; K, \epsilon, \alpha)$

22 写入缓存: $M[id_i] \leftarrow \delta_{new}$

23 $\delta_i \leftarrow \delta_{new}$

24 Else

25 [复用模式]: 读取历史扰动

```

26           $\delta_i \leftarrow M[id_i]$ 
27      End If
28      累计对抗损失:
29           $L*total \leftarrow L*total + L*CE(f(x_i; \theta), y_i) + \lambda \cdot L*CE(f(x_i + \delta_i; \theta), y_i)$ 
30      End For
31      3.2 处理冗余样本
32      For  $j \in I_{redund}$  do:
33          累计原始损失:  $L*total \leftarrow L*total + L_{CE}(f(x_j; \theta), y_j)$ 
34      End For
35      步骤 4: 参数更新
36      计算梯度:  $G \leftarrow \nabla_{\theta} L_{total}$ 
37      更新参数:  $\theta \leftarrow \theta - \eta \cdot G$ 
38      End For (Batch)
39       $t \leftarrow t + 1$ 
40  End While
41 返回结果
42  Return  $\theta^* \leftarrow \theta$ 

```

4.4.2 针对 ET-BERT 的具体实现细节

ET-BERT 模型基于 Transformer 架构，将加密流量数据包序列视为自然语言文本进行处理。与图像数据固定的 $H \times W$ 维度不同，流量序列具有显著的变长特性。这给基于缓存的 DF-ACR 算法带来了张量对齐的工程挑战。

本节详细描述如何构建适配 ET-BERT 的规范化缓存-动态切片机制。

(1) 规范化扰动存

为了统一管理不同长度流样本的对抗信息，我们在缓存库 M 中采用全局最大长度作为存储标准。

设预处理阶段设定的最大序列长度为 L_{max} ，隐藏层维度为 D 。对于任意流样本 x_i ，无论其真实有效长度 l_i 是多少，其在缓存中的扰动 δ_i^{cache} 始终被初始化并存储为固定形状的张量：

$$\delta_i^{cache} \in R^{L_{max} \times D} \quad (4.16)$$

其中，索引区间 $[l_i, L_{max})$ 的部分被置为零向量，不携带任何梯度信息。

(2) 动态批次对齐与读写

在训练过程中，为了最大化 GPU 并行效率，ET-BERT 通常采用动态批处理策略，即当前 Batch 的张量长度 L_{batch} 取决于该 Batch 中最长的样本，通常 $L_{batch} \leq L_{max}$ 。

DF-ACR 实现了如下的动态对齐读写逻辑：

读取对齐：当样本 x_i 被加载到当前 Batch 时，首先根据其唯一索引 id_i 从缓存中检索出 δ_i^{cache} 。然后，执行切片操作以匹配当前 Batch 的维度：

$$\delta_i^{batch} = \delta_i^{cache}[0 : L_{batch}, :] \quad (4.17)$$

此操作利用了 PyTorch 的张量视图机制，零拷贝且高效。

写入对齐：在更新模式下，PGD 攻击生成的扰动 δ_i^{new} 长度为 L_{batch} 。在写入缓存前，需要对其进行零填充扩展：

$$\delta_i^{store} = \text{Pad}(\delta_i^{new}, L_{max}) \quad (4.18)$$

随后更新 $M[id_i] \leftarrow \delta_i^{store}$ 。

(3) 基于掩码的梯度隔离

在计算对抗损失 L_{adv} 时，必须防止对抗扰动落到无意义的 Padding 区域，否则会导致模型学习到虚假的噪声模式。

我们利用 BERT 的 Attention Mask ($M \in \{0,1\}^{B \times L_{batch}}$) 对取出的缓存扰动进行严格过滤。对抗样本的嵌入表示 E_{adv} 计算如下：

$$E_{adv} = E_{clean} + (\delta^{batch} \odot M) \quad (4.19)$$

其中 $\odot$ 表示逐元素乘法。该操作确保了对于 Padding Token ($M_{ij}=0$)，其叠加的扰动恒为零，保证了对抗训练聚焦于有效的流量载荷特征。

(4) 显存优化策略

由于 M 需要存储整个训练集的扰动张量，显存开销较大。工程实现上，我们将缓存库 M 驻留在 CPU 内存中。仅在每个 Batch 数据加载阶段，利用多线程预取技术将所需的 δ 异步传输至 GPU 显存。实验表明，这种 IO-Compute 重叠策略使得数据传输延迟几乎可忽略不计。

4.5 理论分析

本节从理论层面定量分析 DF-ACR 方法的时间复杂度。通过对比标准对抗训练与 DF-ACR 在单轮训练中的浮点运算次数，推导理论加速比公式，给出轻量化证明，并探讨时空近似计算下的模型收敛性。

4.5.1 时空复杂度与算法级轻量化证明

为了简化分析模型，我们忽略数据加载和简单的张量加减运算开销，主要关注神经网络中计算密集的前向传播和反向传播操作。

(1) 符号定义与基准成本

设数据集包含 N 个流样本。定义单位计算成本如下：

C_{fwd} : 模型进行一次前向传播的计算量。

C_{bwd} : 模型进行一次反向传播的计算量。通常假设 $C_{bwd} \approx 2C_{fwd}$ 。

$C_{unit} = C_{fwd} + C_{bwd}$: 完成一次标准参数更新的总成本。

(2) 基线方法：PGD-AT 的计算复杂度

在标准的 PGD-K 对抗训练中，对于每个样本，在进行参数更新前，必须先执行 K 步梯度迭代以生成对抗扰动。

攻击生成阶段：需要 K 次前向传播和 K 次输入梯度计算，近似为 $K \times C_{unit}$ 。

参数更新阶段：需要 1 次前向传播和 1 次反向传播。

因此，PGD-AT 单个 Epoch 的总计算复杂度为：

$$C_{PGD} = N \cdot \left[\underbrace{K \cdot C_{unit}}_{\text{Attack Generation}} + \underbrace{C_{unit}}_{\text{Parameter Update}} \right] = N \cdot (K + 1) \cdot C_{unit} \quad (4.20)$$

显然，训练成本随攻击步数 K 线性增长。对于 ET-BERT，当 $K=10$ 时，训练时间约为普通训练的 11 倍。

(3) DF-ACR 的计算复杂度

DF-ACR 通过空间过滤和时间缓存两个维度削减计算量。我们假设采用软过滤策略，即

所有样本计算 Clean Loss，仅关键样本计算 Adversarial Loss。

空间维 (ρ)：仅 $\rho \cdot N$ 个关键样本参与对抗计算。

时间维 (T_c)：在 T_c 个 Epoch 周期内，仅有 1 次执行 PGD-K 攻击，其余 T_c-1 次直接复用缓存。

平均单轮对抗计算成本 $\bar{C}_{adv}$ 为：

$$\bar{C}_{adv} = \frac{1}{T_c} \underbrace{(K \cdot C_{unit})}_{\text{Update Mode}} + \frac{T_c - 1}{T_c} \underbrace{(0)}_{\text{Reuse Mode}} = \frac{K}{T_c} \cdot C_{unit} \quad (4.21)$$

复用模式下，仅需读取缓存张量，前向传播已包含在参数更新步骤中，故生成成本近似为 0。

DF-ACR 单个 Epoch 的总计算复杂度为：

$$\begin{aligned} C_{DF-ARTC} &= \underbrace{N \cdot C_{unit}}_{\text{Clean Update (All)}} + \underbrace{(\rho \cdot N) \cdot (\bar{C}_{adv} + C_{unit})}_{\text{Adversarial Part (Critical Only)}} \\ &= N \cdot C_{unit} \cdot \left[1 + \rho \left(1 + \frac{K}{T_c} \right) \right] \end{aligned} \quad (4.22)$$

其中，第一项是全量数据的标准训练开销，第二项是关键样本的对抗训练开销。

(4) 理论加速比推导

定义加速比 S 为基线成本与优化方法成本之比：

$$S = \frac{C_{PGD}}{C_{DF-ARTC}} = \frac{(K+1)}{1 + \rho \left(1 + \frac{K}{T_c} \right)} \quad (4.23)$$

极限情况分析：

情况 A：仅使用缓存， $T_c \rightarrow \infty, \rho=1$

$$S_{cache} \approx \frac{K+1}{2} \quad (4.24)$$

当 K 较大时，加速比趋近于 $K/2$ 。例如 $K=10$ 时，加速比约为 5.5 倍。这表明仅仅复用梯度就能带来显著收益。

情况 B：仅使用过滤， $T_c=1, \rho \rightarrow 0$

$$S_{filter} \approx \frac{K+1}{1} = K+1 \quad (4.25)$$

如果过滤掉绝大多数样本，速度接近普通训练。但这也意味着对抗鲁棒性可能完全丧失，因此 ρ 不能过小。

情况 C：联合优化，典型配置 $\rho=0.5, T_c=5, K=10$

$$S_{joint} = \frac{11}{1 + 0.5 \times (1+2)} = \frac{11}{2.5} = 4.4 \quad (4.26)$$

通过上述公式可以看出，DF-ACR 在保留了全量数据 Clean Loss 和 50% 难样本对抗训练的前提下，理论上能将训练速度提升 4 倍以上。这使得在单 GPU 上训练大规模加密流量模型成为可能。

综上数学推导证明，DF-ACR 方法通过对数据流的空域截断与时域复用，实现了对浮点

运算数与显存占用的双重下界约束。这种在数学本质上不损失模型理论容量的优化，为大规模模型提供了坚实的算法级轻量化理论支撑。

4.5.2 时空近似计算下的模型收敛性分析

DF-ACR 方法本质上是一种近似计算策略。相比于标准的全量对抗训练，它引入了两类误差来源：由空间过滤引起的采样偏差和由时间缓存引起的梯度陈旧性。本节基于随机梯度下降理论，定性分析为何在引入这些近似后，模型依然能够稳定收敛。

(1) 空间过滤的收敛性：基于重要性采样的视角

在 DF-ACR 中，我们丢弃了 $1-\rho$ 比例的简单样本，仅利用关键样本集 D_{crit} 更新参数。这在数学上等价于一种非均匀重要性采样。

设原始对抗目标函数的真实梯度为 $E[\nabla L]$ 。DF-ACR 的梯度估计 $\hat{g}$ 可以看作是针对于难样本的加权估计。

在深度学习训练后期，大部分简单样本的梯度范数接近于零 $|\nabla L_{easy}| \approx 0$ ，它们对参数更新方向的贡献极小，主要表现为随机噪声。剔除这些样本，实际上过滤了无效的梯度噪声，使得优化器更加专注于能够显著降低 Loss 的正交方向。

对抗训练的目标本质上是优化最坏情况。根据 Min-Max 理论，决策边界主要由支持向量决定。只要 D_{crit} 包含了所有的支持向量，DF-ACR 的优化轨迹将渐进收敛于全量训练的轨迹。

(2) 时间缓存的收敛性：基于慢变性与有界误差假设

缓存机制的核心风险在于使用了陈旧的扰动 $\delta^{(t-\tau)}$ 来近似当前时刻的最优扰动 $\delta^{(t)}$ 。我们需要证明这种近似误差是有界的。

假设 1 (Lipschitz 连续性)： 假设对抗扰动生成函数 $\delta^*(\theta)$ 关于模型参数 θ 是 Lipschitz 连续的，即存在常数 L ，使得 $|\delta^*(\theta_1) - \delta^*(\theta_2)| \leq L|\theta_1 - \theta_2|$ 。

在 DF-ACR 的复用阶段，参数更新量 $\Delta\theta$ 受学习率 η 控制。在 T_c 个周期内，参数的累积变化量有界：

$$\|\theta_t - \theta_{t-\tau}\| \approx \sum_{k=1}^{\tau} \eta \|g_k\| \leq \tau \cdot \eta \cdot M \quad (4.27)$$

其中 M 为梯度上界。

结合 Lipschitz 假设，扰动的近似误差 e_{adv} 为：

$$\|\delta^*(\theta_t) - \delta^*(\theta_{t-\tau})\| \leq L \|\theta_t - \theta_{t-\tau}\| \leq L \cdot T_c \cdot \eta \cdot M \quad (4.28)$$

结论：只要学习率 η 足够小且缓存周期 T_c 设定合理，扰动误差就是有界的。在 SGD 优化理论中，这种有界的梯度误差被视为一种正则化噪声。只要梯度估计的期望方向与真实方向的夹角小于 90 度，模型就能保证收敛到局部极小值。实验中 DF-ACR 依然保持高准确率，也反向验证了加密流量对抗扰动具有较强的时间相关性。

4.6 实验评估与分析

本节针对 ET-BERT 模型开展了详尽的实验评估。下文将首先明确实验的基础环境与评估指标，随后围绕方法的综合效率、资源消耗与现存优化等核心维度展开深入剖析。

4.6.1 实验设置

(1) 数据集与数据预处理

为了保持全文实验的一致性与结果的可比性，本章继续沿用第三章所述的 Cross-Platform2022(App60)基准数据集。

数据预处理流程与第三章保持严格一致，确保后续观察到的性能变化完全源于本文提出的 DF-ACR 算法，而非数据处理差异。

(2) 骨干网络选型策略

与第三章验证防御通用性时同时选取 CNN 和 ET-BERT 不同，本章的效率优化实验将聚焦于计算密集型的 ET-BERT 模型。这种差异化选型的依据如下：

计算瓶颈的紧迫性：BUPT-CNN 作为轻量级模型，其训练开销相对可控。相比之下，拥有 1.1 亿参数的 ET-BERT 模型基于 Transformer 架构，其自注意力机制的 $O(L^2)$ 复杂度叠加对抗训练的 K 倍反向传播，导致训练成本呈指数级增长。解决此类大模型的效率瓶颈具有更高的工程价值。

技术适配性：本章提出的 DF-ACR 方法中，核心的对抗扰动缓存策略针对变长序列设计了 Mask 对齐机制。这一机制契合 Transformer 架构对 Padding Token 的处理方式，能够在 ET-BERT 上发挥最大的加速效能。

因此，本章实验将以 ET-BERT 为核心对象，重点考察 DF-ACR 在大规模预训练模型上的加速比与资源节省效果

(3) 对比基准方法

为了验证 DF-ACR 方法在训练效率与防御性能之间的最佳平衡，本文选取了 6 种在该领域具有代表性的方法进行对比，涵盖了从最快速度到最强防御的基线：

Standard：采用标准交叉熵损失进行训练。该方法不涉及任何对抗样本生成步骤，因此具有训练速度的上限和鲁棒性的下限。

PGD-AT^[32]：标准的对抗训练方法。由于每一轮训练都需要 K 次反向传播来生成对抗样本，其计算开销巨大，代表了训练速度的下限，作为效率对比的基准锚点。

Flash-AT^[75]：结合硬件感知与注意力机制优化的极速对抗训练方法。该方法专门针对 Transformer 架构设计，通过底层算子优化缓解了多头注意力计算中的显存读写瓶颈，是当前序列模型在算力层面的加速标杆。

LoFT^[76]：基于低秩适配（LoRA）的高效鲁棒微调框架。该方法放弃了全参数更新，将对抗扰动的生成与参数梯度计算严格约束在极小比例的低秩特征空间中，在极大地降低了计算时间与显存复杂度的同时保持了良好的防御效果。

ME-AT^[77]：内存高效对抗训练（Memory-Efficient AT）。该方法专门针对大规模预训练模型的显存墙瓶颈，通过梯度检查点与自适应片段式反向传播技术，在受限显存环境下实现了高吞吐量的对抗训练，代表了显存与时间统筹优化的前沿。

DF-ACR：本文提出的基于动态流过滤与自适应缓存复用的高效训练方法。

(4) 评价指标与参数设定

为了量化评估训练系统的综合性能，本文定义了以下 4 个核心效率指标：

单轮耗时 (Seconds per Epoch, s/epoch) : 完成一轮全量训练数据的平均时间。

总训练耗时 (Total Training Hours, h) : 模型完成所有 Epoch 训练所需的总时间。

加速比 (Speedup Ratio) : 以 PGD-AT 为基准 1.0×, 计算各方法的相对加速倍数。

显存峰值 (Peak Memory Usage, GB) : 训练过程 GPU 显存占用的最大值。

平均保留率 (Average Retention Rate) : 在动态流过滤机制中, 平均保留率用于量化第 t 个训练轮次 Epoch 下, 针对特定类别 c 的流样本被保留的比例。其计算公式定义如下:

$$\rho_c^{(t)} = \frac{N_{kept,c}^{(t)}}{N_{total,c}} \times 100\% \quad (4.29)$$

其中: $N_{kept,c}^{(t)}$ 表示在第 t 个训练轮次中, 被动态过滤机制判定为重要样本并实际保留用于对抗训练的该类别 c 的流样本数量;

$N_{total,c}$ 表示该类别 c 在全量数据集 CP-Full 中的总样本数量;

$\rho_c^{(t)}$ 的单位为百分比%, 取值范围[0.100]。

为了确保实验的公平性, 所有方法的超参数与环境配置分别列于表 4-2 与表 4-3 中。实验统一在单张 NVIDIA RTX 4090 上进行, 严格控制 Batch Size=32。

表 4-2 实验软硬环境配置

类别	项目	配置参数
硬件环境	GPU	NVIDIA GeForce RTX 4090 (24GB)
	CPU	Intel(R) Xeon(R) Gold 6248R
	Driver	CUDA 11.6 + cuDNN 8.5
软件环境	框架	PyTorch 1.12.1 (FP32 Precision)
	基础库	HuggingFace Transformers 4.21.0

表 4-3 不同训练方法的训练参数设定

方法	关键参数	说明
PGD-AT	$K=3$	内部攻击迭代次数
	$\alpha=0.01, \epsilon=0.05$	攻击步长与扰动半径
Flash-AT	$m=1$	单步快速对抗生成的迭代次数
	RS=true	启用随机初始化噪声
LoFT	$r=8$	低秩适配器的内在秩
	$\alpha_{LoA} = 16$	低秩矩阵特征的缩放比例因子
ME-AT	$N_{ckpt} = 4$	梯度重计算激活时的检查点分段数量
DF-ACR	$\rho_{init} = 1 \rightarrow \rho_{min} = 0.5$	动态流过滤保留比例
	$T_c \in [1,3]$	扰动缓存的自适应更新周期区间
	$\tau=0.7$	难易流样本动态判定的置信度阈值

4.6.2 综合效率与性能对比

为了验证 DF-ACR 方法在训练效率提升与防御性能保持之间的平衡能力，本节在 Cross-Platform2022(App60)数据集的两个异构子集 CP-Mobile 与 CP-Desktop 上，对比了各训练策略在 ET-BERT 骨干网络上的时间开销与最终分类表现。

实验选取了 Standard、PGD-AT、Flash-AT、LoFT、ME-AT 以及本文提出的 DF-ACR 方法进行横向评测。详细的实验数据如表 4-4 和表 4-5 所示。表中单轮耗时指训练一个 Epoch 所需的平均物理时间，总耗时指模型收敛所需的总时间，加速比以 PGD-AT 为基准进行归一化计算。

表 4-4 不同训练方法的时间开销对比

数据集	训练方法	单轮耗时 (s/epoch)	总训练耗时 (h)	加速比
CP-Mobile	Standard	380	2.11	6.5×
	PGD-AT	2470	13.72	1.0×
	Flash-AT	720	4.00	3.4×
	LoFT	510	2.83	4.8×
	ME-AT	850	4.72	2.9×
	DF-ACR	535	2.97	4.6×
CP-Desktop	Standard	410	2.27	6.3×
	PGD-AT	2600	14.44	1.0×
	Flash-AT	760	4.22	3.4×
	LoFT	540	3.00	4.8×
	ME-AT	890	4.94	2.9×
	DF-ACR	565	3.14	4.6×

表 4-5 不同训练方法的分类准确率对比

数据集	训练方法	CleanAcc/Macro-F1	PGD-20Acc/Macro-F1
CP-Mobile	Standard	96.50/95.10	0.05/0.01
	PGD-AT	88.40/86.50	62.20/58.80
	Flash-AT	87.80/85.50	59.50/56.10
	LoFT	91.20/89.80	58.80/54.50
	ME-AT	88.10/86.20	61.50/58.10
	DF-ACR	94.10/93.20	61.60/58.30
CP-Desktop	Standard	97.20/96.30	0.10/0.05
	PGD-AT	89.10/87.20	64.50/61.10
	Flash-AT	88.50/86.40	61.80/58.50
	LoFT	92.10/90.50	61.10/57.20
	ME-AT	88.80/86.90	63.80/60.50
	DF-ACR	94.80/93.90	63.90/60.80

表 4-4 与表 4-5 的实验结果表明，本文提出的 DF-ACR 方法在训练效率和防御性能之间取得了较好的平衡。在时间开销上，传统的 PGD-AT 方法耗时过高，CP-Desktop 数据集总耗时达 14.44 小时），难以满足实际部署需求。DF-ACR 通过时空联合降维机制，将该数据集上的总耗时缩短至 3.14 小时，加速比达到 4.6 倍。尽管 LoFT 方法的加速比略高，但结合表 4-5 可知，是以牺牲模型鲁棒性为代价的。整体而言，DF-ACR 的加速效果优于 Flash-AT 和 ME-AT。

在分类与防御性能方面，传统对抗训练 PGD-AT 虽然提升了鲁棒性，但会导致模型在干净样本上的准确率明显下降，均低于 90%。DF-ACR 凭借动态过滤机制有效缓解了这一问题，在两个数据集上的准确率分别保持在 94.10%和 94.80%。同时，在面对 PGD-20 高强度攻击时，DF-ACR 的鲁棒准确率 61.60%和 63.90%与 PGD-AT 相比差距极小，且明显优于 Flash-AT 和 LoFT 等轻量化基线方法。这表明 DF-ACR 在削减训练计算成本的同时，能够有效维持大模型的高精度与抗逃逸能力。

为了从全局视角客观评估各对抗训练方法在亿级高熵加密流量下的综合性价比，本节基于 CP-Full 数据集，绘制了训练时间开销与鲁棒准确率的 Pareto 前沿权衡分析图。在以时间成本为横轴、PGD-20 准确率为纵轴的二维分布系中，理想的大模型工业级训练方案应当尽可能逼近坐标系的左上角区域。




图 4-4 训练效率与鲁棒准确率的 Pareto 前沿权衡分析

图 4-4 直观展示前沿大语言模型加速机制与 DF-ACR 的性能拓扑分布。PGD-AT 虽达 63.5%鲁棒准确率上限，但耗时 17.5 小时，实用性受限；Standard 耗时仅 2.5 小时，却无防御能力。LoFT 耗时 3.2 小时但鲁棒准确率仅 54.2%；Flash-AT 缓解显存墙但引入近似误差，准确率降至 58.5%；ME-AT 解决显存溢出但重计算导致耗时达 8.5 小时。DF-ACR 通过剔除冗余样本、复用特征缓存将训练耗时削减至 3.8 小时，同时维持 63.2%无损防御精度，形成的全新 Pareto 前沿证实其是全加密流量抗逃逸任务的最优落地方案。

4.6.3 资源消耗与显存优化分析

除了训练时间效率外，深度学习模型对计算资源的占用情况，是衡量其在工业互联网边缘设备等资源受限场景下可部署性的另一项关键指标。本节深入剖析了 DF-ACR 方法在训练过程中的显存峰值表现与单轮耗时的具体构成，旨在揭示其高效性的底层来源。




图 4-5 不同训练策略下的 GPU 显存峰值占用对比

图 4-5 展示了 6 种算法的显存足迹。Standard 作为基准仅占用 8.2GB。传统的 PGD-AT 显存需求高达 21.5GB，不仅逼近了 4GB 的物理红线，且在大批次下极易突破 A100 的单任务分配限额。在前沿加速算法中，Flash-AT 通过算子优化将显存压低至 18.2GB，但仍较高。LoFT 由于仅微调极小比例的低秩参数，显存降至 11.5GB，展现了极佳的轻量化特性。ME-AT 作为显存优化的最前沿，通过显存重计算技术实现 10.8GB 的最低占用，但代价是极大的计算延迟。

相比之下，本文 DF-ACR 实现了资源占用与防御性能的 Pareto 最优，其峰值显存为 14.2GB。它成功将 ET-BERT 的对抗训练门槛降至 16GB 以下。这不仅意味着在 A100 集群上可以获得更高的计算并发密度，更证实了该算法在资源受限的网络流量场景中具备极强的可部署性。

为了进一步探究加速效果的微观机理，图 4-6 对各方法的单轮训练耗时进行了细粒度的成分分解，将总时间拆解为基础训练、对抗生成以及额外开销三部分。




图 4-6 异构大模型单轮训练耗时的细粒度成分分解

如图 4-6 所示, 该堆叠图清晰揭示不同加速方式的提速逻辑。PGD-AT 时间瓶颈源于对抗生成模块, 其需在 Transformer 参数空间执行 K 次串行梯度迭代, 耗时占比高达 82%。Flash-AT 通过算子优化缩减基础训练时间, 但对抗生成负担未缓解; ME-AT 显存占用低, 但梯度重计算导致额外开销激增, 总耗时偏高; LoFT 通过低秩空间生成扰动压缩对抗生成时间, 但精度折损较大。

DF-ACR 展现极优耗时结构: 筛选与缓存读写仅引入约 6% 算法额外开销, 且在 T_c 周期内读取历史扰动、跳过昂贵迭代攻击步骤, 将对抗生成时间压缩近 90%。这种以极低算法开销换取极高攻击耗时降幅的策略, 使训练节奏近似 Standard 模式, 从计算复杂度层面本质优化对抗训练范式。

4.6.4 消融实验

为了验证 DF-ACR 框架中动态流过滤 DF 与自适应缓存复用 ACR 两个核心模块的独立贡献及其协同加速效应, 本节在 CP-Full 数据集上设计了消融对比实验。我们构建了以下三种变体模型与基准 PGD-AT 进行对比:

w/o ACR: 仅启用动态过滤策略, 禁用缓存机制。

w/o DF: 仅启用检索缓存机制, 不对样本进行过滤。

DF-ACR: 完整版本, 同时启用双重加速机制。




图 4-7 核心加速模块有效性的消融实验结果

图 4-7 双轴对比图直观展示各变体方法相对 PGD-AT 的加速比与鲁棒准确率变化轨迹, 消融实验揭示显著机制互补效应。单独启用 DF 模块实现 2.4 倍加速, 证实剔除简单样本可削减计算规模, 但难样本满载对抗计算导致提速瓶颈, 准确率滑落至 61.8%; 单独启用 ACR 模块通过跨步缓存复用压缩计算图深度, 达成 2.9 倍加速, 精度维持在 62.9%。

完整版 DF-ACR 双重机制协同工作, 斩获 4.6 倍超线性加速, 鲁棒准确率达 63.2%, 近乎无损逼近 PGD-AT 理论上限。这表明 DF 的广度剪枝与 ACR 的深度复用形成乘数效应, 二者相辅相成, 实现训练效率与防御性能的最佳结合。

4.6.5 参数敏感性分析

DF-ACR 框架的性能表现主要受两个核心超参数的影响：流样本保留比例（Retention Ratio, ρ ）与检索缓存更新周期（Caching Period, T_c ）。前者决定了计算负载的缩减程度，后者决定了历史梯度信息的复用频率。为了探寻这两个参数的最优配置，本节在 CP-Full 数据集上进行了细致的参数敏感性分析实验。

首先，探究流样本保留比例 ρ 对模型性能的影响。实验中，我们将 ρ 从 100% 逐步降低至 30%，观察加速比与鲁棒准确率的变化趋势。




图 4-8 动态过滤保留比例 ρ 对加速比与精度的影响

图 4-8 实验结果揭示计算量缩减与特征学习完整性的复杂权衡关系。加速维度上，随 ρ 降低，训练加速比线性增长， ρ 降至 50% 时，计算图大规模剪枝使加速比达 4.6 倍。精度维度上，准确率呈平台-骤降特征： $\rho \in [60\%, 100\%]$ 区间，鲁棒准确率稳定在 63.5% 左右， $\rho=80\%$ 附近微幅提升，证实加密流量存在大量对抗冗余，剔除简单样本可缓解过拟合，不破坏特征流形构建。当 ρ 降至 40% 以下，模型丢失关键难样本，特征空间覆盖不全，准确率大幅下跌。据此，将动态过滤下限设定为 $\rho=50\%$ ，在确保防御性能无损的前提下，最大化释放算力，实现训练效能 Pareto 改进。

其次，分析缓存更新周期 T_c 的影响。该参数决定了模型每隔多少个 Epoch 重新计算一次精确的对抗梯度。实验测试了 T_c 在 1 到 5 之间的取值。




图 4-9 检索缓存更新周期 T_c 对模型性能的敏感性分析

图 4-9 实验轨迹揭示梯度时效性与加速效率的耦合规律。随 T_c 增加，模型跳过完整反向传播的频率提升，训练加速比持续走高，当 $T_c=5$ 时，系统加速比达 5.2 倍。但过大的 T_c 会引发严重梯度过期问题：对抗扰动计算依赖实时模型参数，当 $T_c \geq 4$ 时，历史梯度信息与实时参数偏离，无法有效引导对抗样本生成，导致模型鲁棒性衰退， $T_c=5$ 时准确率仅为 60.4%。

数据显示当 $T_c=3$ 时，DF-ACR 既能实现 4.6 倍高加速比，又能将鲁棒准确率稳定在 62.8%，较 PGD-AT 基准仅微弱折损 0.3%，是兼顾梯度时效性与计算成本的最优临界点。

据此，本文将 DF-ACR 的最佳更新周期设定为 $T_c=3$ ，确保海量高熵流量环境下系统兼具训练能效与防御稳定性。

4.6.6 动态流过滤过程与自适应类别平衡分析

为探究 DF-ACR 框架中动态流过滤策略的实际运作机理，本节对模型在训练全周期内的样本筛选行为进行了可视化监控。图 4-10 展示了在 ET-BERT 训练过程中，参与反向传播计算的保留样本（Kept Samples）与被跳过的过滤样本（Filtered Samples）的数量变化情况。




图 4-10 训练全周期内流样本动态过滤过程的可视化

图 4-10 堆叠面积图揭示样本保留比例 ρ 的非线性演变。Epoch 0 至 5 预热期，系统强制 100% 样本参与计算，保障模型获取完整基准特征；Epoch 5 后进入修剪期，过滤机制阶梯状介入，剔除样本规模逐轮扩大；训练后期进入稳态，算力锁定在约 50% 高价值对抗样本，使 DF-ACR 持续提速，验证其自动聚焦决策边界的精细化算力分配能力。

该机制还具备自适应类别平衡衍生属性。App60 数据集呈长尾分布，传统对抗训练中多数类主导梯度更新，容易忽略少数类特征；而 DF-ACR 中，多数类因拟合快、损失和梯度范数下降，中期被大量过滤，少数类因不确定性高被近乎 100% 保留，无需额外采样即实现类别梯度平衡，提升长尾混淆类别鲁棒性。

为了直观量化这一过滤机制对不同类别样本的选择，表 4-6 统计了处理 CP-Full 全量数据集时典型多数类（如样本规模巨大的 Facebook 社交流量）平均保留率 $\rho_{max}^{(t)}$ 与典型少数类（如具备长尾特征的 Signal 加密通讯流量）平均保留率 $\rho_{min}^{(t)}$ 在不同训练阶段的变化，公式如下：

$$\rho_{maj}^{(t)} = \frac{1}{K_{maj}} \sum_{c \in maj} \rho_c^{(t)}, \quad \rho_{min}^{(t)} = \frac{1}{K_{min}} \sum_{c \in min} \rho_c^{(t)} \quad (4.30)$$

其中， K_{max} 和 K_{min} 分别为参与统计的典型多数类和少数类数量。

表 4-6 典型多数类与少数类在不同训练阶段的动态保留率对比

训练阶段	典型多数类平均保留率	典型少数类平均保留率	类别平衡演化效应
初期 Epoch1	100.0%	100.0%	全量计算，建立基础特征映射
中期 Epoch10	62.5%	94.8%	多数类进入拟合平台期，简单样本开始被剔除
后期 Epoch20	15.2%	88.5%	计算图高度精简，算力自适应向长尾类别倾斜

如表 4-6 的实测数据所示，在训练初期 Epoch 1，模型对所有流量保留率均为 100%，以确保模型能够从底层捕获全局语义。但进入训练后期 Epoch 20，占比极高的多数类 Facebook 样本保留率已骤降至 15.2%，而作为少数类的 Signal 样本保留率依然维持在 88.5% 左右。这一跨越量级的保留率差异，从微观层面印证了 DF-ACR 的空间过滤机制在物理意义上等效于一种隐式动态难样本挖掘。

这种机制使得每个 Batch 内实际参与梯度反向传播的样本分布，自发地从原始的长尾分布向均衡分布演化。这种无需人工干预的内生类别重加权机制，使得模型在削减冗余计算量的同时，不仅未折损对长尾样本的特征获取能力，反而通过维持少数类的高权重更新，有效抑制了灾难性遗忘现象。这一发现解释了前文表 3-5 中 DS-RGO 框架在宏观 Macro-F1 评价体系下领先的深层加速机理，实现了高训练效率与抗类别不平衡干扰的结合。

4.6.7 资源利用率与大批次扩展性分析

在工业级加密流量分析场景中，训练算法对硬件资源的利用率及大规模扩展性至关重要。随着 ET-BERT 等序列模型参数量的激增，显存墙效应成为限制对抗训练吞吐量的核心瓶颈。本节评估了在不同 Batch Size 设置下，各主流训练方法在 CP-Full 数据集上的计算吞吐量（Throughput, samples/s）。




图 4-11 不同批次大小下的计算吞吐量与扩展性分析

图 4-11 展示 Batch Size 从 16 增至 64 时各方法吞吐量变化。所有批次下 DF-ACR 吞吐量均显著优于各前沿加速基线。Batch Size=32 时，DF-ACR 处理速度达 110 samples/s，约为 PGD-AT 的 4.4 倍，优于 Flash-AT；Batch Size=64 时，PGD-AT 与 Flash-AT 因显存溢出触发 OOM 错误导致训练中断。DF-ACR 通过动态流过滤削减反向传播计算图释放显存冗余，Batch Size=64 时仍稳定运行，吞吐量攀升至 135 samples/s，较显存优化的 ME-AT 领先约 1.5 倍。这证明 DF-ACR 具备卓越的硬件扩展能力，能够深度挖掘大容量 GPU 的并行计算潜力，契

合大规模高性能计算集群在网络安全实战中的部署需求。

4.6.8 工程综合收益评估

为了最终量化 DF-ACR 框架在真实工业环境下的综合工程收益，本节汇总了 ET-BERT 模型在 CP-Full 数据集下，采用不同对抗训练加速策略时的核心性能指标。表 4-7 从防御效能、时间成本、空间压力及硬件适配性四个维度进行了对比。

表 4-7 异构训练策略下 ET-BERT 模型的资源开销与轻量化收益对比

训练策略	鲁棒准确率(PGD-20)	单轮耗时	显存峰值	理论计算开销(FLOPs)	16GB 设备适配性
Standard	0.0%	2.5h	8.2GB	0.14×	Excellent
PGD-AT	63.5%	17.5h	21.5GB	1.00×	OOM
Flash-AT	61.5%	5.8h	18.2GB	0.33×	OOM
LoFT	59.8%	4.2h	11.5GB	0.24×	Excellent
ME-AT	62.8%	8.5h	10.8GB	0.48×	Excellent
DF-ACR	63.2%	3.8h	14.2GB	0.22×	Excellent

如表 4-7 所示,DF-ACR 框架在 ET-BERT 加密流量对抗训练任务中展现出了良好的 Pareto 优化特性。与经典的 PGD-AT 相比,DF-ACR 在保持防御性能几乎无损的前提下,实现了约 4.6 倍的端到端训练提速,并将理论计算复杂度大幅压缩了 78%。

在工程实战意义上,与当前最前沿的加速算法相比,DF-ACR 成功解决了速度-精度-显存的零和博弈问题。虽然 ME-AT 凭借梯度重计算技术将显存降至最低,但其训练耗时比 DF-ACR 多出 123%; LoFT 虽轻量,但其鲁棒性折损高达 3.7%。

DF-ACR 成功将原本属于重资产运算的大模型对抗训练任务,压缩至单卡 16GB 显存的工业边缘设备即可平滑运行的范畴。这种从高门槛集群到中端工作站的硬件适配性突破,极大地提升了加密流量防御模型在动态对抗环境下的敏捷更新能力,具备极高的实战部署价值。

4.7 本章小结

本章针对 ET-BERT 等大规模加密流量分析模型在对抗训练场景下面临的计算资源瓶颈与显存受限问题,提出了一种基于动态流过滤与自适应缓存复用的高效训练方法 DF-ACR。首先,从空间维度出发,构建了基于流特征动态重要性的样本过滤机制,通过精准剔除对鲁棒性贡献较低的简单样本,显著减少了无效计算量。其次,从时间维度出发,设计了适配变长序列的对抗扰动缓存策略,利用对抗扰动的慢变性实现了历史梯度的有效复用,大幅降低了反向传播的频率。

最后,在 Cross-Platform2022(App60)数据集上的实验结果表明,DF-ACR 方法成功打破了传统 PGD-AT 的效率壁垒。在保证鲁棒准确率无显著下降的前提下,该方法实现了平均 4.6 倍的训练加速比,并将显存峰值占用降低了 31%。相比 Flash-AT、LoFT、ME-AT 等现有加速算法,DF-ACR 展现出了更优的综合效能比。结合第三章的高鲁棒性防御策略与本章的高效率训练框架,

本文最终构建了一套兼具理论深度与工程可行性的加密流量抗逃逸分析体系,为应对全

加密时代的网络安全威胁提供了强有力的技术支撑。

第五章 加密流量分析集成平台与评估系统的设计与实现

5.1 系统需求分析

本系统旨在构建一个面向加密流量分析的多功能对抗防御算法集成与效能评估平台，用于验证本文提出的 DS-RGO 博弈防御算法与 DF-ACR 高效训练机制在工程实践中的有效性。本系统为评估模型在对抗环境下的鲁棒性提升与训练资源优化效果提供了完整的实验验证支撑。

5.1.1 功能性需求

依据算法验证的闭环逻辑，系统功能划分为以下四个核心模块：

（1）用户与实验任务管理

系统需具备基础的权限控制与实验任务隔离能力，包括：

权限认证：支持多用户注册与登录，基于 RBAC 模型实现用户身份鉴权，保障实验数据的安全性与独立性。

任务编排：支持创建独立的实验项目，允许用户针对不同的数据集和模型架构配置专属的实验任务，并对历史训练权重与评估日志进行版本化管理。

（2）数据接入与多模态预处理

系统需支持离线数据集的标准化导入与异构特征工程，包括：

离线数据解析：支持 PCAP/PNG 原始流量文件及 CSV 格式标注数据集的上传与解析，内置五元组流重组与头部去隐私化组件。

多模态特征映射：针对异构模型架构提供差异化预处理管线。对于序列模态，实现载荷的十六进制序列化与 Subword 分词；对于视觉模态，实现流字节向灰度矩阵的映射与归一化变换，输出适配深度学习框架的标准 Tensor 数据。

（3）对抗博弈训练与加速配置

系统需将本文核心理论算法封装为可配置的功能组件，包括：

博弈防御配置：内置 PGD、FGSM 等梯度攻击算法库，支持用户自定义 DS-RGO 算法的关键超参数，以验证不同对抗强度下的模型鲁棒性边界。

高效训练配置：集成 DF-ACR 加速引擎，提供动态流过滤与自适应缓存复用的功能开关及参数阈值调节接口。系统需支持在训练过程中动态启用双层级联优化策略，以验证算法在显存开销与时间成本上的优化效能。

（4）模型性能评估与可视化

系统需提供定性与定量相结合的多维度评估视图，包括：

训练过程监控：实时渲染训练过程中的损失函数 Loss 收敛曲线及准确率 CA/RA 变化趋势，直观反映模型的收敛状态与防御效果。

效能对比分析：自动计算并直观展示开启 DF-ACR 加速算法前后的训练耗时与显存占用对比，量化评估系统的资源优化能力。

特征空间投影：集成 t-SNE 降维算法，对测试样本的高维特征进行二维可视化投影，直

观展示防御前后模型在特征空间中对恶意流量与正常流量的聚类分离度。

5.1.2 非功能性需求

除系统功能性需求外，系统的非功能性需求对确保系统平稳运行和保证用户使用满意度具有至关重要的作用，本系统的非功能性需求如下：

（1）系统交互性：系统应采用 B/S 架构设计，提供简洁友好的 Web 图形化交互界面。参数配置项应具备合法性校验机制，降低算法验证的操作门槛与配置错误率。

（2）运行稳定性：鉴于对抗训练任务的高计算负载特性，系统需具备长时间运行的稳定性。后台服务应具备内存溢出保护与异常捕获机制，在显存资源不足时能够自动中断当前 Batch 并提示用户调整参数，防止服务崩溃。

（3）模块可扩展性：系统架构应遵循模块化设计原则，解耦算法逻辑与业务逻辑。底层模型接口应具备良好的扩展性，支持通过脚本插件的形式便捷集成新的骨干网络或新型攻击算法，以适应未来的研究拓展需求。

5.2 系统架构设计

基于高内聚、低耦合的软件工程设计原则，本系统采用经典的 B/S 分层架构，自下而上划分为四个逻辑层次：数据接入层、核心计算层、业务服务层与表现层。各层之间通过标准化的接口进行数据交互与功能解耦，具体架构如图 5-1 所示。




图 5-1 系统总体架构图

（1）数据接入层

该层位于架构的最底层，主要负责系统全生命周期数据的持久化存储与访问。既包括基于 MySQL 等关系型数据库存储的用户信息、实验配置参数及评估指标，也涵盖利用高性能文件系统管理的离线 PCAP 流量数据集、预处理后的中间特征文件以及模型训练权重文件。

该层通过 ORM 技术屏蔽底层数据库差异，为上层提供统一数据读写接口。

（2）核心计算层

该层位于架构的中下部，是本系统的算法引擎核心，直接对接底层 GPU 硬件资源。该层基于 PyTorch 深度学习框架构建，封装了本文第三章提出的 DS-RGO 博弈防御算法与第四章提出的 DF-ACR 高效训练机制。其核心任务是接收上层下发的训练指令，动态分配显存资源，执行复杂的张量运算、反向传播及对抗样本生成任务，并实时回传 Loss、Accuracy 等训练状态指标。

（3）业务服务层

该层位于架构的中上部，是系统的逻辑中枢，负责调度各层资源以完成具体的业务功能。它封装了用户权限鉴权、实验任务管理、文件上传校验、算法调度策略等核心逻辑模块，起到承上启下的关键作用。该层将底层的复杂算法调用过程抽象为统一的 RESTful API 接口，向表现层提供稳定数据服务，屏蔽底层算法迭代对前端界面的影响。

（4）表现层

该层位于架构的最顶层，直接面向用户提供可视化的交互操作环境。该层采用现代 Web 前端技术构建，提供实验参数配置向导与数据上传组件。同时，该层集成了 ECharts 等可视化库，负责将后端的训练日志与评估结果实时渲染，实现算法效能的直观展示。

5.3 系统功能模块设计

依据系统总体架构及用户的操作业务流，本系统在逻辑上划分为四个独立功能模块：用户管理模块、模型训练模块、模型验证模块以及可视化分析模块，如图 5-2 所示。




图 5-2 系统功能模块设计图

5.3.1 用户管理模块

该模块是系统的安全入口与实验管理基础，主要负责多用户环境下的资源隔离、实验配置管理以及任务调度，其状态流转逻辑如图 5-3 所示。




图 5-3 实验任务生命周期状态图

（1）功能描述

用户权限管理：系统提供参数化的配置面板，支持用户自定义实验名称、选择数据集版本、设置训练超参数以及对抗博弈参数。

试验任务管理：系统采用异步任务队列机制管理实验进程。用户提交任务后，系统根据 GPU 显存占用情况进行调度，自动维护任务从等待、运行到完成或失败的状态流转，确保实验过程的可监控与可回溯。

（2）关键业务流程

如图 5-3 所示，当用户提交实验请求时，系统后台首先进行参数合法性校验与资源预检。若显存资源充足，任务进入运行状态，系统实时记录训练日志；若训练过程中出现梯度爆炸或显存溢出，系统自动触发异常中断，并保存断点以便用户调整参数后重试。

5.3.2 模型训练模块

该模块是本系统的核心，集成了数据预处理管道与核心算法引擎。针对本文研究涉及的视觉模态与序列模态两种异构骨干网络，本模块设计了自适应策略路由机制，以确保算法策略与模型架构的精确匹配。详细流程如图 5-4 所示。




图 5-4 模型训练与策略适配流程图

(1) 数据加载与多模态预处理

系统不设独立的数据处理模块，而是将其作为训练流程的前置流水线。系统读取离线数据集的 PCAP 文件或预处理缓存，根据用户选择的模型类型自动切换处理算子：

视觉模态分支：若用户选择 BUPT-CNN 等视觉模型，系统调用图像映射算子，将流量载荷截断并重塑为灰度图像张量。

序列模态分支：若用户选择 ET-BERT 等序列模型，系统调用 Tokenizer 分词器，将流量

载荷转换为 Token 序列张量。

(2) 自适应对抗训练流程

系统依据骨干网络类型，动态构建计算图与优化策略：

分支 A：标准博弈防御（针对 CNN）。当检测到模型为 CNN 时，系统仅激活 DS-RGO 博弈防御引擎。在训练循环中，攻击生成器基于像素空间生成扰动，防御者基于 Stackelberg 博弈策略更新参数，自动屏蔽不适用的流筛选机制。

分支 B：高效级联优化（针对 ET-BERT）。当检测到模型为 Transformer 时，系统同时激活 DS-RGO 防御与 DF-ACR 加速引擎。在反向传播前执行双层优化：先进行流样本筛选，实时计算样本梯度敏感度，剔除对鲁棒性贡献低的简单样本；其次查询显存中扰动缓存池，若命中则复用历史最优扰动；最后在筛选后的难样本上执行梯度更新。

5.3.3 模型验证模块

该模块用于客观评估模型在未知对抗环境下的抗逃逸能力，采用离线留出法进行验证，流程如图 5-5 所示。




图 5-5 对抗鲁棒性验证流程图

(1) 验证数据源逻辑

系统加载在数据划分阶段预先留出的同源测试集。该部分数据遵循独立同分布假设，且从未参与模型的梯度更新过程。通过在此类数据上进行测试，能够有效评估模型对未见同类流量的泛化能力。

(2) 攻防演练与评估流程

验证过程包含两条并行的推理支线：

基准性能测试：将干净的测试样本输入模型，计算原始分类准确率 CA，验证模型对业务特征的学习效果。

对抗压力测试：系统调用内置的攻击模拟器，针对测试集实时生成高强度对抗样本。随后，将这些伪装流量输入模型进行推理，计算鲁棒准确率 RA。

通过对比开启防御算法前后的鲁棒准确率变化，直观验证 DS-RGO 算法的有效性。

5.3.4 可视化分析模块

该模块负责将抽象的实验数据转化为直观的图表，支持用户从微观特征到宏观指标的全方位分析，前后端交互时序如图 5-6 所示。




图 5-6 可视化评估交互时序图

(1) 功能描述

训练状态监控：绘制损失函数 Loss 收敛曲线，帮助判断模型是否收敛或过拟合。

效能对比审计：自动统计并以柱状图形式展示开启 DF-ACR 加速前后的训练总耗时与显

存占用峰值，量化评估系统的资源优化能力。

特征空间投影：系统后端集成 t-SNE 降维算法。用户发起请求后，系统抽取测试样本的倒数第二层输出，将其从高维空间映射至二维平面，并返回前端渲染为散点图。

(2) 交互时序逻辑

如图 5-6 所示，可视化流程采用异步请求模式。前端 Vue.js 组件发起数据请求，后端计算引擎读取数据库日志或实时执行降维计算，将处理后的 JSON 数据返回前端，由 ECharts 组件完成最终渲染。这种设计确保了在大数据量分析时前端界面的流畅性。

5.4 系统部署与运行环境

系统的部署架构与运行环境是保障原型系统功能可用性、实验结果可复现性以及算法性能指标真实性的物理基础。本节将从软硬件环境配置、运行优化策略两个维度阐述。

5.4.1 软硬件环境配置

本节侧重于全栈系统的工程化部署，选用了高性能计算服务器作为部署载体。详细配置如表 5-1 所示。

表 5-1 系统开发与部署环境配置表

类别	组件/模块	规格/版本	部署说明
硬件层	计算加速卡	NVIDIA RTX 4090 (24GB)	核心算力支撑。提供第四代 Tensor Core，支持 Stackelberg 博弈过程中的高维张量运算与 DF-ACR 的扰动缓存存储
	中央处理器	Intel Xeon Gold 6248R	多核并行架构，支撑离线 PCAP 数据集的多线程预处理与特征映射
	内存/存储	256GB RAM + 2TB NVMe SSD	配合 LMDB 内存映射消除小文件读取 I/O 瓶颈，保障数据不阻塞 GPU 计算
后端服务	操作系统	Ubuntu 20.04 LTS (Docker)	采用 Docker 容器化部署，构建独立的算法运行沙箱，隔离 CUDA 版本依赖
	深度学习框架	PyTorch 1.13.1 + CUDA 11.7	开启动态计算图适配流样本动态筛选
	任务调度容器	Celery + Redis	采用异步任务队列管理任务，替代同步请求模式，确保长周期训练任务稳定性
前端交互	交互框架	Vue.js 3.0 + Element Plus	基于 MVVM 模式构建响应式界面，实现实验配置与日志监控的前后端分离
	可视化引擎	Apache ECharts 5.0	实现 Loss 收敛曲线、t-SNE 特征分布散点图的高性能动态渲染

5.4.2 运行优化策略

为了在单卡算力限制下支撑大规模加密流量的对抗训练与验证，本系统在工程实现阶段实施了系统级资源隔离与算子级计算加速的双重优化策略。

(1) 容器化资源隔离与环境一致性

系统采用 Docker 容器技术构建了算法运行沙箱。通过编写 Dockerfile 严格锁定

Transformers、Scapy 等关键依赖库的版本，消除了因环境差异导致的依赖问题，确保了实验结果的可复现性。同时，利用 Docker 的`--gpusall` 参数实现 GPU 显存的独占式映射，防止系统后台进程抢占显存资源，确保 DF-ACR 算法中显存缓存池的稳定性与命中率。

（2）多模态模型的底层算子自适应加速

对本文涉及的异构模型，系统基于 RTX4090 硬件特性实施了差异化加速配置：

针对 Transformer（ET-BERT）的混合精度加速：

鉴于 BERT 模型参数量巨大，系统在训练与推理阶段开启 `torch.cuda.amp` 自动混合精度模块。该策略将模型前向传播的中间变量从 FP32 动态调整为 FP16，充分利用 RTX4090 的 Tensor Cores 算力。实测表明，该策略在保持 DS-RGO 梯度计算精度无损的前提下，将显存占用降低了约 40%，显著提升了 BatchSize 上限与训练吞吐量。

针对 CNN 的卷积核自动调优：

在系统初始化阶段，开启 `cudnn.benchmark=True` 选项。系统会自动根据输入流量灰度图的张量维度，在底层搜索最高效的卷积算法内核并进行缓存，从而优化 CNN 骨干网络的特征提取速度。

5.5 系统功能测试

系统测试是验证原型系统是否满足需求分析中规定的各项功能指标与性能指标的关键环节。本文采用黑盒测试方法，从功能性、运行性能以及安全性三个维度对系统进行全面的测试与验收。

5.5.1 功能测试

系统功能性测试旨在验证原型平台是否满足各项业务需求，重点评估实验配置交互的逻辑正确性以及后台策略路由机制的执行可靠性。本节采用针对数据接入、运行模式切换、算法内核调度及任务下发等核心功能点设计测试用例。

（1）实验配置与策略路由功能验证

实验配置模块是用户与底层算法引擎交互的核心中枢。如图 5-7 所示，系统实现了可视化的全景参数配置面板，并内置了完备的自适应校验逻辑：

运行模式自适应：系统支持从零执行训练与加载已训练模型直接评估两种执行逻辑。当用户切换至加载已有模型模式时，系统会自动激活文件上传组件，支持用户导入外部权重（`.pth/.onnx`），并智能绕过耗时的敏捷微调训练监控流程，直接进入对抗审计阶段。这证明了系统具备高度的流水线编排灵活性。

模型感知与防呆路由：在骨干网络选项中，系统预置了轻量级视觉模态 BUPT-CNN 与大规模序列模态 ET-BERT 两种异构架构。当选择计算密集的 ET-BERT 模型时，系统下方的 DF-ACR 加速内核开关保持激活状态；而切换至参数量极小的 CNN 模型时，系统会自动锁定并禁用该加速选项，从而防止无效的算力分配与系统资源浪费等问题。

并发调度与压测管控：针对工业界海量离线 PCAP 文件的处理需求，平台专门设计了离线检测流水线与并发压测模块。可通过拖拽滑块，动态配置检测任务的并发进程数，并下拉选择压测的数据规模。此外，系统内置了硬件状态感知提示，当分配过多进程时，会主动预警 GPU 显存溢出风险，显著提升了系统的工程健壮性。

算法内核协同与消融：界面底部提供了 DS-RGO 防御内核与 DF-ACR 加速内核的独立物理开关，允许以极低的门槛执行组合消融实验。测试表明，前端配置的博弈参数能够被后台调度引擎正确解析，并无缝注入底层的 PyTorch 计算图中。



图 5-7 实验配置与策略路由交互界面

(2) 核心功能测试用例与结果

为了全面验证系统的功能完备性，本次测试选取了 5 个关键功能点执行回归测试。测试环境基于 Chrome 120.0 浏览器与搭载 NVIDIA RTX A4000 的 Ubuntu 22.04 服务器。详细的测试用例及执行结果如表 5-2 所示。

表 5-2 系统功能测试用例与结果一览表

测试 ID	测试功能项	预置条件与输入数据	预期结果	实际结果	结论
FT-01	模型运行模式切换	选择加载已训练模型模式，上传权重文件	系统成功挂载权重，跳过训练流程，导航栏训练监控不可用。	与预期一致	通过
FT-02	策略路由自适应	选择模型 BUPT-CNN	DF-ACR 加速组件自动锁定并禁用，防止资源冗余	与预期一致	通过
FT-03	策略路由联合激活	选择模型 ET-BERT	系统解除 DF-ACR 锁定，支持手动开启加速与防御双核并行	与预期一致	通过
FT-04	对抗参数动态注入	在配置面板输入 $\epsilon=0.05$ ， $\alpha=0.01$	任务启动后，DS-RGO 防御引擎成功解析博弈梯度约束参数	与预期一致	通过
FT-05	App60 仿真闭环	提交全流程验证任务	系统依次执行数据预处理、微调加速、对抗审计，输出分类	与预期一致	通过

测试结果表明，本系统的实验编排、模型自适应路由及算法组件调度等核心模块功能运

行稳定。系统实现了对训练阶段（DF-ACR）与评估阶段（DS-RGO）的逻辑解耦与按需组合，确保了在面对不同研究需求时，平台能够自动匹配最优的计算路径与防御策略。

5.5.2 性能测试

为了量化评估系统在工程实现上的优越性，本节基于 RTX 4090 硬件环境设计了性能对比实验。实验采用控制变量法，固定骨干网络为 ET-BERT（参数量约 1.1 亿），对比开启与关闭 DF-ACR 加速引擎后的训练耗时、吞吐量与显存占用情况。

（1）DF-ACR 加速效能对比

实验选取 CP-Full 数据集进行 20 轮 Epoch 的对抗训练，记录平均单轮耗时与显存峰值。测试结果如表 5-3 所示。

在关闭加速引擎的标准对抗训练模式下，系统需对全量样本执行完整的梯度反向传播。测试显示，显存峰值占用达到 21.5GB，远超 RTX A4000 的 16GB 物理限额，导致系统频繁触发显存溢出而无法完成训练任务。

启用 DF-ACR 引擎后，系统利用流样本时空特征过滤机制剔除了约 45%的非关键样本。测试表明，显存峰值占用被成功压制在 14.2GB，降幅可以达到 34.0%，使模型能够在 16GB 的主流显卡上平稳运行。同时，训练耗时也实现了 78.3%的大幅度压缩，系统吞吐量稳定在 135 samples/s。这一结果验证了 DF-ACR 方法在工程落地中的核心价值：通过动态资源调度，在保障训练质量的前提下，成功突破了大规模序列模型的显存墙限制。

表 5-3 训练加速与资源开销对比测试表

实验配置方案	显存峰值占用(GB)	显存压降比	系统吞吐量(samp/s)	训练耗时压缩比
Baseline	21.5	-	约 31	-
DF-ACR	14.2	↓34.0	135	↓78.3%

（2）训练过程实时监控与资源审计

图 5-8 展示了系统在开启 DF-ACR 模式下的实时监控界面。

界面下方的显存占用实时轨迹清晰展示了优化前后的对比。灰色虚线代表标准 AT 模式的显存需求，已穿过红色 High-End GPU 警戒线；而蓝色实线代表 DF-ACR 模式下的实际开销，始终运行在绿色 Edge Limit(16GB)安全线以下。

右侧日志终端实时记录了 DF-ACR 引擎的运行细节。日志显示，系统成功执行了数据流时空特征预分析，并触发了样本动态过滤与时间维度扰动缓存复用机制。

顶部的四 KPI 指标实时汇总了当前任务的总体优化效能。测试显示，在 135 samp/s 的高吞吐负载下，模型显存保持稳定，证明了系统在复杂工业级环境下的工程稳健性。



图 5-8 实时训练监控与资源审计大屏

(3) 端到端离线检测吞吐量与并发调度压测

在完成模型的高效训练后，为进一步验证本系统在真实工业应用中盘点与审计海量历史加密流量的可用性，本文针对离线批量检测场景开展了端到端吞吐量（Queries Per Second, QPS）压测。测试涵盖了从 PCAP 文件解析、多模态特征清洗到 GPU 模型推理的完整 MLOps 流水线，具体评估结果如表 5-4 所示。

表 5-4 面向海量离线 PCAP 文件的端到端检测吞吐量评估

检测引擎核心模型	任务并发数	QPS(流/s)	平均单流延迟(ms)	GPU 显存峰值占用(GB)	系统吞吐瓶颈分析
BUPT-CNN	单任务串行	8,540	0.11	2.4	I/O 读取与图像矩阵映射 瓶颈
	4 进程多并发	14,200	0.28	6.8	多进程预处理打满 CPU， GPU 仍有余量
ET-BERT	单任务串行	2,850	0.35	9.5	Transformer 强算力消耗 与 Token 截断
	2 进程多并发	4,380	0.45	18.2	接近 RTX4090(24GB)显 存与算力极限

实验结果表明，系统在应对异构模型时展现出卓越的并发调度能力。对于轻量级的 BUPT-CNN 引擎，开启多进程并发后，系统最高检测吞吐量可达 14,200 流/秒，此时核心计算瓶颈在于前置的 I/O 载荷解析；而对于计算密集型的 ET-BERT 引擎，在双并发任务下吞吐量稳定在 4,380 流/秒，显存峰值达到 18.2GB，已逼近单张显卡的硬件红线。该压测数据证实，本平台构建的离线检测流水线不仅能够充分利用异构算力资源，更能够从容应对工业互联网

环境下 TB 级历史流量的快速安全审计需求，具备企业级的工程落地价值。

5.5.3 安全性测试

本节重点验证系统在面对恶意逃逸攻击时的鲁棒性，将安全性定义为深度学习模型在对抗环境下的特征不变性与抗扰动能力。实验基于 CP-Full 测试集，模拟强黑盒场景下的高强度 PGD-20 梯度攻击，深度对比开启防御内核前后的模型安全表现。

(1) 对抗攻击下的鲁棒性量化评估

表 5-4 展示了 ET-BERT 骨干网络在标准训练与开启 DS-RGO 防御模式下应对强对抗攻击 $\epsilon=0.05$ 的拦截效能。

在未开启防御的基准状态下，系统面临 PGD-20 攻击时的对抗鲁棒准确率 RA 降至 0.00%，攻击成功率 ASR 高达 100%。这表明在缺乏鲁棒加固的情况下，逃逸扰动能够轻易诱导模型发生分类偏差，致使流量识别系统失效。

启用 DS-RGO 引擎后，系统通过二阶博弈梯度优化策略，使模型在对抗空间内成功捕捉到了加密流量的语义不变特征。测试结果显示，模型在同等高强度攻击下的鲁棒准确率恢复至 82.50%，整体防御增益达+82.5%。此外，平均判定置信度从 0.14 显著提升至 0.87。该数据有力证明了本系统能够有效减小攻击者的对抗搜索空间，在极端扰动下依然维持了决策边界的稳定性。

表 5-5 对抗攻击下的鲁棒性评估数据表

评估维度	未开启防御	DS-RGO 开启	性能提升
对抗鲁棒准确率 RA	0.00%	82.50%	+82.5%
攻击成功率 ASR	100%	17.50%	-82.50%
平均置信度 Confidence	0.14	0.87	6.2x
二阶梯度稳定性	Low	High	显著增强

(2) 攻击防御效能可视化分析

图 5-9 展示了系统生成的对抗防御审计大盘，直观反映了系统在应用层级的防御细节。

界面左侧呈现了 App60 细粒度分类在攻击环境下的混淆矩阵。对角线区域的高亮绿色数值表明，绝大部分加密应用在受到逃逸扰动后，其特征向量依然被分类在原有的语义簇内，未发生大规模跨类偏移。

矩阵中的红色单元格展示了残余的错分样本。例如，部分 Chat 流量被诱导误判为 VoIP，这反映了强混淆协议在极端对抗下的边界重叠现象。

界面右侧实时汇总各项安全指标。审计结果证实，系统不仅能抵御弱噪声，在面对具有明确逃逸动机的梯度攻击时，依然能够提供满足工程安全阈值的防护能力。



图 5-9 对抗防御效能评估结果界面

(3) 特征空间防御机理可视化

为了从特征表示层面探究系统的防御机理与分类效能，还集成了高维特征分析模块。如图 5-10 所示，在进入加载测试集阶段后，系统通过内置的 t-SNE 降维引擎，将测试集中 6 类核心 App 在 ET-BERT 骨干网络倒数第二层的 768 维特征向量，映射至二维可视化流形空间。

界面显示，在开启防御内核后，测试样本呈现出显著的高内聚、低耦合聚类分布态势。尽管 WhatsApp 与 Telegram 同属即时通讯协议 Chat，YouTube 与 Netflix 同属流媒体视频协议 Video，存在高度的统计行为相似性，但模型依然能在特征空间中为它们划定清晰且互相独立的决策边界。对应全局轮廓系数达到 0.892，指示了极佳的类内紧凑度与类间分离度。

这一流形空间分布结果证实系统的博弈防御并未破坏模型对原始业务流量的分类能力。相反，它成功驱动模型摒弃了表层脆弱的统计特征，转而提取了深层、本质的加密语义不变性。这种高度鲁棒的特征表征结构，从根本上阻断了攻击者利用微小对抗扰动来跨越分类决策面的逃逸企图。




图 5-10 特征空间可视化分析界面

5.6 本章小结

本章在第三章提出的协同层级博弈防御算法与第四章设计的高效训练机制的基础上，设计并实现了一个面向加密流量的抗逃逸分析与效能评估系统。首先，本文明确了系统在多模态数据处理与高并发对抗训练场景下的功能性需求与非功能性需求，并构建了基于 B/S 的四层总体架构，确立了数据层、计算层、业务层与表现层的分层治理方案；其次，依据模块化开发思想，将系统划分为实验任务配置与资源调度、模型训练与策略适配、对抗鲁棒性验证以及可视化分析四大核心模块，详细阐述了基于异构模型路由的训练流程与基于同源留出法的验证逻辑，并解决了多任务并发下的资源竞争与调度问题；

最后，基于高性能计算集群与容器化技术完成了系统的全栈部署，并通过系统功能测试、加速比性能测试与抗逃逸安全性测试，量化验证了原型系统在工程实践中的运行效率与防御有效性，成功实现了理论算法向工程应用的转化。

第六章 总结与展望

6.1 论文总结

随着加密通信协议的全面普及，深度学习已成为网络空间安全监管与加密流量分析的核心组成部分。然而，模型高度非线性的决策边界使其在面对恶意流量逃逸攻击时暴露出严重的内生脆弱性。同时，旨在弥补这一缺陷的传统对抗训练方法在应用于大规模预训练模型时，又面临着梯度震荡难收敛、计算开销呈指数级增长的双重致命瓶颈。

针对上述安全防御与工程落地之间的核心矛盾，本文跳出传统对抗训练的局限，围绕模型防御鲁棒性、训练计算高效性以及攻防可视化部署三大维度展开了系统性、递进式的研究。通过引入博弈论优化与近似计算理论，本文成功打破了大规模模型在对抗训练中的性能与效率壁垒。全文的主要研究成果与创新点总结如下：

(1) 提出了基于动态难度调度与二阶反应梯度优化的抗逃逸训练方法（DS-RGO）

针对传统对抗训练极易陷入局部最优与梯度震荡的理论局限，本文将流量攻防演化建模为非对称的 Stackelberg 双层优化问题。通过展开双层优化显式计算二阶反应梯度，赋予了防御策略前瞻性的博弈约束；同时引入动态难度调度自适应平滑了非凸优化曲面。研究不仅彻底消除了训练初期的损失震荡，还引导模型提取了更具语义不变性的深层协议特征。在异构骨干网络上的验证表明，该方法较基线实现了 4.2%~8.6% 的鲁棒性提升，达成了防御能力与收敛稳定性的双重跨越。

(2) 提出了基于动态流过滤与自适应缓存复用的高效训练方法（DF-ACR）

针对大规模预训练模型在执行多步对抗迭代时面临的极高时间开销与显存溢出瓶颈，本文提出了一套时空联合的高效训练架构。在空间维度，基于预测不确定性与梯度敏感度实时评估，动态剔除对决策边界贡献极低的简单样本；在时间维度，利用对抗扰动的慢变性特征构建外部记忆库，并通过静态存储-动态对齐策略彻底解决了变长序列的高维张量复用难题。实验证实，该机制在鲁棒准确率边际损失微乎其微的前提下，实现了平均 4.6 倍的加速比，并显著压降了峰值显存占用，打破有限算力下大模型鲁棒性训练的效率壁垒。

(3) 设计并实现了加密流量分析集成平台与评估系统（ETADS）

为推动前沿算法向工业级现网场景转化，本文基于 B/S 架构独立研发了一套功能完备的四层验证平台。该系统底层深度封装了上述两大核心算法，前端不仅实现了异构骨干网络的自适应策略路由，还集成了高强度攻击模拟、高效模型训练与特征空间降维等全链路可视化功能。综合实测表明，系统在抵御高强度逃逸攻击时展现出卓越的防御鲁棒性，并在训练吞吐量与显存调度上实现了工程级的跨越式提升，真正完成了从理论算法推导到实际工程落地的技术闭环，充分验证了本文研究成果在真实工程环境下的可用性与优越性。

6.2 工作展望

尽管本文在加密流量的抗逃逸防御与加速训练方面取得了一定的理论突破与工程成果，但由于时间、算力及实验环境的限制，研究工作仍存在可进一步探索拓展的空间。未来的研

究工作将重点围绕以下四个方向展开：

（1）防御维度向非梯度攻击与多模态融合拓展

本文当前的安全性验证主要聚焦于白盒与黑盒场景下的梯度型逃逸攻击。而在真实的现网环境中，攻击者可能采用不依赖模型梯度的侧信道攻击。未来的工作将探索结合时序图神经网络（T-GNN）等先进架构，融合时空多模态特征，以抵御更广泛维度的免载荷规避攻击。

（2）验证场景向现网在线实时检测与跨域泛化演进

本系统的效能与安全性评估目前主要依赖于离线的同源标准数据集进行留出法验证。然而，真实网络流量具有高度的非平稳性与概念漂移特性。下一步计划将本系统以虚拟网络功能组件的形式旁路部署于软件定义网络环境中，引入联邦学习与增量学习机制，研究模型在面对零日未知加密流量时的持续自适应与跨域泛化能力。

（3）系统底层架构向分布式算力与大语言模型赋能升级

现有的 ETADS 原型系统主要基于单机单卡 RTX4090 环境进行任务调度与显存优化。随着骨干网流量规模的爆炸式增长，未来可引入 Kubernetes 与 Ray 等分布式计算框架，将现有的显存缓存池升级为分布式的全局 Redis 参数服务器。此外，考虑在可视化分析模块接入大语言模型 Agent，实现对异常对抗样本的自动化智能归因分析，生成自然语言级别的可解释性威胁情报报告，从而全面提升系统的安全闭环运营能力。

（4）向底层密码学特征与协议原生安全的探索

本文的研究主要聚焦于应用层统计特征以及深度学习骨干网络参数空间内的博弈防御，本质上仍属于加密后的被动防御机制。在真实的强对抗环境中，攻击者可能会利用 TLS 或 QUIC 协议本身的密码学特性进行更底层的规避。未来的研究将进一步探索突破现有的应用层或载荷特征提取框架，尝试结合握手阶段的密码套件协商指纹、密文随机性评估等底层密码学语义，寻求从协议规范层面实现更具原生安全性的内生防御体系。

参考文献

- [1] 付钰, 刘涛涛, 王坤, 等. 基于机器学习的加密流量分类研究综述[J]. 通信学报, 2025, 46(1): 167-191.
- [2] Google. Google Transparency Report: HTTPS encryption on the web[R/OL]. 2023.
- [3] Moore A W, Zuev D. Internet traffic classification using bayesian analysis techniques[C]//Proceedings of the 2005 ACM SIGMETRICS International Conference on Measurement and Modeling of Computer Systems. 2005.
- [4] Draper-Gil G, Lashkari A H, Mamun M S I, et al. Characterization of encrypted and vpn traffic using time-related[C]//Proceedings of the 2nd International Conference on Information Systems Security and Privacy (ICISSP). 2016.
- [5] SonicWall. 2022 Cyber Threat Report[R]. Milpitas, CA, USA: SonicWall Inc., 2022.
- [6] 樊祖薇, 张顺亮, 赵泓策. 基于深度学习的恶意加密流量检测及对抗技术综述[J]. 信息安全学报, 2024.
- [7] 刘奇旭, 肖聚鑫, 谭耀康, 等. 工业互联网流量分析技术综述[J]. 通信学报, 2024, 45(8): 221-237.
- [8] Conti M, Donadel D, Turrin F. A survey on industrial control system testbeds and datasets for security research[J]. IEEE Communications Surveys & Tutorials, 2021, 23(4): 2248-2294.
- [9] 王影, 王钢, 高雲鹏, 等. 基于深度学习的加密流量分类研究综述[J]. 计算机工程与应用, 2025, 61(21).
- [10] Yuan X, He P, Zhu Q, et al. Adversarial examples: Attacks and defenses for deep learning[J]. IEEE Transactions on Neural Networks and Learning Systems, 2019, 30(9): 2805-2824.
- [11] 崔苏苏, 刘宝旭, 董聪, 等. 加密流量识别技术综述[J]. 信息安全学报, 2023.
- [12] Lashkari A H, Gil G D, Mamun M S I, et al. Characterization of tor traffic using time based features[C]//International Conference on Information Systems Security and Privacy. SciTePress, 2017, 2: 253-262.
- [13] Zang X, Wang T, Zhang X, et al. Encrypted malicious traffic detection based on natural language processing and deep learning[J]. Computer Networks, 2024, 250: 110598.
- [14] Shen M, Liu Y, Zhu L, et al. Fine-grained webpage fingerprinting using only packet length information of encrypted traffic[J]. IEEE Transactions on Information Forensics and Security, 2021, 16: 2046-2059.
- [15] Rezaei S, Liu X. Deep learning for encrypted traffic classification: An overview[J]. IEEE Communications Magazine, 2019, 57(5): 76-81.
- [16] Wang W, Zhu M, Zeng X, et al. Malware traffic classification using convolutional neural network for representation learning[C]//2017 International Conference on Information Networking (ICOIN). IEEE, 2017: 712-717.
- [17] Zhang J, Pan L, Han Q, et al. DF-IDS: An intrusion detection system based on deep forest for encrypted traffic[J]. IEEE Access, 2022.
- [18] Lopez-Martin M, Carro B, Sanchez-Esguevillas A, et al. Network traffic classifier with convolutional and recurrent neural networks for Internet of Things[J]. IEEE Access, 2017, 5: 18042-18050.
- [19] Lotfollahi M, Jafari Siavoshani M, Shirali Hossein Zade R, et al. Deep packet: A novel approach for encrypted traffic classification using deep learning[J]. Soft Computing, 2020, 24(3): 1999-2012.

- [20] Lin X, Xiong G, Gou G, et al. Et-bert: A contextualized datagram representation with pre-training transformers for encrypted traffic classification[C]//Proceedings of the ACM Web Conference 2022. 2022: 633-642.
- [21] He H Y, Yang Z G, Chen X N. PERT: Payload encoding representation from transformer for encrypted traffic classification[C]//2020 ITU Kaleidoscope: Industry-Driven Digital Transformation (ITU K). IEEE, 2020: 1-8.
- [22] Yan J, Liu Z, Xie Y, et al. CertTA: Certified robustness made practical for learning-based traffic analysis[C]//34th USENIX Security Symposium (USENIX Security 25). 2025: 7349-7368.
- [23] He X, Chen Q, Tang L, et al. CGAN-based collaborative intrusion detection for UAV networks: A blockchain-empowered distributed federated learning approach[J]. IEEE Internet of Things Journal, 2023, 10(1): 120-132.
- [24] Telikani A, Gandomi A H, Choo K K R, et al. A cost-sensitive deep learning-based approach for network traffic classification[J]. IEEE Transactions on Network and Service Management, 2022, 19(1): 661-670.
- [25] Zhang J, Li F, Ye F, et al. Autonomous unknown-application filtering and labeling for DL-based traffic classifier update[C]//IEEE INFOCOM. IEEE, 2020.
- [26] 余正飞, 闫巧, 周鋈. 面向网络空间防御的对抗机器学习研究综述[J]. 自动化学报, 2022, 48(7): 1625-1649.
- [27] Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples[J]. CoRR, 2014, abs/1412.6572.
- [28] Papernot N, McDaniel P, Goodfellow I J, et al. Practical black-box attacks against machine learning[C]//Proceedings of the 2017 ACM on Asia Conference on Computer and Communications Security. 2017.
- [29] Iliyasu A S, Deng H. ACGAN-based data augmentation for encrypted traffic classification[J]. IEEE Access, 2020, 8: 114463-114473.
- [30] Shukla P, et al. A review on IoT DDoS attacks: Taxonomy, detection mechanisms, and challenges[C]//2023 International Conference on Computing, Communication and Networking Technologies (ICCCNT). IEEE, 2023.
- [31] 程定国, 曾浩洋. 无线通信网络中流量分析技术综述[J]. 电信科学, 2023, 63(3).
- [32] Madry A, Makelov A, Schmidt L, et al. Towards deep learning models resistant to adversarial attacks[C]//International Conference on Learning Representations. 2018.
- [33] Eldefrawy M, Butun I, Pereira N, et al. Formal security analysis of LoRaWAN[J]. Computer Networks, 2019, 148: 328-339.
- [34] 杨宇, 陈一丁, 赵荣, 等. 网络安全主动防御研究综述[J]. 科学技术与工程, 2025, 25(7).
- [35] Jajodia S, Ghosh A K, Swarup V, et al. Moving target defense: Creating asymmetric uncertainty for cyber threats[M]. Springer, 2011.
- [36] 刘小虎, 张恒巍, 马军强, 等. 基于攻防博弈的网络防御决策方法研究综述[J]. 网络与信息安全学报, 2022, 8(1): 1-14.
- [37] Liang X, Xiao Y. Game theory for network security[J]. IEEE Communications Surveys & Tutorials, 2013, 15(1): 472-486.
- [38] Wang A, Liang R, Liu X, et al. An efficient botnet detection system based on flow analysis and graph neural network[J]. Computers & Security, 2020.
- [39] 贺巩山, 赵传磊, 蒋金虎, 等. 面向深度学习的数据存储技术综述[J]. 计算机学报, 2025, 48(5): 1013-1064.

- [40] Dean J, Ghemawat S. MapReduce: Simplified data processing on large clusters[J]. Communications of the ACM, 2008, 51(1): 107-113.
- [41] 唐湘云, 王伟, 翁戡, 等. 联邦遗忘学习隐私安全与算法效率研究综述[J]. 计算机学报, 2025, 48(9).
- [42] Han S, Mao H, Dally W J. Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding[C]//International Conference on Learning Representations. 2016.
- [43] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[C]//NIPS Deep Learning Workshop. 2014.
- [44] McMahan B, Moore E, Ramage D, et al. Communication-efficient learning of deep networks from decentralized data[C]//Artificial Intelligence and Statistics. PMLR, 2017: 1273-1282.
- [45] 肖国庆, 李雪琪, 陈玥丹, 等. 大规模图神经网络研究综述[J]. 计算机学报, 2024, 47(1): 148-171.
- [46] Chiang W-L, Liu X, Si S, et al. Cluster-GCN: An efficient algorithm for training deep and large graph convolutional networks[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019.
- [47] 李国良, 周焯赫, 冯建华. 面向 AI 的数据管理技术综述[J]. 软件学报, 2020, 32(1): 21-40.
- [48] Hellerstein J M, Ré C, Schoppmann F, et al. The MADlib analytics library or MAD skills, the SQL[J]. Proceedings of the VLDB Endowment, 2012, 5(12): 1700-1711.
- [49] Hamilton W, Ying Z, Leskovec J. Inductive representation learning on large graphs[J]. Advances in Neural Information Processing Systems, 2017, 30.
- [50] 王睿, 王岩, 尹朴, 等. 面向边缘智能的协同训练研究进展[J]. 工程科学学报, 2023, 45(8): 1400-1416.
- [51] Mao Y, You C, Zhang J, et al. A survey on mobile edge computing: The communication perspective[J]. IEEE Communications Surveys & Tutorials, 2017, 19(4): 2322-2358.
- [52] Boehm M, Dusenberry M W, Eriksson D, et al. SystemML: Declarative machine learning on spark[J]. Proceedings of the VLDB Endowment, 2016, 9(13): 1425-1436.
- [53] Wang W, Zhu M, Wang J, et al. End-to-end encrypted traffic classification with one-dimensional convolution neural networks[C]//2017 IEEE International Conference on Intelligence and Security Informatics (ISI). IEEE, 2017: 43-48.
- [54] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30.
- [55] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2019: 4171-4186.
- [56] Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples[C]//International Conference on Learning Representations. 2015.
- [57] Carlini N, Wagner D. Towards evaluating the robustness of neural networks[C]//2017 IEEE Symposium on Security and Privacy (SP). IEEE, 2017: 39-57.
- [58] Rosenberg I, Shabtai A, Elovici Y, et al. Adversarial machine learning attacks and defense methods in the cyber security domain[J]. ACM Computing Surveys (CSUR), 2021, 54(5): 1-36.
- [59] Zhang H, Yu Y, Jiao J, et al. Theoretically principled trade-off between robustness and accuracy[C]//International Conference on Machine Learning. PMLR, 2019: 7472-7482.

- [60] Roth K, Lucchi A, Nowozin S, et al. Stabilizing training of generative adversarial networks through regularization[J]. *Advances in Neural Information Processing Systems*, 2017, 30.
- [61] Bengio Y, Louradour J, Collobert R, et al. Curriculum learning[C]//*Proceedings of the 26th Annual International Conference on Machine Learning*. 2009: 41-48.
- [62] Cai Q Z, Du M, Liu C, et al. Curriculum adversarial training[C]//*International Joint Conference on Artificial Intelligence*. 2018.
- [63] Zhang J, Xu X, Han B, et al. Attacks which do not kill training make adversarial learning stronger[C]//*International Conference on Machine Learning*. PMLR, 2020: 11278-11287.
- [64] Toneva M, Sordoni A, Combes R T, et al. An empirical study of example forgetting during deep neural network learning[C]//*International Conference on Learning Representations*. 2019.
- [65] Mirzasoleiman B, Bilmes J, Leskovec J. Coresets for data-efficient training of machine learning models[C]//*International Conference on Machine Learning*. PMLR, 2020: 6950-6960.
- [66] Katharopoulos A, Fleuret F. Not all samples are created equal: Deep learning with importance sampling[C]//*International Conference on Machine Learning*. PMLR, 2018: 2525-2534.
- [67] Paul M, Ganguli S, Dziugaite G K. Deep learning on a data diet: Finding important examples early in training[J]. *Advances in Neural Information Processing Systems*, 2021, 34: 20596-20607.
- [68] Shafahi A, Najibi M, Ghiasi M A, et al. Adversarial training for free![J]. *Advances in Neural Information Processing Systems*, 2019, 32.
- [69] Zhang D, Zhang T, Lu Y, et al. You only propagate once: Accelerating adversarial training via maximal principle[J]. *Advances in Neural Information Processing Systems*, 2019, 32.
- [70] Wong E, Rice L, Kolter J Z. Fast is better than free: Revisiting adversarial training[C]//*International Conference on Learning Representations*. 2020.
- [71] Zhu C, Cheng Y, Gan Z, et al. FreeLB: Enhanced adversarial training for natural language understanding[C]//*International Conference on Learning Representations*. 2020.
- [72] Peng S, Wang M, He J, et al. CAT: Contrastive adversarial training for evaluating the robustness of protective perturbations in latent diffusion models[C]//*Proceedings of the 42nd International Conference on Machine Learning*. 2025.
- [73] Ji Y, Liu Y, Zhang Z, et al. Advlora: Adversarial low-rank adaptation of vision-language models[J]. 2024.
- [74] Nie W, Guo B, Huang Y, et al. Diffusion models for adversarial purification[C]//*International Conference on Machine Learning*. 2022.
- [75] Wu B, Gu J, Li Z, et al. Towards efficient adversarial training on vision transformers[C]//*European Conference on Computer Vision*. Springer, 2022.
- [76] Fu J, Fang J, Sun J, et al. Loft: Lora-based efficient and robust fine-tuning framework for adversarial training[C]//*2024 International Joint Conference on Neural Networks (IJCNN)*. IEEE, 2024.
- [77] Xhonneux S, Sordoni A, Günnemann S, et al. Efficient adversarial training in llms with continuous attacks[J]. *Advances in Neural Information Processing Systems*, 2024, 37: 1502-1530.

作者简介

攻读硕士学位期间发表的论文

- [1] 基于 Stackelberg 博弈的安全对抗正则化研究[C]. 2025 东南大学校庆研究生学术报告会, 2025.